

12/13  
15/16

①

## OBJASNI DVA OSNOVNA POSTUPKA PROVJERE LINEARNOSTI MODELA:

## 1. NACIN

1. Proces se doveđe u radnu točku na sredini očekivanog radijusa podniza procesa  $[u_0(k), y_0(k)]$
2. Ulazni se signal skokovito promjeni za iznos  $\Delta u^{(1)}$  i snimi se odziv izlaznog signala procesa  $y^{(1)}(k)$
3. Proces se ponovo vrati u početnu radnu točku pa se ulazni signal skokovito promjeni za iznos  $\Delta u^{(2)}$  koji je  $\neq \Delta u^{(1)}$  veći od prethodne promjene ( $\Delta u^{(2)} = \Delta u^{(1)} + \Delta u^{(1)}$ ) i snimi se odziv izlaznog signala procesa  $y^{(2)}(k)$ . Tada se računa:

$$\boxed{p_y(k) = \frac{y^{(2)}(k) - y_0}{y^{(1)}(k) - y_0}}$$

4. Ako je  $p_y(k)$  konstantan i jednaku je, proces je LINEARAN!

- Zasniva se na međusobnoj usporedbi odziva procesa na više različitih skokovitih promjena ulaznog signala procesa.
- Postupak je potrebno provesti NAJMANJE DVA PUTA, jednom za POZITIVNU, a drugi put za NEGATIVNU PROMJENU ULAZNOG SIGNALA u odabranoj radnoj točki.
- Postupak je moguće provesti samo na procesima koji su STABILNI i mogu raditi u OTVORENOM PETLU!

## 2. NACIN

1. Na ulaz procesa doveđe se signal  $u(k)$ , koji se sastoji od istočuvanog offseta  $u_0$  i njuju superponirajućeg pobudnog signala  $u_{\text{sig}}(k)$  i snimi se odziv izlaznog signala procesa  $y(k)$
2. Tada se iz izlaznog signala eliminira očuvanje  $y^1(k) = y(k) - E[y(k)]$  te se izračuna korelacijska funkcija višeg reda:

$$\boxed{R_{yy^2} = E[y(k+\tau)y^1(k)]}$$

3. Ako je ispunjen uvjet  $R_{yy^2} = 0$  tada je proces LINEARAN

- Zasniva se na izračunavanju korelacijske funkcije izlaznog signala višeg reda.

15/16 (2) OBJASNITI VAŽNOST ODABIRA DIMENZIJE NEURONSKOG MODELA  
PROCESA, DIME MOŽE REZULTIRATI PREMALE, A ČIME PREVELIKU DIM?

• DIMENZIJA - ovaj je broj prošlih vrijednosti ulata u tlu, i  
broj neurona  $\Rightarrow$  (či broj konačja ul. i izl. signala i  
br. neurona u skrenutom sloju)

$\Rightarrow$  Postupak određivanja dim. NM-e se dijeli na POSTUPAK  
SMANJIVANJA DIMENZIJE MREZE i na POSTUPAK POVEĆANJA  
POVEĆANJA DIMENZIJE MREZE.  
 $\hookrightarrow$  Izgradbeni algoritmi

$\Rightarrow$  OPTIMALNA DIM. MODELA je ona dimenzija koja model čini  
dovoljno fleksibilnim da može modelirati svu relevantnu  
dinamiku procesa, ali koja u isto vrijeme ne povećava  
precise i to s varijancu prediktivske pogreske.

$\Rightarrow$  PREMALA DIMENZIJA - Može rezultirati podnaučenost modela,  
odnosno da model ne može modelirati  
svu relevantnu dinamiku procesa.

$\Rightarrow$  PREVELIKA DIMENZIJA - Može dovesti do preučenosti modela,  
- Može rezultirati povećanju numeričkim  
problemima pri estimaciji parametara  
modela  
- još gore: Može POVEĆATI VARIJANCU  
PREDIKCIJSKE POGRESKE  
 $\hookrightarrow$  Ovo uzrokuje pogoršanje svojstava  
popunjavanja modela, odnosno može  
se izgubiti svojstvo GENERALIZACIJE  
jer će model previše prilagođava  
sumu u podacima.

\* Prema br. konačja - podnaučenost - ne može se modelirati  
relevantna dinamika austv.  
izbor broja konačja ravno povezan s ODABIROM VREMENA  
IZDKOVANJA.

$\hookrightarrow$  MANJE VRJEME UZDKOVANJA  $\rightarrow$  POTENCIJALNA  
PRENUKLENOST  $\rightarrow$  PONREDNO KORISTITI VEĆI BROJ  
ZAKAŠNJENIH REGREFORA

③ OBJASNI KAKO POVEĆANJE MREŽE UDEĆE NA VARIJANCI POGREŠKE  
(FORMULA SA SLEDEĆIM I OPISATI REGULARIZACIJE)

REGULARIZACIJE  $\rightarrow$

- ① EKSPlicitna
- ② IMPlicitna

### ① EKSPlicitna REGULARIZACIJA

Ponebno minimizirati kriterij:

za  $N \rightarrow \infty$ ,  $\Theta^* = \Theta^0$

$$\Theta^0 = \operatorname{argmin}_{\Theta} \bar{J}(\Theta) = \operatorname{argmin}_{\Theta} \frac{1}{N} \sum_{k=1}^N [\ell_{\text{log}}(y(N)) - \ell_{\text{log}}(f_k(\Theta), \Theta)]^2$$

Zanima nas srednja vrijednost kvadratne pogreške  $\bar{J}(\Theta^*)$ .  
Da to odredimo neba nam treba očekivana vrijednost za sve skupove U/I podataka duljine  $N \rightarrow E(\bar{J}(\Theta^*))$ .

↳ Da bismo računamo neba ga linearizirati oko  $\Theta^0$ :

$$E(\bar{J}(\Theta^*)) = G_f^2 + E(\bar{J}(\Theta^0)) + G_f^2 \frac{n(\Theta)}{N}$$

SLUČAJ

i)  $\beta = 0$

→ Pogreška u potpunosti određena dimenzijom neuronske mreže. Dim  $\uparrow$ , pogr.  $\downarrow$   
 $E(\bar{J}(\Theta^0))$

ii)  $\beta \neq 0$  i  $N \rightarrow \infty \rightarrow E(\bar{J}(\Theta^*)) = G_f^2 + E(\bar{J}(\Theta^0))$

↳ dim  $\uparrow E(\bar{J}(\Theta^0)) \downarrow E(\bar{J}(\Theta^*)) \rightarrow G_f^2$

iii)  $\beta \neq 0$  i  $N$  konacan

→ Karo bi se omogulo dobro uspostvo raspodjeljivanja želimo manjiti rizik clana  $G_f^2 \frac{n(\Theta)}{N}$

↳ To postizemo ili smanjujući dimenzije modela ili povećanjem br. pod.

(EKSP. REG)  $\nabla J_r(\Theta) = \nabla J(\Theta) + 2k_r \Theta$ ,  $\nabla J(\Theta) \gg 2k_r \Theta \rightarrow$  REG. NEKA UDRINKA  
 $\nabla J(\Theta) \ll 2k_r \Theta \rightarrow$  REG. ODN VODI PAK  
 K NUMEROJ VR.

② IMPlicitna REGULARIZACIJA → Izračunava se ranoš funkcija  $J(\Theta^{(k)})$  na podacima za učenje i rizik na podacima za testiranje  $J^*(\Theta^{(k)}) \rightarrow$  u sljedećoj iteraciji

Pustiti se zaustavlja u trenutku kada je ispunjen uvjet:

$$J^*(\Theta^{(k)}) \geq J^*(\Theta^{(k-1)}) \text{ i } J(\Theta^{(k)}) \leq J(\Theta^{(k-1)})$$

#### 4 OBJASNITI IDEJU IZA KASKADNO KORELACIJSKE NEURONSKIE MREŽE TE SATI ALGORITAM UČENJA IZGRADNJE MREŽE.

KASKADNA KORELACIJA NEURONSKIE MREŽE spada pod postupke postupnog povećanja dimenzije neuronske mreže. Započinje se mrežom male dimenzije te poj potom povećava dimenziju postupno dokle god ne pronađe optimalnu.

- POSTUPAK:
- i) Kreće se od mreže koja je razbij sasivo od ul. i izlaznog sljga
  - ii) Iterativno se dodaje po jedan neuron u skorici sljgj
  - iii) Parametri dodanog neurona se određuju na način da PLAT NEURONA MAX KORELURA S POGR. APPROXIMACIJE
  - iv) Postupak se zaustavlja kada se dosegne željena razina pogreške aproksimacije.

PARAMETRI NEURONA : TEŽINSKI KOEFICIENT I POMAK

#### \* VREDNOVANJE MODELA - ZAVRŠNA FАЗА POSTUPKA IDENTIFIKACIJE

→ ZADACA - Objektivno vrednovati identificirani model procesa, odnosno ocijeniti stupanj podudaranosti vladanja identificiranog procesa modela sa stvarnim procesom (nepovini vladanja)

Provjera se mora provoditi na podacima za vrednovanje

RAZLIKUJEMO: 1) PARAMETARSKE ; 2) KORELACIJSKE POSTUPKE VREDNOVA

1) PARAMETRSKI postupak vrednovanja modela VREDNUJE IDENTIFICIRANI MODEL PROCESA USPOREDUJUCI GA S MODELOM (VIŠE DIMENZIJE)  
on se ne identificira

PREDNOST  
JASNA SE NA PROGONI V KRITERIJA KAKVOĆE MODELA VEĆE DIM.  
NA TEMEŠU IZNOSA KRIT. KAKVOĆE IDENTIFICIRANOG MODELA.

2) KORELACIJSKI postupak vrednovanja modela temelji se na IZRAČUNAVANJU AUTOKORELACIJSKE FJE  
PREDIKCIJSKE POGR. I KEDUKORELACIJSKIH FJI  
ODREĐENIH KOMBINACIJA RASPREDJIVIH SIGNALNIH PROCES

PREDNOST : jednostavnost

15/16  
12/13?

5) NAPISITE izraz za kriterijsku funkciju koja se minimizira u postupku ucenja mere s eksplucijom regularizacijom. Sto se radi u kriterijem postave?

$$\text{KRIT. Fa} \quad J_{\text{R}}(\theta) = J(\theta) + k_{\text{R}} \| \theta \|^2, \quad k_{\text{R}} = \text{koef. regularizacije}$$

$\Rightarrow$  Takvimi kriterijem se podnje da su KRAZENIM ČLANOM  
SUVIŠNI PARAMETRI drže na ŠTO MANJIM RAZOŠIRUJUĆA da  
se pri tome ne utječe načinjenje na važne parametarske mjerice.

6. SIVIŠNI PARAMETRI mreže su parametri koji ne utječu značajno na prvi član rizata za kontinuiranu fizičku.

## ⇒ OBJAŠNENJE UČINKA

$\rightarrow \Delta\theta \propto \nabla J_r(\theta) \Rightarrow$  Promjena parametara  $\theta$  proporcionalna je negativnom gradientu kriterijske funkcije  $J_r(\theta)$

$$\nabla J_r(\theta) = \nabla J(\theta) + 2k_r \theta$$

– Ako je  $\nabla J(\theta) \gg 2kr\theta \Rightarrow$  Parametar  $\theta$  jasno utječen na s kriterijse funkcije pa je gradient kriterijse već po njemu velik. To je maticom parameta i on se neće smanjivati pa tako REGULARIZACIJA NE MAJU INAKA.

- Ako je  $\nabla J(\theta) \ll 2kr\theta \Rightarrow$  Parametar  $\theta$  je u mali uvećanju  
na vremenjsku funkciju gradienta  
kao što je po nekom je fiksirani.  
Kako bi naručili vremenjsku  
funkciju naručimo nego  
ponos  $\rightarrow$  PRETREM G NARUČI

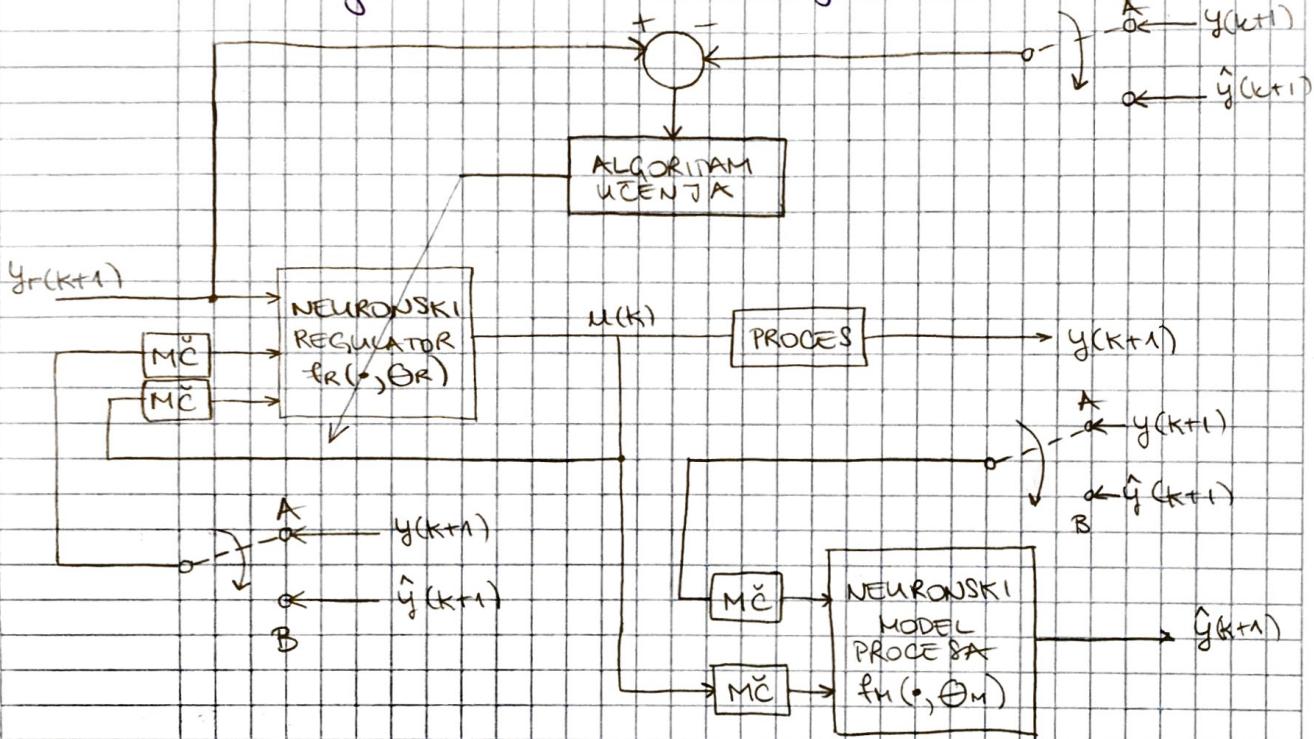
↳ CIV : PRITEGNUTI PARAMETRI KOI NE UMEĆU  
PUNO NA KRIT. FJU NA Ø JER ONI  
VODE DO PREKUČENOSTI.

→ POMAK (bias) - nerastuła fja od brojca param. NM-c.

(SMANJENJEM BROJA PARAMETARA MREŽE N JE OBICNO  
POVEĆAVA NEGOV IDNOS !

$\Rightarrow$  Kr  $\uparrow$  varianca  $\downarrow$  pomak  $\uparrow$

6) NACRTATI BLOK STEMU I OBJASNITI POSTUPAK NEIZRAVNOG INVERZNOG UPRAVljANJA KAKO GLASI IZRAZ ZA DERIVACIJU IZLAZA IZ NEURONSKOG MODELA PO NJEGOVOM ULAZU ZA SLUČAJ DUSLOVNE NARX RBF (NARX MLP U 12/13) MREŽE S DVA NEURONA U SKRIVENOM SLOJU I PO DVA PROŠLA Stanja ULAZA I IZLAZA.



⇒ POSTUPAK učenja neizravnog neuronskog regulatora zasniva se na IDENTIFICIRANOM MODELU PROCESA korišćekonst za izračunavanje gradienta kriterija ukućice po parametrima regulatora.

UČENJE REGULATORA može se provoditi ONLINE (A, sa interakcijom s procesom) ili OFFLINE (B) bez interakcije s procesom).

### i) OFF LINE

- Off line učenje se obavlja BEZ INTERAKCIJE S PROCESOM, što znači da INVERZNI MODEL PROCESA i UNAPRIJEĐENI MODEL PROCESA moraju biti u NEZADLUKU

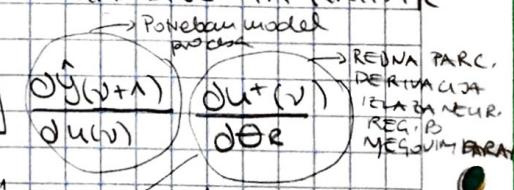
→ OPTIMALNA VR. PARAMETARA INVERZNOG NEURONSKOG REGULATORA u k-tom koraku učenja dobiju se MINIMIZIRANjem KRITERIJA UKUĆICE

$$J_R(\theta_R(k)) = \frac{1}{2} \sum_{v=0}^{N-1} (y_r(v+1) - \hat{y}(v+1, \theta_R))^2$$

SVAKI ALG. UČENJA ZAHTEVU PRORAČUN GRADIJENTA KRITERIJE PO PARAMETRIMA REGULATORA  $\theta_R$ :

$$\frac{\partial J_R(\theta_R(k))}{\partial \theta_R} = \sum_{v=0}^{N-1} [\hat{y}(v+1, \theta_R) - y_r(v+1)] \frac{\partial \hat{y}(v+1)}{\partial u(v)} \frac{\partial u(v)}{\partial \theta_R}$$

$$\frac{\partial u(v)}{\partial \theta_R} = \frac{\partial u(v)}{\partial \theta_R} + \sum_{p=1}^{N-1} \frac{\partial u(v)}{\partial u(v-p)} \frac{\partial^+ u(v-p)}{\partial \theta_R} + \sum_{r=0}^{N-1} \frac{\partial u(v)}{\partial \hat{y}(v-r)} \frac{\partial^+ \hat{y}(v-r)}{\partial \theta_R}$$



ii) **ON-LINE** - Postupak učenja se obavlja tijekom normalnog rada procesa i u intervalu s njim  
 INVERZNIH MOD. REG.

↳ PARAMETRI SE ODREĐUJU MINIMIZACIJOM KRITERITA:

Kad popuni zadani  
mali početni vektor  
zavrsava →

$$J_R(\theta_R(k)) = \frac{1}{2} \sum_{i=1}^n (y_r(i) - y(i))^2 \quad \approx \text{dužina površinskog putanja}$$

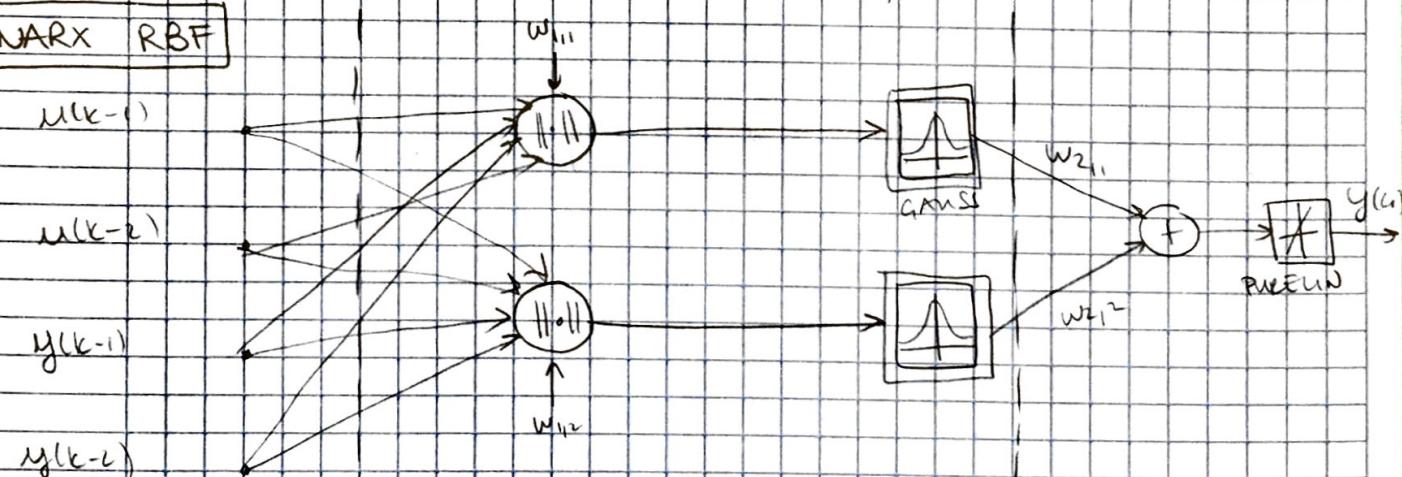
GRADIJENT  $\frac{\partial J_R(\theta_R(k))}{\partial \theta} = \sum_{i=1}^n [y(i) - y_r(i)] \frac{\partial y(i)}{\partial \theta} \frac{\partial \theta(i-1)}{\partial \theta}$

→ NAKON ISTO JE INVERZNI NEURONSKI REG. NAVĆEN SPAJAN GA SE U KASKADU S PROCEŠOM

→ IZRAVNO UČENJE VS. NEIZRAVNO UČENJE

- znatno složenije (OPUNE)
- konan je kad NELINEARNOST PROCEŠA NIJE BIJEKTIVNA
- USMJEŠEN ERSPUCJOM algoritmu temelji se na minimizaciji pogreške zadanog i stvarnog vlastitog rezulta procesa

⇒ **NARX RBF**



**GAUSS**

$$\Psi(v) = e^{-\frac{v^2}{2\sigma^2}}$$

$$\Psi'(v) = -\frac{v}{\sigma^2} e^{-\frac{v^2}{2\sigma^2}}$$

$$\text{ML. VECOR} \quad \Psi(a) = \begin{bmatrix} u(k-1) \\ u(k-2) \\ y(k-1) \\ y(k-2) \end{bmatrix}$$

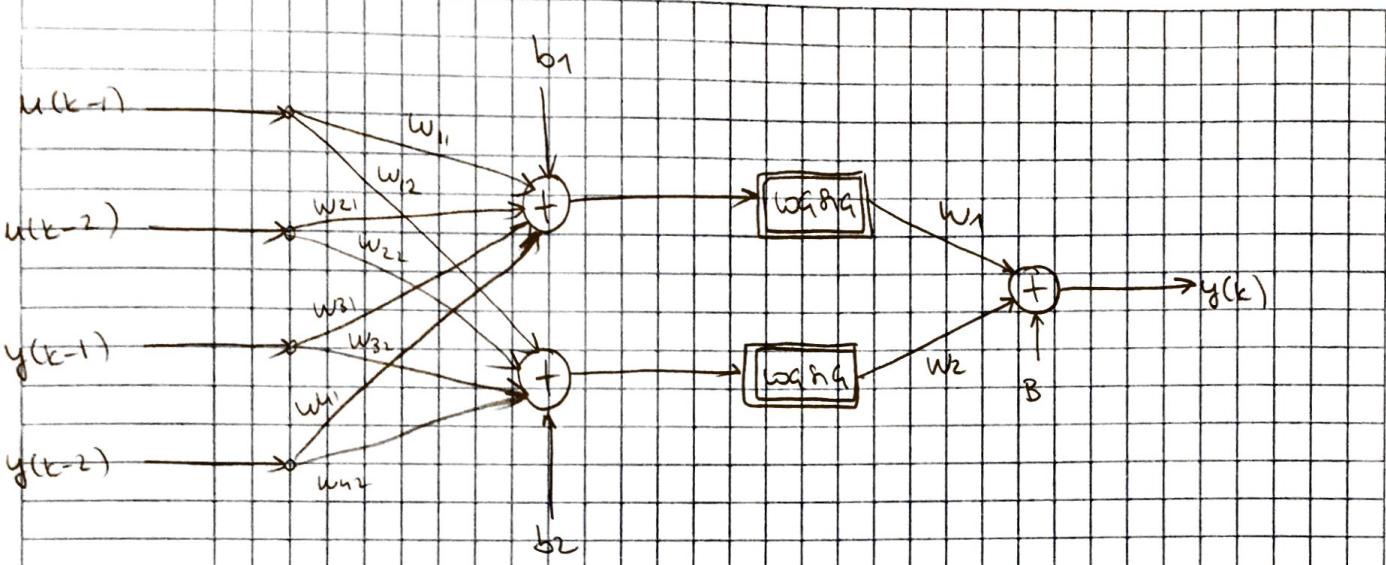
**MREŽA**

$$y(k) = w_{2,1} \cdot \Psi_1 \circ ((w_{1,1} - \Psi_1(k))) + w_{2,2} \Psi_2 ((w_{1,2} - \Psi_2(k)))$$

$$y(k) = w_{2,1} \Psi_1 \left( \sqrt{\sum_{i=1}^n (w_{1,1i} - \Psi_1(k))^2} \right) + w_{2,2} \Psi_2 \left( \sqrt{\sum_{i=1}^n (w_{1,2i} - \Psi_2(k))^2} \right)$$

$$= w_{2,1} \Psi_1 \circ \frac{1}{\sqrt{\sum (w_{1,1i} - \Psi_1(k))^2}} \circ \Psi_1(w_{1,1i} - \Psi_1(k)) (-1)$$

# NARX MLP



$$\Psi = \begin{bmatrix} u(t-1) \\ u(t-2) \\ y(t-1) \\ y(t-2) \end{bmatrix} \quad \text{logistic} \rightarrow \quad \Psi' = \Psi(1-\Psi)$$

~~$\Psi(t) = \Psi(t-1)$~~

$$y(t) = \sum_{i=1}^2 w_i \Psi_i \left( \sum_{j=1}^4 (w_{ji} \Psi_j) + b_i \right) + B$$

$$\frac{\partial y(u)}{\partial \delta} = \sum_{i=1}^2 w_i w_{ji} \Psi \left( \sum_{j=1}^4 (w_{ji} \Psi_j) + b_i \right) (1 - \Psi \left( \sum_{j=1}^4 (w_{ji} \Psi_j) + b_i \right))$$

7) Koji uvjeti moraju biti ispunjeni za IDEALNO UPRAVljANje UNIvARijNIM MODELOM, a koji za IDEALNU KOMPENZACIJU POREMEĆAJA

IDEALNO UPRAVljANje : Zadnjeva BESKONAČNO POJAČANje REG.

KOMPENZACIJA POREMEĆAJA : - Model procesa mora biti NOE strukture  
- ali je regulator nanešen offline  
-  $C = M-1$   
-  $C = P-1 \text{ i } P = M$  (princip pretežkih)

$$G = Y = \frac{CP}{1 + (P-M)C} \cdot \frac{1 - CM}{1 + (P-M)C} \alpha$$

8) KOD LPR. S UNIvARijNIM MODELOM, ukoj se STRUKTURa MODELA, NARX ili NOE, POSTIŽE BOJA KOMPENZACIJA POREMEĆAJA I ZASNO?

Kod NOE, uobičajeno je regulator nanešen offline, zato što je prema svojstvu IMC u "preplodno" delu regulator što bolje opisuje inverzni model modela procesa kako bi se postigla kompenzacija poremećaja bez statičke greške.

NOE  $\rightarrow$  zato što NOE predstavlja prediktor sa brojem koraka. Svi učivo poč. identific. modela se vrši učivo učivo prema njegovim ne-linearnosti koja mora tu poč. popravljati. Zato je boja NOE kada bi to moglo

$$y_{ref}(t+1) = y_{ref}(t+1)$$

buš. učivo,

$$y(t) \rightarrow \hat{y} \text{ (inverzni model)}$$