

Pravilo razvrstavanja - Ako je $d_i(\vec{x}) > d_j(\vec{x})$ te $j \neq i$ tada uzorak \vec{x} pripada razredu w_i

$$d(\vec{x}) = w_1 x_1 + w_2 x_2 + \dots + w_n x_n + w_{n+1} = \vec{w}^T \vec{x} + w_{n+1}$$


\downarrow težinski koeficijenti \downarrow formirajuće

DVA RAZREDA

- ako $d(\vec{x}) > 0$ onda $\vec{x} \in w_1$
- $d(\vec{x}) < 0$ $\vec{x} \in w_2$
- $d(\vec{x}) = 0$ nedefinirano

$$d(\vec{x}) = \vec{w}_0^T \vec{x} + w_{n+1} = 0$$

Jednadžba hiperravnine



$$\|\vec{w}_0\| = \sqrt{w_1^2 + w_2^2 + \dots + w_n^2}$$

$$\vec{w}_0^T \vec{x} + w_{n+1} = 0$$

$$\vec{w}_0^T (\vec{x} - \vec{p}) = 0$$

$$\vec{w}_0^T \vec{x} = -w_{n+1} / \|\vec{w}_0\|$$

$$\vec{w}_0^T \vec{x} - \vec{w}_0^T \vec{p} = 0$$

$$\frac{\vec{w}_0^T \vec{x}}{\|\vec{w}_0\|} = -\frac{w_{n+1}}{\|\vec{w}_0\|}$$

$$\vec{w}_0^T \vec{x} = \vec{w}_0^T \vec{p}$$

$$\vec{w}_0^T \vec{x} = \frac{\vec{w}_0^T \vec{x}}{\|\vec{w}_0\|}$$

$$\vec{w}_0^T \vec{p} = \frac{w_{n+1}}{\|\vec{w}_0\|}$$

$$= \frac{|w_{n+1}|}{\|\vec{w}_0\|} = D_0$$

$$\vec{w}_0^T = \frac{\vec{w}_0^T}{\|\vec{w}_0\|}$$

udaljenost
hiperravnine
od shodista

$$\vec{w}_0 = \frac{\vec{w}_0}{\|\vec{w}_0\|}$$


$$D_0 = |\vec{w}_0^T \vec{p} - \vec{w}_0^T \vec{x}|$$

projekcija
hiperravnine

↑
udaljenost točke
 \vec{x} od hiperravnine


Separabilnost vršć razreda

- ① Svaki je razred uzorka separabilan od ostalih razreda jednom decizijском ravinom



$$d_i(\vec{x}) = \vec{w}_i^\top \vec{x} = \begin{cases} > 0 & \text{ako } \vec{x} \in w_i \\ < 0 & \text{ako } \vec{x} \notin w_i \end{cases}$$

- ② Svaki razred uzorka je separabilan sa svakim pojedinačnim drugim razredom i to jednom decizijском ravinom



Granica između $w_i : w_j$ zadan je s

$$d_{ij}(\vec{x}) = w_{ij1}x_1 + w_{ij2}x_2 + \dots + w_{ijn}x_n + w_{ijn+1} = 0$$

$$d_{ij}(\vec{x}) > 0 \quad \text{za svaki } j \neq i$$

• \vec{x} pripada w_i

- ③ Postoji C decizijskih funkcija sa svojstvom da \vec{x} pripada razredu w_i ako

$$d_i(\vec{x}) > d_j(\vec{x}) \quad \text{za sve } j \neq i$$

Možemo definirati

$$d_{ij}(\vec{x}) = d_i(\vec{x}) - d_j(\vec{x}) = (\vec{w}_i - \vec{w}_j)^\top \vec{x} = \vec{w}_{ij}^\top \vec{x}$$

ako je $d_i(\vec{x}) > d_j(\vec{x})$ za sve $j \neq i$ onda je $d_{ij}(\vec{x}) > 0$ za sve $j \neq i$ tj.

ako su razredi separabilni za ③ onda su automatski separabilni i za ②

$$d_{ij}(\vec{x}) = d_i(\vec{x}) - d_j(\vec{x}) = (w_{i1} - w_{j1})x_1 + (w_{i2} - w_{j2})x_2 + \dots + (w_{in} - w_{jn})x_n + (w_{in+1} - w_{jn+1}) = 0$$

$$\Rightarrow (\vec{w}_i - \vec{w}_j)^\top \vec{x} + (w_{in+1} - w_{jn+1}) = 0$$

Nazdrojni vektor

↳ Vektor \vec{w} koji zadnjava sustav linearnih nejednačbi

$$[\vec{x}] \cdot \vec{w} > 3$$

gdje je

$$\begin{matrix} \vec{x}_{11}, \vec{x}_{12}, \dots \\ \vec{x}_{21}, \vec{x}_{22}, \dots \end{matrix} \in W_1 \quad \begin{matrix} \vec{x}_{12} \\ \vec{x}_{22} \\ \vdots \end{matrix} \in W_2$$

→ dimenzionalnost vektora
povećava se za jedan
(dodaje se i na kraj)

$$\vec{x} = \begin{bmatrix} \vec{x}_{11} \\ \vec{x}_{12} \\ \vec{x}_{21} \\ \vec{x}_{22} \\ \vdots \end{bmatrix}$$

uzorci iz W_2
pomnoženi su
sa -1

(Uzorak je pravina razvrstani tako da sve \vec{x} iz $W_1 \cup W_2$ vrijedu

$$\vec{w}^T \vec{x} > 0$$

gdje su uzori iz W_2 pomnoženi s -1

Tražimo funkciju koja dostiže minimum kada je ispunjen uslov

$$\vec{w}^T \vec{x} > 0$$

Gradientni postupak

Korak po korak povećavamo argument \vec{w} u smjeru negativnog gradijenta funkcije $J(\vec{w}, \vec{x})$ dok ne postignemo njen minimum

$$\vec{w}(k+1) = \vec{w}(k) - c \left\{ \frac{\partial J(\vec{w}, \vec{x})}{\partial \vec{w}} \right\}_{\vec{w} = \vec{w}(k)}$$

a)

Uzimamo funkciju:

$$J(\vec{w}, \vec{x}) = \frac{1}{2} (\|\vec{w}^T \vec{x}\| - 3)^2$$

$$(|x|)' = \text{sgn}(x)$$

$$\frac{\partial J}{\partial \vec{w}} = \frac{1}{2} [\vec{x} \text{ sgn}(\vec{w}^T \vec{x}) - \vec{x}]$$

$$\text{sgn}(x) = \begin{cases} 1 & \text{ako } x > 0 \\ -1 & \text{ako } x \leq 0 \end{cases}$$

$$\vec{w}(k+1) = \vec{w}(k) + c \cdot \frac{\partial J}{\partial \vec{w}} = \vec{w}(k) + \frac{c}{2} [\vec{x}(k) - \vec{x}(k) \text{ sgn}(\vec{w}^T(k) \vec{x}(k))]$$

$$\vec{w}(k+1) = \vec{w}(k) + \frac{c}{2} \cdot \begin{cases} 0 & \text{ako } \vec{w}^T(k) \vec{x}(k) > 0 \\ 2\vec{x}(k) & \text{ako } \vec{w}^T(k) \vec{x}(k) \leq 0 \end{cases}$$

$$\vec{w}(k+1) = \vec{w}(k) + c \cdot \begin{cases} 0 & \text{ako } \vec{w}^T(k) \cdot \vec{x}(k) > 0 \\ \vec{x}(k) & \text{ako } \vec{w}^T(k) \cdot \vec{x}(k) \leq 0 \end{cases}$$

b)

Uzimamo funkciju:

$$J(\vec{w}, \vec{x}) = \frac{1}{4\vec{x}^T \vec{x}} (|\vec{w}^T \vec{x}|^2 - |\vec{w}^T \vec{x}| \cdot |\vec{w}^T \vec{x}|)$$

$$\frac{\partial J}{\partial \vec{w}} = \frac{1}{4\vec{x}^T \vec{x}} \left[2 \cdot |\vec{w}^T \vec{x}| \cdot \text{sgn}(\vec{w}^T \vec{x}) \cdot \vec{x} - \text{sgn}(\vec{w}^T \vec{x}) \cdot \vec{x} \cdot \vec{w}^T \vec{x} - |\vec{w}^T \vec{x}| \cdot \vec{x} \right]$$

$$= \frac{1}{4\vec{x}^T \vec{x}} \left[2 |\vec{w}^T \vec{x}| \cdot \vec{x} \text{sgn}(\vec{w}^T \vec{x}) - |\vec{w}^T \vec{x}| \cdot \vec{x} - |\vec{w}^T \vec{x}| \cdot \vec{x} \right]$$

$$= \frac{1}{4\vec{x}^T \vec{x}} \left[2 |\vec{w}^T \vec{x}| \cdot \vec{x} \text{sgn}(\vec{w}^T \vec{x}) - 2 |\vec{w}^T \vec{x}| \cdot \vec{x} \right]$$

$$= \frac{1}{4\vec{x}^T \vec{x}} \left[|\vec{w}^T \vec{x}| \cdot \vec{x} (\text{sgn}(\vec{w}^T \vec{x}) - 1) \right]$$

$$= \frac{|\vec{w}^T \vec{x}|}{2\vec{x}^T \vec{x}} \left[\vec{x} (\text{sgn}(\vec{w}^T \vec{x}) - 1) \right] = \frac{|\vec{w}^T \vec{x}|}{2\vec{x}^T \vec{x}} \cdot \begin{cases} 0 \text{ ako } \vec{w}^T \vec{x} > 0 \\ -2\vec{x} \text{ ako } \vec{w}^T \vec{x} \leq 0 \end{cases}$$

$$\vec{w}(k+1) = \vec{w}(k) - \lambda \frac{\partial J}{\partial \vec{w}} = \vec{w}(k) - \lambda \cdot \frac{|\vec{w}^T \vec{x}|}{2\vec{x}^T \vec{x}} \cdot \begin{cases} 0 \text{ ako } \vec{w}^T \vec{x} > 0 \\ -2\vec{x} \text{ ako } \vec{w}^T \vec{x} \leq 0 \end{cases} =$$

$$\vec{w}(k+1) = \vec{w}(k) + \lambda \frac{|\vec{w}^T(k) \cdot \vec{x}(k)|}{\vec{x}^T(k) \cdot \vec{x}(k)} \cdot \begin{cases} \vec{x} & \text{ako } \vec{w}^T(k) \cdot \vec{x}(k) > 0 \\ \vec{x}(k) & \text{ako } \vec{w}^T(k) \cdot \vec{x}(k) \leq 0 \end{cases}$$

• za $0 < \lambda < 2 \Rightarrow$ postupak učenja konvergira• za $\lambda > 1 \Rightarrow$ uzorak se pravilno razvretava i nakan svake korekcije \vec{w}

Varijacije algoritma perceptron

a) $C = \text{konst.} > 0 \rightarrow$ ALGORITAM SA STALJIM PRIRASOMb) C izabran tako da je dovoljno velik da imati da će uzorak biti ispravno klasificiran nakon ugatjanja težinskog faktora \vec{w} - ako je $\vec{w}^T(k) \cdot \vec{x}(k) \leq 0$ izabire se C tako da vrijedi

ALGORITAM

s

APSOLUTNOM
KOREKCIJOM

$$\vec{w}^T(k+1) \vec{x}(k) = [\vec{w}(k) + C \vec{x}(k)]^T \vec{x}(k) > 0$$

$$\vec{w}^T(k) \vec{x}(k) + C \vec{x}^T(k) \vec{x}(k) > 0$$

$$C > \frac{|\vec{w}^T(k) \vec{x}(k)|}{\vec{x}^T(k) \vec{x}(k)}$$

C je najmanji cijeli broj veći od

c) C je izabran tako da vrijedi

$$|\vec{w}^T(k)\vec{x}(k) - \vec{w}^T(k+1)\vec{x}(k)| = \eta |\vec{w}^T(k)\vec{x}(k)| \quad (1)$$

izraz $\vec{w}(k+1) = \vec{w}(k) + c\vec{x}(k)$ tj. $\vec{w}^T(k+1) = \vec{w}^T(k) + c\vec{x}^T(k)$ uvrstimo u (1)

ALGORITAM

3

DJELONIČNOM
KOREKCIJOM

$$|\vec{w}^T(k)\vec{x}(k) - \vec{w}^T(k)\vec{x}(k) - c\vec{x}^T(k)\vec{x}(k)| = \eta |\vec{w}^T(k)\vec{x}(k)|$$

$$|c\vec{x}^T(k)\vec{x}(k)| = \eta |\vec{w}^T(k)\vec{x}(k)|$$

$$c \cdot |\vec{x}^T(k)\vec{x}(k)| = \eta |\vec{w}^T(k)\vec{x}(k)|$$

kvadrirajući je pozitivan

$$c = \eta \frac{|\vec{w}^T(k)\vec{x}(k)|}{\vec{x}^T(k)\vec{x}(k)}$$

PERCEPTRON - klasifikator uzorka u dva razreda - ako su razredi linearno separabilni

Perceptron za M > 2

M = broj razreda

PRAVILA - uzorak se svrstava u razred w_i ako

$$R_i > R_j \text{ za sve } i \neq j$$

$$\text{gdje je } R = \vec{w}^T \cdot \vec{x}$$

Algoritam perceptrona

1) Ako $\vec{x}(k) \in w_1$ i $\vec{w}^T(k)\vec{x}(k) \leq 0$

zamjeni $\vec{w}(k)$ sa $\vec{w}(k+1) = \vec{w}(k) + c\vec{x}(k)$.

2) Ako $\vec{x}(k) \in w_2$ i $\vec{w}^T(k)\vec{x}(k) > 0$

zamjeni $\vec{w}(k)$ sa $\vec{w}(k+1) = \vec{w}(k) - c\vec{x}(k)$

3) Inace $\vec{w}(k+1) = \vec{w}(k)$

C → korekcijski faktor, mora biti pozitivan

$\vec{w}(1) \rightarrow$ početna vrijednost vektora težinskih koeficijenata - proizvorno izabrana

RJEŠENJE - dobiva se kada se pojavi iteracija bez pogresaka
tj. iteracija u kojoj za sve uzorke vrijedi "3")

Ho-Kashyap algoritam (LMSE - Last Mean Square Error)

- Traži se vektor \vec{w} tako da vrijedi

$$[\mathbf{x}] \vec{w} = \vec{b}$$

\vec{b} - vektor kojemu su sve komponente pozitivne

Kriterijska funkcija:

$$J(\vec{w}, \vec{x}, \vec{b}) = \frac{1}{2} \sum_{j=1}^N (\vec{w}^T \vec{x}_j - b_j)^2 = \frac{1}{2} \| [\mathbf{x}] \vec{w} - \vec{b} \|^2$$

veličina vektora $[\mathbf{x}] \vec{w} - \vec{b}$

Gradient:

$$\frac{\partial J}{\partial \vec{w}} = \frac{1}{2} \cdot [\mathbf{x}]^T \cdot 2([\mathbf{x}] \vec{w} - \vec{b}) = [\mathbf{x}]^T ([\mathbf{x}] \vec{w} - \vec{b})$$

$$\frac{\partial J}{\partial \vec{b}} = \frac{1}{2} \cdot (-1) \cdot 2([\mathbf{x}] \vec{w} - \vec{b}) = -([\mathbf{x}] \vec{w} - \vec{b})$$

- Pošto se umjestio uvjet $[\mathbf{x}] \vec{w} > \vec{b}$ koristi $[\mathbf{x}] \vec{w} = \vec{b}$ to znači da \vec{w} nije ograničen: možemo uvesti $\frac{\partial J}{\partial \vec{w}} = \vec{0}$

$$\frac{\partial J}{\partial \vec{w}} = \vec{0}$$

$$[\mathbf{x}]^T ([\mathbf{x}] \vec{w} - \vec{b}) = \vec{0}$$

$$[\mathbf{x}]^T [\mathbf{x}] \vec{w} - [\mathbf{x}]^T \vec{b} = \vec{0}$$

$$[\mathbf{x}]^T [\mathbf{x}] \vec{w} = [\mathbf{x}]^T \vec{b} / \cdot ([\mathbf{x}]^T [\mathbf{x}])^{-1}$$

$$\vec{w} = ([\mathbf{x}]^T [\mathbf{x}])^{-1} [\mathbf{x}]^T \vec{b}$$

$$[\mathbf{x}]^{\#} = ([\mathbf{x}]^T [\mathbf{x}])^{-1} [\mathbf{x}]^T \rightarrow \text{generalizirani inverz od } [\mathbf{x}]$$

$$\vec{w} = [\mathbf{x}]^{\#} \vec{b} \quad (1)$$

- Vektor \vec{b} se mijenja tako da uvjet vrijedi $b_i > 0$ za $i = 0, 1, 2, \dots, N$

$$\vec{b}(k+1) = \vec{b}(k) + \delta \vec{b}(k) \quad (2)$$

$$\delta b_i(k) = \begin{cases} 2c([\mathbf{x}] \vec{w}(k) - b(k))_i & \text{ako } ([\mathbf{x}] \vec{w}(k) - b(k))_i > 0 \\ 0 & \text{ako } ([\mathbf{x}] \vec{w}(k) - b(k))_i \leq 0 \end{cases}$$

$$\vec{e}(k) = [\mathbf{x}] \vec{w}(k) - \vec{b}(k) \Rightarrow \delta \vec{b}(k) = c (\vec{e}(k) + |\vec{e}(k)|)$$

(2) se uvrštava u (1)

$$\begin{aligned}\vec{w}(k+1) &= [x]^{\#} \vec{b}(k+1) \\ &= [x]^{\#} (\vec{b}(k) + c \vec{e}(k)) \\ &= \underbrace{[x]^{\#} \vec{b}(k)}_{\vec{w}(k)} + [x]^{\#} c \vec{e}(k) \\ &= \vec{w}(k) + [x]^{\#} c (\vec{e}(k) + c \vec{e}(k))\end{aligned}$$

$$\vec{w}(k+1) = \vec{w}(k) + c [x]^{\#} (\vec{e}(k) + c \vec{e}(k))$$

$$\vec{b}(k+1) = \vec{b}(k) + c (\vec{e}(k) + c \vec{e}(k))$$

Pravilo - ako su u bilo kojoj iteraciji sve komponente vektora

$\vec{e}(k) < 0$ razredi nisu linearne separabilni

- kada je $\vec{e}(k) = \vec{0}$ znači da vrijedi $[x] \vec{w}(k) = b(k)$
pa je $\vec{w}(k)$ RJEŠENJE

Poopćeni algoritam perceptrona za M razreda

- istodobno se određuje M težinskih koeficijenata $\vec{w}_1, \vec{w}_2, \dots, \vec{w}_M$
 - računa se M dečijskih funkcija
- $$d_j(\vec{x}(k)) = \vec{w}_j^T(k) \vec{x}(k) \quad \text{za } j=1, 2, \dots, M$$

Pravilo: Ako

$$d_i(\vec{x}(k)) > d_j(\vec{x}(k)) \quad \text{za } i=1, 2, \dots, M$$

ONDA $\vec{w}_j(k+1) = \vec{w}_i(k) \quad \text{za } j=1, 2, \dots, M$

Ako

$$d_i(\vec{x}(k)) \leq d_e(\vec{x}(k))$$

ONDA

$$\vec{w}_l(k+1) = \vec{w}_l(k) + c \vec{x}(k)$$

$$\vec{w}_e(k+1) = \vec{w}_e(k) - c \vec{x}(k)$$

$$\vec{w}_j(k+1) = \vec{w}_j(k) \quad \text{za } j=1, 2, \dots, M, j \neq l$$

- Postupak konvergira u konacnom broju ponavljanja ako

su razredi linearne separabilni

FISHEROVA LINEARNA DISKRIMINANTA

- d-dimenzionalan vektor značajki \vec{x} reducira se na jednu dimenziju

$$\mathbb{R}^d \rightarrow \mathbb{R}^1$$

- ZADATAK - naći orijentaciju pravca na koji se projiciraju d-dimenzionalni uzorci da su projicirani uzorci separabilni

\rightarrow broj uzoraka razreda w_1

$n = \text{broj uzoraka} = n_1 + n_2 \rightarrow$ broj uzoraka razreda w_2


$\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n$ - d-dimenzionalni uzorci

$$y_i = \vec{w}^T \vec{x}_i \quad i=1,2,\dots,n$$

\hookrightarrow linearna kombinacija komponenti \vec{x}

$$\begin{matrix} \mathbb{D}_1, \mathbb{D}_2 \\ \downarrow \\ \text{d-dimenzionalno} \end{matrix} \longrightarrow \begin{matrix} y_1, y_2 \\ \downarrow \\ \text{jednodimenzionalno} \end{matrix}$$

ako $\|\vec{w}\| = 1 \rightarrow$ svaki y_i je projekcija odgovarajućeg \vec{x}_i na pravac u smjeru \vec{w}




Cilj - nari najbolji smjer od \vec{w}

MJERA ODVODIVOSTI između projiciranih uzoraka je razlika srednjih vrijednosti projiciranih uzoraka

$$\vec{m}_i = \frac{1}{n_i} \sum_{x \in D_i} \vec{x} ; i=1,2 \rightarrow \text{srednja vrijednost uzorka u svakog razreda u } d\text{-dimenzionalnom prostoru}$$

$$\tilde{m}_i = \frac{1}{n_i} \sum_{y \in Y_i} \vec{y} ; i=1,2 \rightarrow \text{srednja vrijednost projiciranih uzoraka}$$



$$\vec{m}_i = \frac{1}{n_i} \sum_{y \in Y_i} \vec{y} = \frac{1}{n_i} \sum_{x \in D_i} \vec{w}^\top \vec{x} = \vec{w}^\top \left[\frac{1}{n_i} \sum_{x \in D_i} \vec{x} \right] = \vec{w}^\top \vec{m}_i$$

\tilde{m}_i je projekcija vektora \vec{m}_i

Razlika srednjih vrijednosti projiciranih uzoraka

$$|\tilde{m}_1 - \tilde{m}_2| = |\vec{w}^\top \vec{m}_1 - \vec{w}^\top \vec{m}_2| = |\vec{w}^\top (\vec{m}_1 - \vec{m}_2)|$$

skaliranjem \vec{w} razliku činimo proizvoljno velikom

Kriterijska funkcija:

$$J(\vec{w}) = \frac{(\tilde{m}_1 - \tilde{m}_2)^2}{\sigma_1^2 + \sigma_2^2} \rightarrow \text{razlika sr. vrijednosti}$$

\rightarrow varijanca uzoraka unutar razreda

- za dobro odvojavaće projiciranih uzoraka udaljenost između srednjih vrijednosti projiciranih uzoraka mora biti relativno velika u odnosu na standardnu devijaciju svakog razreda

Linearna funkcija $\vec{w}^\top \vec{x}$ za koju je kriterijska funkcija $J(\vec{w})$

MAKSIMALNA radi najboljem razdvajajuću između projiciranih skupova

- Umjesto varijance s_i^2 raspršenost unutar razreda definisamo kao

$$\tilde{s}_i^2 = \sum_{y \in Y_i} (y - \tilde{m}_i)^2$$

$$\frac{1}{n} (\tilde{s}_1^2 + \tilde{s}_2^2) \rightarrow \text{procjena varijance podataka}$$

mjeri raspršenosti
projekcionih podataka
unutar razreda

$$J(\vec{w}) = \frac{(\tilde{m}_1 - \tilde{m}_2)^2}{\sigma_1^2 + \sigma_2^2} = \frac{(\tilde{m}_1 - \tilde{m}_2)^2}{\tilde{s}_1^2 + \tilde{s}_2^2}$$

Raspršenost unutar razreda w_i :

$$S_i = \sum_{x \in D_i} (x - \tilde{m}_i)(x - \tilde{m}_i)^T \rightarrow \text{matrica raspršenosti unutar razreda } w_i$$

matrica

$$S_w = S_1 + S_2 \rightarrow \text{matrica raspršenosti unutar razreda}$$

$$\begin{aligned} \tilde{s}_i^2 &= \sum_{y \in Y_i} (y - \tilde{m}_i)^2 = \left\{ \begin{array}{l} y = \vec{w}^T \vec{x} \\ \tilde{m}_i = \vec{w}^T \vec{m}_i \end{array} \right\} \\ &= \sum_{x \in D_i} (\vec{w}^T \vec{x} - \vec{w}^T \vec{m}_i)^2 \\ &= \sum_{x \in D_i} (\vec{w}^T \vec{x} - \vec{w}^T \vec{m}_i)(\vec{w}^T \vec{x} - \vec{w}^T \vec{m}_i)^T \\ &= \sum_{x \in D_i} \vec{w}^T (\vec{x} - \vec{m}_i)(\vec{x} - \vec{m}_i)^T \vec{w} \\ &= \vec{w}^T \cdot \left[\sum_{x \in D_i} (\vec{x} - \vec{m}_i)(\vec{x} - \vec{m}_i)^T \right] \cdot \vec{w} \\ &= \vec{w}^T S_i \vec{w} \end{aligned}$$

$$\tilde{s}_i^2 = \vec{w}^T S_i \vec{w}$$

$$\tilde{s}_1^2 + \tilde{s}_2^2 = \vec{w}^T S_1 \vec{w} + \vec{w}^T S_2 \vec{w} = \vec{w}^T (S_1 + S_2) \vec{w} = \vec{w}^T S_w \vec{w}$$

$$\tilde{s}_1^2 + \tilde{s}_2^2 = \vec{w}^T S_w \vec{w}$$

$$\begin{aligned}
 (\vec{m}_1 - \vec{m}_2)^T &= (\vec{w}^T \vec{m}_1 - \vec{w}^T \vec{m}_2)^T \\
 &= (\vec{w}^T \vec{m}_1 - \vec{w}^T \vec{m}_2)(\vec{w}^T \vec{m}_1 - \vec{w}^T \vec{m}_2)^T \\
 &= (\vec{w}^T \vec{m}_1 - \vec{w}^T \vec{m}_2)(\vec{m}_1^T \vec{w} - \vec{m}_2^T \vec{w}) \\
 &= \vec{w}^T (\vec{m}_1 - \vec{m}_2) \underbrace{(\vec{m}_1 - \vec{m}_2)^T}_{S_B} \vec{w} \\
 &= \vec{w}^T S_B \vec{w}
 \end{aligned}$$

$$S_B = (\vec{m}_1 - \vec{m}_2)(\vec{m}_1 - \vec{m}_2)^T$$

$$(\vec{m}_1 - \vec{m}_2)^2 = \vec{w}^T S_B \vec{w}$$

$$J(\vec{w}) = \frac{\vec{w}^T S_B \vec{w}}{\vec{w}^T S_w \vec{w}}$$

$$\left(\frac{a}{b}\right)^T = \frac{ba^T - ab^T}{b^2}$$

Traži se maksimum funkcije $J(\vec{w})$

$$\frac{\partial J}{\partial \vec{w}} = 0$$

$$\begin{aligned}
 \frac{\partial J(\vec{w})}{\partial \vec{w}} &= \frac{(\vec{w}^T S_w \vec{w})(\vec{w}^T S_B \vec{w})' - (\vec{w}^T S_B \vec{w})(\vec{w}^T S_w \vec{w})'}{(\vec{w}^T S_w \vec{w})^2} \\
 &= \frac{(\vec{w}^T S_w \vec{w}) \cdot 2 S_B \vec{w} - (\vec{w}^T S_B \vec{w}) \cdot 2 S_w \vec{w}}{(\vec{w}^T S_w \vec{w})(\vec{w}^T S_w \vec{w})^T} = 0
 \end{aligned}$$

$$(\vec{w}^T S_w \vec{w}) \cdot 2 S_B \vec{w} - (\vec{w}^T S_B \vec{w}) \cdot 2 S_w \vec{w} = 0 \quad | : 2$$

$$(\vec{w}^T S_w \vec{w}) \cdot S_B \vec{w} = (\vec{w}^T S_B \vec{w}) \cdot S_w \vec{w} \quad | \cdot (\vec{w}^T S_w \vec{w})^{-1}$$

$$S_B \vec{w} = \underbrace{(\vec{w}^T S_B \vec{w})}_{\text{skalar}} \underbrace{(\vec{w}^T S_w \vec{w})^{-1} S_w \vec{w}}_{\text{skalar}}$$

$$\lambda = (\vec{w}^T S_B \vec{w}) (\vec{w}^T S_w \vec{w})^{-1}$$

$$S_B \vec{w} = \lambda S_w \vec{w} \rightarrow \text{generalizirani problem s ugovorenim smjerom vektora}$$

Ako S_w^{-1} postoji, onda je smjer \vec{w} -a

$$\hat{\vec{w}} = (S_w^{-1} S_B) \vec{w}$$

Pošto je $S_B \cdot \vec{w}$ uvijek uzmjeran kao $(\vec{m}_1 - \vec{m}_2)$, a faktor skaliranja za \vec{w} ne zanima nego samo smjer, onda pišemo

$$\hat{\vec{w}} = S_w^{-1} (\vec{m}_1 - \vec{m}_2) \rightarrow \vec{w} \text{ maksimizira smjer rasprejeda izmedu razreda i raspredaja unutar razreda}$$

Višestruka FLD → generalizirana FLD

C - broj razreda

Postoji $(c-1)$ diskriminantnih funkcija

Cilj: Projekcija d-dimenzionalnog prostora u $(c-1)$ -dimenzionalni
 $d \gg c$

$$S_W = \sum_{i=1}^c S_i \quad \rightarrow \text{generalizirana matrica raspršenosti unutar razreda}$$

$$S_i = \sum_{\vec{x} \in D_i} (\vec{x} - \vec{m}_i)(\vec{x} - \vec{m}_i)^T$$

$$\vec{m}_i = \frac{1}{n_i} \sum_{\vec{x} \in D_i} \vec{x} \quad | \cdot n_i$$

$$n_i \vec{m}_i = \sum_{\vec{x} \in D_i} \vec{x}$$

$$\vec{m} = \frac{1}{n} \sum_{\vec{x}} \vec{x} = \frac{1}{n} \sum_{i=1}^c \sum_{\vec{x} \in D_i} \vec{x} = \frac{1}{n} \sum_{i=1}^c n_i \vec{m}_i$$

$$\vec{m} = \frac{1}{n} \sum_{i=1}^c n_i \vec{m}_i$$

$$\begin{aligned} S_T &= \sum_{\vec{x}} (\vec{x} - \vec{m})(\vec{x} - \vec{m})^T \\ &= \sum_{i=1}^c \sum_{\vec{x} \in D_i} (\vec{x} - \vec{m}_i + \vec{m}_i - \vec{m})(\vec{x} - \vec{m}_i + \vec{m}_i - \vec{m})^T \\ &= \sum_{i=1}^c \sum_{\vec{x} \in D_i} [(\vec{x} - \vec{m}_i) + (\vec{m}_i - \vec{m})] [(\vec{x} - \vec{m}_i)^T + (\vec{m}_i - \vec{m})^T] \\ &= \sum_{i=1}^c \sum_{\vec{x} \in D_i} [(\vec{x} - \vec{m}_i)(\vec{x} - \vec{m}_i)^T + (\vec{x} - \vec{m}_i)(\vec{m}_i - \vec{m})^T + (\vec{m}_i - \vec{m})(\vec{x} - \vec{m}_i)^T + (\vec{m}_i - \vec{m})(\vec{m}_i - \vec{m})^T] \\ &= \underbrace{\sum_{i=1}^c \sum_{\vec{x} \in D_i} (\vec{x} - \vec{m}_i)(\vec{x} - \vec{m}_i)^T}_{S_W} + \sum_{i=1}^c \sum_{\vec{x} \in D_i} (\vec{m}_i - \vec{m})(\vec{m}_i - \vec{m})^T \\ &= S_W + \sum_{i=1}^c n_i (\vec{m}_i - \vec{m})(\vec{m}_i - \vec{m})^T \sum_{\vec{x} \in D_i} 1 \end{aligned}$$

$$S_T = S_W + \sum_{i=1}^c n_i (\vec{m}_i - \vec{m})(\vec{m}_i - \vec{m})^T$$

Drugi clan je

$$S_B = \sum_{i=1}^c n_i (\vec{m}_i - \vec{m})(\vec{m}_i - \vec{m})^T \quad \rightarrow \text{generalizirana matrica raspredjeljenosti između razreda}$$

$$S_T = S_W + S_B$$

Projekcija iz d-dimenz. prostora u (c-1)-dimenz. uz (c-1) diskriminacionih funkcija:

$$y_i = \vec{w}_i^T \vec{x} \quad ; \quad i=1, 2, \dots, c-1$$

$\vec{y} \rightarrow$ vektor čije su komponente y_i

$W \rightarrow$ matrica dimenzija $d \times (c-1)$
 \rightarrow stupci su još vektori \vec{w}_i

$$\vec{y} = W^T \vec{x}$$

Uzorci $\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n$ projiciraju se u $\vec{y}_1, \vec{y}_2, \dots, \vec{y}_n$ čiji vektori srednjih vrijednosti i matricom raspredjeljenosti iznose:

$$\tilde{m}_i = \frac{1}{n_i} \sum_{y \in y_i} \vec{y} \quad \Rightarrow n_i \tilde{m}_i = \sum_{y \in y_i} \vec{y}$$

$$\tilde{m} = \frac{1}{n} \sum_{i=1}^c n_i \tilde{m}_i$$

$$\tilde{m} = \frac{1}{n} \sum_{y \in y_i} \vec{y} = \frac{1}{n} \sum_{i=1}^c \sum_{y \in y_i} \vec{y} = \frac{1}{n} \sum_{i=1}^c n_i \tilde{m}_i$$

$$\begin{aligned} \tilde{S}_W &= \sum_{i=1}^c \sum_{y \in y_i} (\vec{y} - \tilde{m}_i)(\vec{y} - \tilde{m}_i)^T \\ &= \sum_{i=1}^c \sum_{x \in x_i} (W^T \vec{x} - W^T \tilde{m}_i)(W^T \vec{x} - W^T \tilde{m}_i)^T \\ &= \sum_{i=1}^c \sum_{x \in x_i} W^T (\vec{x} - \tilde{m}_i)(\vec{x} - \tilde{m}_i)^T W \\ &= W^T S_W W \end{aligned}$$

$$\tilde{S}_W = W^T S_W W$$

$$\begin{aligned}
 S_B &= \sum_{i=1}^c \sum_{j \neq i} (\tilde{m}_i - \tilde{m})(\tilde{m}_i - \tilde{m})^T \\
 &= \sum_{i=1}^c (\tilde{m}_i - \tilde{m})(\tilde{m}_i - \tilde{m})^T \sum_{j \neq i} 1 \\
 &= \sum_{i=1}^c n_i (\tilde{m}_i - \tilde{m})(\tilde{m}_i - \tilde{m})^T \\
 &= \sum_{i=1}^c n_i (W^T \tilde{m}_i - W^T \tilde{m})(W^T \tilde{m}_i - W^T \tilde{m})^T \\
 &= \sum_{i=1}^c n_i \cdot W^T (\tilde{m}_i - \tilde{m})(\tilde{m}_i - \tilde{m})^T \cdot W \\
 &= \sum_{i=1}^c W^T \cdot n_i (\tilde{m}_i - \tilde{m})(\tilde{m}_i - \tilde{m})^T \cdot W \\
 &= W^T S_B W
 \end{aligned}$$

$$\tilde{S}_B = W^T S_B W$$

Cilj: Naći matricu W koja maksimizira omjer $\frac{\tilde{S}_B}{S_W}$

- jednostavna skalarna mjeru raspršenosti je DETERMINANTA

$$J(W) = \frac{|\tilde{S}_B|}{|S_W|} = \frac{|W^T S_B W|}{|W^T S_W W|}$$

Stupci optimalne matrice W su generalizirani svojstveni vektori koji odgovaraju najvećim svojstvenim vrijednostima u

$$S_B \vec{w}_i = \lambda_i S_W \vec{w}_i$$

Traže se svojstvene vrijednosti kao konjeni karakterističnog polinoma

$$|S_B - \lambda_i S_W| = 0$$

Zatim se traže svojstveni vektori rješavanjem

$$(S_B - \lambda_i S_W) \vec{w}_i = \vec{0}$$

$$W^T S_B W = \lambda_i W^T S_W W$$

METODE ISPITIVANJA

1) Holdout metoda

Skup uzoraka s poznatom klasifikacijom dijeli se na:

- Skup uzoraka za učenje = S_u
- Skup uzoraka za ispitivanje = S_i

NEDOSTACI - smanjene skupove za učenje, ispitivanje
- kako pravilno razdijeliti skupove?

2) Leave - One - Out metoda

- Učenje se obavlja na $N-1$ uzorku a ispitivanje na onom preostalom
- Ovisno je li preostali uzorak točno ili netočno klasificiran povećava se brojlo točnost ili pogreške
- Postupak se ponavlja N puta tako da je struki put za ispitivanje koristi drugi uzorak

NEDOSTATAK - velika računska složenost

3) Resubstitution metoda (metoda ponarne zanjece)

- isti skup se koristi prvo za učenje pa za ispitivanje
- OPTIMISTICKA prognoza vjerojatnosti klasifikatora

SVM - SUPPORT VECTOR MACHINES

(strojevi s potpornim vektorima)

Cilj: Konstrukcija decizijske hiperplane ali tako da
margina odvajanja između pozitivne i negativne skupine
uzoraka bude **MAKSIMALNA**

Skup uzoraka za učenje: $\{(\vec{x}_i, d_i)\}_{i=1}^N$ → broj primjera

$$\{(\vec{x}_i, d_i)\}_{i=1}^N$$

↓ ↓
 ulazni vektor želeni odgovor
 uzorka za i -ti primer klasifikatora


za: $w_1 \rightarrow d_i = +1$
 $w_2 \rightarrow d_i = -1$

Jednadžba decizijske ravnine:

$$\vec{w}^\top \vec{x} + b = 0$$

↓ ↓
 vektorski koeficijent učinkovitih vektora pomerajuće (w₀)

za: $d_i = +1$ vrijedi $\vec{w}^\top \vec{x} + b > 0$
 $d_i = -1$ vrijedi $\vec{w}^\top \vec{x} + b < 0$



MARGINA ODVAJANJA \Rightarrow udaljenost između hiperplane i
najblže točke u n-dimenzionalnom prostoru


OPTIMALNA RAVNINA - hiperplanina za koju je margina
odvajanja maksimalna.

\vec{w}_o, b_o - optimalne vrijednosti \vec{w} i b

$$\vec{w}_o^\top \vec{x} + b_o = 0 \rightarrow \text{optimalna hiperpravina}$$

$$g(\vec{x}) = \vec{w}_o^\top \vec{x} + b_o \rightarrow \text{decijska funkcija}$$

- daje mjeru udaljenosti \vec{x} -a od optimalne hiperpravine



Par (\vec{w}_o, b_o) mora zadovoljiti (ako su uzorci lin. odvojivi)

$$\vec{w}_o^\top \vec{x}_i + b_o \geq 1 \quad \text{za } d_i = +1$$

$$\vec{w}_o^\top \vec{x}_i + b_o \leq -1 \quad \text{za } d_i = -1$$

POTPORNI VEKTORI - uzorci iz skupa za učenje za koje vrijedi

$$\vec{x}^{(s)}$$

$$\vec{w}_o^\top \vec{x} + b_o = 1 \quad \text{za } d_i = +1$$

$$\vec{w}_o^\top \vec{x} + b_o = -1 \quad \text{za } d_i = -1$$

$$g(\vec{x}^{(s)}) = \vec{w}_o^\top \vec{x}^{(s)} + b_o = \pm 1 \quad \text{za } d_i = \pm 1$$

$$r = \frac{g(\vec{x}^{(s)})}{\|\vec{w}_o\|} = \frac{\pm 1}{\|\vec{w}_o\|} = \begin{cases} 1/\|\vec{w}_o\| & \text{za } d^{(s)} = +1 \\ -1/\|\vec{w}_o\| & \text{za } d^{(s)} = -1 \end{cases}$$

Optimalna vrijednost marge r

$$r = 2f = \frac{2}{\|\vec{w}_o\|}$$

minimiziranjem norme od \vec{w}_o maksimizira se marga r

Cilj: Pronadri optimalne vrijednosti koeficijenata \vec{w} i pomaknutie b tako da je zadovoljeno ogranicenje

$$d_i \cdot (\vec{w}^\top \vec{x}_i + b) \geq 1 \quad ; \quad i = 1, 2, \dots, N$$

a da pri tomu vektor \vec{w} minimizira KRITERIJSKU FUNKCIJU

$$J(\vec{w}) = \frac{1}{2} \underbrace{\vec{w}^\top \vec{w}}_{\vec{w}^\top \vec{w} = \|\vec{w}\|^2}$$

Problem optimizacije rješava se Lagrangeovim množilikatorima:

Određivanje ekstremum funkcije $f(x,y)$ uz uvjet $g(x,y)=0$

$$F = f(x,y) + \lambda \cdot g(x,y)$$

↳ Lagrangeov množilikator

$$\frac{\partial F}{\partial x} = 0 \quad \frac{\partial F}{\partial y} = 0 \quad g(x,y) = 0$$

ovim sustavom jednadžbi
određuju se $x, y \in \mathbb{R}$

AKO

$$\begin{aligned} d^2 F < 0 &\rightarrow F(x,y) \text{ ima MAXIMUM} \\ d^2 F > 0 &\rightarrow F(x,y) \text{ ima MINIMUM} \end{aligned}$$

$$d^2 F = \frac{\partial^2 F}{\partial x^2} dx^2 + 2 \frac{\partial^2 F}{\partial x \partial y} dx dy + \frac{\partial^2 F}{\partial y^2} dy^2$$

ODREĐIVANJE OPTIMALNE HYPERRAVNINE

$$J(\vec{w}) = \frac{1}{2} \vec{w}^T \vec{w}$$

$$d_i \cdot (\vec{w}^T \vec{x}_i + b) \geq 1 \quad : i=1, 2, \dots, N$$

$$\hookrightarrow \varphi(\vec{w}, \alpha) = d_i (\vec{w}^T \vec{x}_i + b) - 1$$

$$J(\vec{w}, b, \alpha) = \frac{1}{2} \vec{w}^T \vec{w} - \sum_{i=1}^N \alpha_i [d_i (\vec{w}^T \vec{x}_i + b) - 1] \quad (*)$$

$$\frac{\partial J}{\partial \vec{w}} = \frac{\partial J}{\partial b}, \quad \varphi(\vec{w}, b) = 0$$

$$\begin{aligned} \frac{\partial J}{\partial \vec{w}} &= \vec{w} - \sum_{i=1}^N \alpha_i d_i \vec{x}_i \\ &= \vec{w} - \sum_{i=1}^N \alpha_i d_i \vec{x}_i + \sum_{i=1}^N \alpha_i d_i \vec{x}_i - \sum_{i=1}^N \alpha_i d_i \vec{x}_i \end{aligned}$$

$$1) \quad \frac{\partial J(\vec{w}, b, \alpha)}{\partial \vec{w}} = \frac{1}{2} \cdot 2\vec{w} - \sum_{i=1}^N \alpha_i d_i \vec{x}_i = \vec{w} - \sum_{i=1}^N \alpha_i d_i \vec{x}_i = 0$$

$$\boxed{\vec{w} = \sum_{i=1}^N \alpha_i d_i \vec{x}_i}$$

$$\frac{\partial J(\vec{w}, b, \alpha)}{\partial b} = - \sum_{i=1}^N \alpha_i d_i = 0$$

vrjednosti za koje $J(\vec{w})$ dobit će minimume

$$\boxed{\sum_{i=1}^N \alpha_i d_i = 0}$$

$$\pi_i [d_i (\vec{w}^T \vec{x}_i + b) - 1] = 0$$

$$\boxed{\pi_i [d_i (\vec{w}^T \vec{x}_i + b) - 1] = 0 \quad ; \quad i=1,2,\dots,N}$$

$$\boxed{\pi_i \geq 0}$$

$$J(\vec{w}, b, \pi) = \frac{1}{2} \vec{w}^T \vec{w} - \sum_{i=1}^N \pi_i d_i \vec{w}^T \vec{x}_i - \sum_{i=1}^N \pi_i d_i b + \sum_{i=1}^N \pi_i$$

$$= \frac{1}{2} \vec{w}^T \vec{w} - \sum_{i=1}^N \pi_i d_i \vec{w}^T \vec{x}_i - b \sum_{i=1}^N \pi_i d_i + \sum_{i=1}^N \pi_i$$

$\vec{w} = \sum_{j=1}^n \pi_j d_j \vec{x}_j = 0$

** se uvrstava

do b-
se dobiti
 $\min_{\vec{w}} J(\vec{w}, \pi)$

$$= \frac{1}{2} \vec{w}^T \vec{w} - \sum_{i=1}^N \sum_{j=1}^n \pi_i d_i \pi_j d_j \vec{x}_i^T \vec{x}_j + \sum_{i=1}^N \pi_i$$

$$= \frac{1}{2} \vec{w}^T \vec{w} - \sum_{i=1}^N \sum_{j=1}^n \pi_i \pi_j d_i d_j \vec{x}_i^T \vec{x}_j + \sum_{i=1}^N \pi_i$$

$$= \left\{ \vec{w}^T \cdot \vec{w} = \left[\sum_{i=1}^N \pi_i d_i \vec{x}_i^T \right] \cdot \left[\sum_{j=1}^n \pi_j d_j \vec{x}_j \right] = \sum_{i=1}^N \sum_{j=1}^n \pi_i \pi_j d_i d_j \vec{x}_i^T \vec{x}_j \right\}$$

$$= \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^n \pi_i \pi_j d_i d_j \vec{x}_i^T \vec{x}_j - \sum_{i=1}^N \sum_{j=1}^n \pi_i \pi_j d_i d_j \vec{x}_i^T \vec{x}_j + \sum_{i=1}^N \pi_i$$

$$= \sum_{i=1}^N \pi_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^n \pi_i \pi_j d_i d_j \vec{x}_i^T \vec{x}_j$$

$$\boxed{Q(\pi) = J(\vec{w}, b, \pi) = \sum_{i=1}^N \pi_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^n \pi_i \pi_j d_i d_j \vec{x}_i^T \vec{x}_j = \min_{\vec{w}} J(\vec{w}, \pi)}$$

Lagrangeov dualni problem

$$\min_{\vec{w}} J(\vec{w})$$

Optimizacijski zadatak - minimizacija $J(\vec{w})$ uz uvjet $f_L(\vec{w}) \geq 0$

Lagrangeova funkcija

$$J(\vec{w}, \pi) = J(\vec{w}) - \sum_{i=1}^N \pi_i f_L(\vec{w})$$

ima maksimum kada je

$$\begin{aligned} \pi_i &= 0 \quad ; \quad i=1,2,\dots,N \\ \text{ili} \quad f_L(\vec{w}) &= 0 \quad ; \quad i=1,2,\dots,N \end{aligned}$$

$$\text{tj. } \max_{\pi} (J(\vec{w}, \pi)) = J(\vec{w})$$

Ta se originalni problem može pribraziti kao

$$\min_{\vec{w}} J(\vec{w}) = \min_{\vec{w}} \max_{\pi} J(\vec{w}, \pi) = \max_{\pi} \min_{\vec{w}} J(\vec{w}, \pi)$$

Zadatak se svedi na $\max_{\pi} Q(\pi)$

SVM za $M > 2$ razreda

- Za svaki od razreda traži se optimalna dečijska funkcija $g_i(\vec{x})$ -

tako da vrijedi

$$g_i(\vec{x}) > g_j(\vec{x}) \quad \forall j \neq i$$

ako je $\vec{x} \in w_i$

ZADATAK - Naći dečijsku funkciju $g_i(\vec{x}) = 0$ koja je optimalna hiperplanina koja odvaja razred w_i od svih ostalih:

$$g_i(\vec{x}) > 0 \quad \text{za } \vec{x} \in w_i$$

$$g_i(\vec{x}) < 0 \quad \text{inac}$$

KLASIFIKACIJSKO PRAVLO

Dodijeli \vec{x} u w_i ako

$$i = \arg \max_k \{g_k(\vec{x})\}$$

SVM za linearne neodvojive razrede

Cilj: Pronalazak optimalne hiperavnine koja minimizira vjerojatnost klasifikacijske pogreške

Meka merna razdvajanja - merna kol koje za uzorak


(\vec{x}_i, d_i) NE VRIJEDI

$$d_i \cdot (\vec{w}^T \vec{x}_i + b) \geq +1$$

Povreda uvjeta $d_i \cdot (\vec{w}^T \vec{x}_i + b) > +1$ u dva slučaja:

1) uzorak (\vec{x}_i, d_i) pada unutar područja odvajanja ali s prave strane decizione hiperavnine

2) uzorak (\vec{x}_i, d_i) pada unutar područja odvajanja na krivu stranu decizione hiperavnine



Kategorije uzoraka za učenje

1) Uzorci koji padaju izvan mjerne i ispravno su klasificirani. Za njih vrijedi:

$$d_i \cdot (\vec{w}^T \vec{x}_i + b) \geq 1 \quad \xi_i = 0$$

2) Uzorci koji padaju unutar mjerne ali su pravilno razvrstani. Za njih vrijedi:

$$0 < d_i \cdot (\vec{w}^T \vec{x}_i + b) < 1 \quad 0 < \xi_i < 1$$

3) Uzorci koji su pogresno razvrstani (mogu biti i unutar i izvan mjerne). Za njih vrijedi:

$$d_i \cdot (\vec{w}^T \vec{x}_i + b) < 0 \quad \xi_i > 1$$

Jedinstveni oblik: $d_i \cdot (\vec{w}^T \vec{x}_i + b) \geq 1 - \xi_i$

$\xi_i \rightarrow$ Labava varijabla

- mjeru od stupnja vektora od idealnog uvjeta separabilnosti uzorka

Potporni vektori zadovoljavaju:

$$d_i (\vec{w}^\top \vec{x}_i + b) \geq 1 - \xi_i$$

čak i za slučaj $\xi_i > 0$

Cilj: - Vaći deozijsku funkciju za koju je pogreška klasifikacije minimalna tj.

- učiniti marginu što je moguće većom ali uz uvjet da je broj uzoraka sa

$$\xi_i > 0$$

što je moguće manji

$\xi \rightarrow$ vektor s komponentama ξ_i

$$I(\xi_i) = \begin{cases} 1 & \text{za } \xi_i > 0 \rightarrow \text{loš slučaj} \\ 0 & \text{za } \xi_i = 0 \rightarrow \text{dobar slučaj} \end{cases}$$

Funkcija koštanjā

$$J(\vec{w}, b, \vec{\xi}) = \frac{1}{2} \|\vec{w}\|^2 + C \underbrace{\sum_{i=1}^N I(\xi_i)}_{\text{broj loših slučajeva}}$$

C - pozitivna konstanta kojom se upravlja relativan međusjedanj

$$\frac{1}{2} \|\vec{w}\|^2 + \sum_{i=1}^N I(\xi_i)$$

Optimizacija je teška jer je $I(\xi_i)$ diskontinuirana funkcija pa se koristi nova funkcija "bliski" funkciji koštanjā

$$J(\vec{w}, b, \vec{\xi}) = \frac{1}{2} \vec{w}^\top \vec{w} + C \sum_{i=1}^N \xi_i$$

Primarni problem za neseparabilne razrede

Za zadani skup uzoraka $\{\vec{x}_i, d_i\}_{i=1}^N$, pronaći optimalne vrijednosti vektora \vec{w} tako da su zadovoljena ograničenja

$$d_i(\vec{w}^\top \vec{x}_i + b) \geq 1 - \xi_i \quad ; \quad i=1,2,\dots,N$$

$$\text{uz } \xi_i \geq 0$$

te da labave varijable ξ_i minimiziraju funkciju koštaja

$$J(\vec{w}, b, \vec{\xi}) = \frac{1}{2} \vec{w}^\top \vec{w} + C \sum_{i=1}^N \xi_i$$

Uporaba Lagrangeovih množilnika

$$\mathcal{L}(\cdot) = J(\vec{w}, b, \vec{\xi}) - \eta_i \varphi_i(\cdot)$$

$$\begin{aligned} \mathcal{L}(\vec{w}, b, \vec{\xi}, \vec{\eta}, \vec{\varphi}) &= \frac{1}{2} \vec{w}^\top \vec{w} + C \sum_{i=1}^N \xi_i - \sum_{i=1}^N \eta_i [d_i(\vec{w}^\top \vec{x}_i + b) - 1 + \xi_i] - \sum_{i=1}^N \varphi_i \xi_i \\ &= \eta_i [d_i \vec{w}^\top \vec{x}_i + d_i b + 1 - \vec{w}^\top \vec{x}_i - \vec{w}^\top b - \eta_i + \varphi_i] \end{aligned}$$

$$\text{Trazimo } \frac{\partial \mathcal{L}}{\partial \vec{w}}, \frac{\partial \mathcal{L}}{\partial b}, \frac{\partial \mathcal{L}}{\partial \vec{\xi}}$$

$$\frac{\partial \mathcal{L}}{\partial \vec{w}} = \frac{1}{2} \cdot L \vec{w} - \sum_{i=1}^N \eta_i d_i \vec{x}_i = \vec{w} - \sum_{i=1}^N \eta_i d_i \vec{x}_i = 0$$

$$\boxed{\vec{w} = \sum_{i=1}^N \eta_i d_i \vec{x}_i} \quad i=1,2,\dots,N$$

$$\frac{\partial \mathcal{L}}{\partial b} = - \sum_{i=1}^N \eta_i d_i = 0$$

$$\boxed{\sum_{i=1}^N \eta_i d_i = 0} \quad i=1,2,\dots,N$$

$$\frac{\partial \mathcal{L}}{\partial \xi_i} = C \cdot 1 - \eta_i - \varphi_i = C - \eta_i - \varphi_i = 0$$

$$\boxed{C - \eta_i - \varphi_i = 0} \quad i=1,2,\dots,N$$

$$\boxed{\eta_i [d_i (\vec{w}^\top \vec{x}_i + b) - 1 + \xi_i] = 0} \quad i=1,2,\dots,N$$

$$\boxed{\mu_i \xi_i = 0} \quad i=1,2,\dots,N$$

$$\boxed{\mu_i > 0}$$

$$\boxed{\eta_i > 0}$$

Novi zadatak:

Maksimizacija

$$J(\vec{w}, b, \vec{\xi}, \pi_i, \mu) = \frac{1}{2} \vec{w}^T \vec{w} + C \sum_{i=1}^N \xi_i - \sum_{i=1}^N \pi_i [d_i (\vec{w}^T \vec{x}_i + b) - 1 + \xi_i] - \sum_{i=1}^N \mu_i \xi_i$$

$$= \pi_i [d_i (\vec{w}^T \vec{x}_i + b) - 1 + \xi_i] = 0$$

$$= \pi_i d_i \vec{w}^T \vec{x}_i + \pi_i b - \pi_i + \pi_i \xi_i$$

uz uvjete

$$1) \quad \vec{w} = \sum_{i=1}^N \pi_i d_i \vec{x}_i$$

$$4) \quad \sum_{i=1}^N \pi_i d_i = 0$$

$$2) \quad C - \mu_i - \pi_i = 0$$

$$5) \quad \pi_i \xi_i = 0$$

$$3) \quad \pi_i \geq 0, \quad \mu_i \geq 0$$

$$\vec{w}^T \vec{w} = \sum_{i=1}^N \pi_i d_i \vec{x}_i^T \cdot \sum_{j=1}^N \pi_j d_j \vec{x}_j - \sum_{i=1}^N \sum_{j=1}^N \pi_i \pi_j d_i d_j \vec{x}_i^T \vec{x}_j$$

$$J(\vec{w}, b, \vec{\xi}, \pi_i, \mu) = \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \pi_i \pi_j d_i d_j \vec{x}_i^T \vec{x}_j + \sum_{i=1}^N (\mu_i + \pi_i) \xi_i - \sum_{i=1}^N \pi_i d_i \vec{w}^T \vec{x}_i - \sum_{i=1}^N \pi_i d_i b + \sum_{i=1}^N \pi_i - \sum_{i=1}^N \pi_i \xi_i$$

$$= \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \pi_i \pi_j d_i d_j \vec{x}_i^T \vec{x}_j + \sum_{i=1}^N \mu_i \xi_i - \sum_{i=1}^N \pi_i \xi_i - \sum_{i=1}^N \pi_i d_i \vec{w}^T \vec{x}_i - b \sum_{i=1}^N \pi_i d_i + \sum_{i=1}^N \pi_i - \sum_{i=1}^N \pi_i \xi_i$$

$$= \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \pi_i \pi_j d_i d_j \vec{x}_i^T \vec{x}_j - \sum_{i=1}^N \pi_i d_i \vec{w}^T \vec{x}_i + \sum_{i=1}^N \pi_i \xi_i$$

$$= \left\{ \sum_{i=1}^N \pi_i d_i \vec{w}^T \vec{x}_i = \sum_{i=1}^N \sum_{j=1}^N \pi_i \pi_j d_i d_j \vec{x}_i^T \vec{x}_j \right\}$$

$$= \sum_{i=1}^N \pi_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \pi_i \pi_j d_i d_j \vec{x}_i^T \vec{x}_j = Q(\pi)$$

Novi zadatak (Lagrangeov dualni problem)

Traži se maksimum funkcije

$$Q(\pi) = \sum_{i=1}^N \pi_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \pi_i \pi_j d_i d_j \vec{x}_i^T \vec{x}_j$$

tj. traži se

$$\max_{\pi} Q(\pi) = \max_{\pi} \left(\sum_{i=1}^N \pi_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \pi_i d_i \pi_j d_j \vec{x}_i^T \vec{x}_j \right)$$

Labave varijable ξ_i i njihovi množilici μ_i ne ulaze izravno u problem nego su prisutni kroz uvjet

$$0 \leq \pi_i \leq C \quad \text{kao lin. s.p. je nivo}$$

Skalarna produktna jezgra za SVM

C4: Prorazlaganje optimalne hiperpovršine za linearne neseparabilne razrede uporabom SVM-a

KORACI:

- 1) Nelinearno preslikavanje ulaznog vektora u prostor značajki većih dimenzija
- 2) Konstrukcija optimalne hiperpovršine za odvajanje vektora značajki dobivenih u 1)

m_0 - dimenzija ulaznog prostora

m_1 - dimenzija prostora značajki većih dimenzija

\vec{x} - vektor iz ulaznog prostora

$\{\varphi_j(\vec{x})\}_{j=1}^{m_1}$ - skup nelinearnih transformacija iz ulaznog prostora u prostor značajki

$$\sum_{j=1}^{m_1} w_j \varphi_j(\vec{x}) + b = 0 \rightarrow \text{DECIDIJSKA RAVNINA}$$

↓

$$\sum_{j=0}^{m_1} w_j \varphi_j(\vec{x}) = 0 \rightarrow w_0 = b$$

$$\vec{\varphi}(\vec{x}) = [\varphi_0(\vec{x}), \varphi_1(\vec{x}), \dots, \varphi_{m_1}(\vec{x})]^T \rightarrow \text{elka inducirana u prostoru značajki zbog ulaznog vektora } \vec{x}$$

$$\vec{w}^T \vec{\varphi}(\vec{x}) = 0 \quad *$$

U prostoru značajki postoji linearna separabilnost za koju je SVM da:

$$\vec{w} = \sum_{i=1}^N \pi_i d_i \vec{x}_i \Rightarrow \boxed{\vec{w} = \sum_{i=1}^N \pi_i d_i \vec{\varphi}(\vec{x}_i)}$$

\vec{w} se vrši u $*$:

$$\vec{w}^T \vec{\varphi}(\vec{x}) = \sum_{i=1}^N \pi_i d_i \vec{\varphi}^T(\vec{x}_i) \cdot \vec{\varphi}(\vec{x}) = 0$$

skalarni produkt
dvaju vektora iz prostora
značajki koji su
inducirani ulaznim
rečnikima \vec{x}, \vec{x}_i

$$K(\vec{x}, \vec{x}_i) = \vec{\varphi}^T(\vec{x}) \cdot \vec{\varphi}(\vec{x}_i) \rightarrow \text{skalarna produktna jezgra}$$

$$K(\vec{x}, \vec{x}_i) = \sum_{j=0}^{m_1} \varphi_j(\vec{x}) \cdot \varphi_j(\vec{x}_i) \quad \text{za } i=1, 2, \dots, N$$

Optimalna hiperplanina u prostoru znacajki je stoga zadana s:

$$\sum_{i=1}^N \pi_i d_i K(\vec{x}_i, \vec{x}) = 0$$

u izvornom prostoru je neelinearna ali u prostoru znacajki linearna

Premda SVM-u imamo

$$J(\vec{\pi}) = \sum_{i=1}^N \pi_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \pi_i \pi_j d_i d_j K(\vec{x}_i, \vec{x}_j)$$

pa ista formula u prostoru znacajki izgleda

$$J(\vec{\pi}) = \sum_{i=1}^N \pi_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \pi_i \pi_j d_i d_j K(\vec{x}_i, \vec{x}_j)$$

uz ogranicenje

$$\sum_{i=1}^N \pi_i d_i = 0 \quad 0 \leq \pi_i \leq C \quad \forall i = 1, 2, \dots, N$$

→ pozitivni parametri

optimalni vektor $\vec{w}_0 = \sum_{i=1}^N \pi_{0,i} d_i \varphi(\vec{x}_i)$

prva komponenta vektora \vec{w}_0 predstavlja optimalno poraknute bo

POOPĆENE LINEARNE DECIJUŠKE FUNKCIJE

Poopćeni oblik linearne decizijске funkcije

$$d(\vec{x}) = \sum_{i=1}^k w_i f_i(\vec{x})$$

$$d(\vec{x}) = w_1 f_1(\vec{x}) + w_2 f_2(\vec{x}) + \dots + w_k f_k(\vec{x}) + w_{k+1}$$

$$f_{k+1} = 1$$

$$\vec{x}^* = \begin{bmatrix} f_1(\vec{x}) \\ f_2(\vec{x}) \\ \vdots \\ f_k(\vec{x}) \\ 1 \end{bmatrix}$$

- linearna funkcija u
k-dimenzijском prostoru

$$d(\vec{x}) = \vec{w}^\top \vec{x}^*$$

- "virtualno linearna"

$$\vec{w} = (w_1, w_2, \dots, w_k, w_{k+1})^\top$$

Obavje se transformacija iz n-dimenzijskog prostora u k-dimenzijski.

Zadatak: Odabrat $\{f_i(\vec{x})\}_{i=1}^k$ - u obliku polinoma

2. stupnja

$$d(\vec{x}) = \sum_{j=1}^n w_{jj} x_j^2 + \sum_{j=1}^{n-1} \sum_{k=j+1}^n w_{jk} x_j x_k + \sum_{j=1}^n w_j x_j + w_{n+1}$$

$$k = \frac{(n+1)(n+2)}{2}$$

$$n=2 \quad r=3$$

r-tog stupnja

$$k = \frac{(n+r)!}{r!n!}$$

$$\begin{array}{l} 1 \ 1 \ 1 \rightarrow x_1^3 \\ 1 \ 1 \ 2 \rightarrow x_1^2 x_2 \\ 1 \ 2 \ 2 \rightarrow x_1 x_2^2 \\ 2 \ 2 \ 2 \rightarrow x_2^3 \end{array}$$

$$\begin{array}{l} 1 \ 1 \rightarrow x_1^2 \\ 1 \ 2 \rightarrow x_1 x_2 \\ 2 \ 2 \rightarrow x_2^2 \\ 1 \rightarrow x_1 \\ 1 \rightarrow x_2 \end{array}$$

$$d(x) = \vec{x}^\top \vec{X}$$

$$\vec{X} = \begin{bmatrix} 1 & x_1^3 & x_1^2 x_2 & x_1 x_2^2 & x_2^3 \\ 1 & x_1^2 & x_1 x_2 & x_2^2 & 1 \\ 1 & x_1 & x_2 & 1 & 1 \end{bmatrix}$$

BAYESOVA DECIJJSKA TEORIJA

$P(w_i)$ - a priori vjerojatnost


$p(x|w_j)$ - gustoća razdiobe vjerojatnosti

Funkcija gustoće razdiobe vjerojatnosti - funkcija $f(x)$ sa svojstvima:

$$1) f(x) \geq 0 \quad \forall x$$

$$2) \int_{-\infty}^{+\infty} f(x) dx = 1$$

$$3) \int_{x_1}^{x_2} f(x) dx = P\{x_1 \leq x \leq x_2\}$$



$$P(w_j|x) = \frac{p(x|w_j) \cdot P(w_j)}{p(x)} \rightarrow \text{BAYESOVO PRAVILA}$$

✓ a posteriori vjerojatnost $p(x) = \sum_{j=1}^n p(x|w_j)P(w_j)$

Bayesovo
decizjsko
pravilo

Ako $P(w_1|x) > P(w_2|x)$ odabiremo w_1
Inače w_2

Potpisuje

- 1) Upotreba više od jedne znacijske
- 2) Više od dva stanja prirode
- 3) Uvođenje okrje uvećava samo odluke o stanju prirode
- 4) Funkcija gubitka $\pi(\alpha_i|w_j)$

$\pi(\alpha_i|w_j)$ - gubitak mada produžimanjem okrje α_i kada je stanje prirode w_j

$$R(\alpha_i|\bar{x}) = \sum_{j=1}^c \pi(\alpha_i|w_j)P(w_j|\bar{x})$$

Očekivani gubitak - nastaje kada poduzmemo akciju α_i a stanje prirode je w_j

Bayesovo decizjsko pravilo

Da bi minimizirali učupan rizik izračunavamo uvjetni rizik

$$R(x_i | \vec{x}) = \sum_{j=1}^c \pi(x_i | w_j) P(w_j | \vec{x})$$

za $i=1, 2, \dots, a$ i tada izabiremo akciju x_i za koju je $R(x_i | \vec{x})$ MINIMUM

M=2

$$\begin{aligned} R(x_1 | \vec{x}) &= \pi(x_1 | w_1) P(w_1 | \vec{x}) + \pi(x_1 | w_2) P(w_2 | \vec{x}) \\ &= \left\{ \begin{array}{l} \pi(x_1 | w_1) = \pi_{11}; \pi(x_1 | w_2) = \pi_{12} \end{array} \right\} \\ &= \pi_{11} P(w_1 | \vec{x}) + \pi_{12} P(w_2 | \vec{x}) \end{aligned}$$

$$\begin{aligned} R(x_2 | \vec{x}) &= \pi(x_2 | w_1) P(w_1 | \vec{x}) + \pi(x_2 | w_2) P(w_2 | \vec{x}) \\ &= \pi_{21} P(w_1 | \vec{x}) + \pi_{22} P(w_2 | \vec{x}) \end{aligned}$$

PRAVILO: Odluci se za w_1 AKO

$$R(x_1 | \vec{x}) < R(x_2 | \vec{x})$$

$$\pi_{11} P(w_1 | \vec{x}) + \pi_{12} P(w_2 | \vec{x}) < \pi_{21} P(w_1 | \vec{x}) + \pi_{22} P(w_2 | \vec{x})$$

$$\pi_{11} P(w_1 | \vec{x}) - \pi_{21} P(w_1 | \vec{x}) < \pi_{22} P(w_2 | \vec{x}) - \pi_{12} P(w_2 | \vec{x})$$

$$(\pi_{11} - \pi_{21}) P(w_1 | \vec{x}) < (\pi_{22} - \pi_{12}) P(w_2 | \vec{x})$$

$$\pi_{11} < \pi_{21}$$

$$\pi_{22} < \pi_{12}$$

$$\pi_{11} - \pi_{21} < 0 \quad | \cdot (-1)$$

$$\pi_{22} - \pi_{12} < 0 \quad | \cdot (-1)$$

$$\pi_{21} - \pi_{11} > 0$$

$$\pi_{12} - \pi_{22} > 0$$

$$\Rightarrow (\pi_{22} - \pi_{12}) P(w_2 | \vec{x}) > (\pi_{11} - \pi_{21}) P(w_1 | \vec{x})$$

$$(\pi_{22} - \pi_{12}) P(\vec{x} | w_2) P(w_2) > (\pi_{11} - \pi_{21}) P(\vec{x} | w_1) P(w_1) \quad | \cdot (-1)$$

$$\frac{P(\vec{x} | w_1)}{P(\vec{x} | w_2)} > \frac{(\pi_{12} - \pi_{22}) P(w_2)}{(\pi_{21} - \pi_{11}) P(w_1)}$$

→ Omjer vjerodostojnosti

ako vrijedi odlučujemo se za w_1

→ Ako rezervisan od \vec{x}

FUNKCIJA GUBITKA - simetrična ili nula-jedan funkcija

$$\pi(x_i | w_j) = \begin{cases} 0 & i=j \\ 1 & i \neq j \end{cases}$$

$$\begin{aligned} R(x_i | \vec{x}) &= \sum_{j=1} \pi(x_i | w_j) P(w_j | \vec{x}) \\ &= \sum_{j \neq i} P(w_j | \vec{x}) \\ &= 1 - P(w_i | \vec{x}) \end{aligned}$$

M = C

$g_i(\vec{x})$, $i=1,2,\dots,c$ \rightarrow skup diskriminacionih funkcija

Klasifikator razvrstava \vec{x} u w_i ako

$$g_i(\vec{x}) > g_j(\vec{x}) \text{ za sve } j \neq i$$

$$g_i(\vec{x}) = -R(x_i | \vec{x}) \rightarrow \text{za opć slučaj s rizikom}$$

$$g_i(\vec{x}) = P(w_i | \vec{x}) \rightarrow \text{za slučaj minimalne pogreške}$$

$$\begin{aligned} g_i(\vec{x}) &= P(w_i | \vec{x}) = \frac{P(\vec{x} | w_i) P(w_i)}{P(\vec{x})} \\ &= p(\vec{x} | w_i) P(w_i) \\ &= \ln p(\vec{x} | w_i) + \ln P(w_i) \end{aligned}$$

$$P(w_i | \vec{x}) - P(w_j | \vec{x}) = 0$$

Decizionska ploha koja u višedimenzionalnom prostoru značajki djeli područja R_i i R_j

- s jedne strane plohe razlika je pozitivna a s druge negativna

Klasificiraj \vec{x} u w_i ako $g_i(\vec{x}) > g_j(\vec{x}) \forall j \neq i$

Bayesova klasifikacija za normalne distribucije

$$P(\vec{x} | \omega_i) = \frac{1}{(2\pi)^{d/2} |\Sigma_i|^{1/2}} \exp\left(-\frac{1}{2} (\vec{x} - \vec{\mu}_i)^T \Sigma_i^{-1} (\vec{x} - \vec{\mu}_i)\right)$$

$\vec{\mu}_i = E[\vec{x}]$ (ocenjivanje) \rightarrow srednja vrijednost skupa podataka ω_i

$\Sigma_i = E[(\vec{x} - \vec{\mu}_i)(\vec{x} - \vec{\mu}_i)^T]$ \rightarrow kovarijacijska matrica

$\mathcal{N}(\vec{\mu}_i, \Sigma_i) \rightarrow$ Gaussova distribucija

$$\begin{aligned} g_i(\vec{x}) &= \ln P(\omega_i | \vec{x}) \\ &= \ln (P(\omega_i | \vec{x})) \\ &= \ln (P(\vec{x} | \omega_i) P(\omega_i)) \\ &= \ln P(\vec{x} | \omega_i) + \ln P(\omega_i) \\ &= \ln \left[\frac{1}{(2\pi)^{d/2} |\Sigma_i|^{1/2}} \right] + \ln \left[e^{-\frac{1}{2} (\vec{x} - \vec{\mu}_i)^T \Sigma_i^{-1} (\vec{x} - \vec{\mu}_i)} \right] + \ln P(\omega_i) \\ &= \ln 1 - \ln \left[(2\pi)^{d/2} |\Sigma_i|^{1/2} \right] - \frac{1}{2} (\vec{x} - \vec{\mu}_i)^T \Sigma_i^{-1} (\vec{x} - \vec{\mu}_i) + \ln P(\omega_i) \\ &= -\ln (2\pi)^{d/2} - \ln |\Sigma_i|^{1/2} - \frac{1}{2} (\vec{x}^T \Sigma_i^{-1} \vec{x} - \vec{x}^T \Sigma_i^{-1} \vec{\mu}_i) + \ln P(\omega_i) \\ &= \underbrace{-\frac{1}{2} \ln (2\pi) - \frac{1}{2} \ln |\Sigma_i|}_{C_i} - \frac{1}{2} (\vec{x}^T \Sigma_i^{-1} \vec{x} - \vec{x}^T \Sigma_i^{-1} \vec{\mu}_i - \vec{x}^T \Sigma_i^{-1} \vec{\mu}_i + \vec{\mu}_i^T \Sigma_i^{-1} \vec{\mu}_i) + \ln P(\omega_i) \\ &= C_i - \frac{1}{2} \vec{x}^T \Sigma_i^{-1} \vec{x} + \frac{1}{2} \vec{\mu}_i^T \Sigma_i^{-1} \vec{x} + \frac{1}{2} \vec{x}^T \Sigma_i^{-1} \vec{\mu}_i - \frac{1}{2} \vec{\mu}_i^T \Sigma_i^{-1} \vec{\mu}_i + \ln P(\omega_i) \end{aligned}$$

$$g_i(\vec{x}) = C_i - \frac{1}{2} \vec{x}^T \Sigma_i^{-1} \vec{x} + \frac{1}{2} \vec{\mu}_i^T \Sigma_i^{-1} \vec{x} + \frac{1}{2} \vec{x}^T \Sigma_i^{-1} \vec{\mu}_i - \frac{1}{2} \vec{\mu}_i^T \Sigma_i^{-1} \vec{\mu}_i + \ln P(\omega_i)$$

Pojednostavljenja

- 1) Kovarijacijska matrica ista za sve razrede
- 2) Kovarijacijska matrica je diagonalna s jednakim elementima

Kovarijacijska matrica ista za sve razrede

$$\Sigma_i = \Sigma$$

$\vec{x}^T \Sigma \vec{x} \rightarrow$ jednok za sve discriminantne funkcije
 c_i
 >> Mogu se ispuštiti

$$g_i(\vec{x}) = \frac{1}{2} \vec{\mu}_i^T \Sigma^{-1} \vec{x} + \frac{1}{2} \vec{x}^T \Sigma^{-1} \vec{\mu}_i - \frac{1}{2} \vec{\mu}_i^T \Sigma^{-1} \vec{\mu}_i + \ln P(\omega_i)$$

$$g_i(\vec{x}) = (\Sigma^{-1} \vec{\mu}_i)^T \vec{x} + (\ln P(\omega_i) - \frac{1}{2} \vec{\mu}_i^T \Sigma^{-1} \vec{\mu}_i)$$

$$\vec{w}_i = \Sigma^{-1} \vec{\mu}_i \quad w_{i0} = \ln P(\omega_i) - \frac{1}{2} \vec{\mu}_i^T \Sigma^{-1} \vec{\mu}_i$$

$$g_i(\vec{x}) = \vec{w}_i^T \vec{x} + w_{i0}$$

Kovarijacijska matrica diagonalna s jednakim elementima

$$\Sigma = \sigma^2 \mathbf{I}$$

- znatkoje da su vektori znacajki su međusobno nekorelirane i mogu jednaku varijancu

$$E[(x_i - \mu_i)(x_j - \mu_j)] = \sigma^2 \delta_{ij}$$

$$\begin{aligned} g_i(\vec{x}) &= \vec{w}_i^T \vec{x} + w_{i0} \\ &= \Sigma^{-1} \vec{\mu}_i^T \vec{x} + w_{i0} \\ &= \frac{1}{\sigma^2} \vec{\mu}_i^T \vec{x} + w_{i0} \end{aligned}$$

$$g_i(\vec{x}) = \frac{1}{\sigma^2} \vec{\mu}_i^T \vec{x} + w_{i0}$$

jer je $\Sigma^{-1} =$

$$\begin{bmatrix} \frac{1}{\sigma^2} & & & \\ & \frac{1}{\sigma^2} & & \\ & & \ddots & \\ & & & \frac{1}{\sigma^2} \end{bmatrix}$$

Decizjska hiperavnina

$$g_{ij}(\vec{x}) = g_i(\vec{x}) - g_j(\vec{x}) = \vec{w}^T (\vec{x} - \vec{x}_0) = 0$$

$$\vec{w} = \vec{\mu}_i - \vec{\mu}_j$$

$$\vec{x}_0 = \frac{1}{2} (\vec{\mu}_i + \vec{\mu}_j) - \sigma^2 \ln \left(\frac{P(\omega_i)}{P(\omega_j)} \right) \frac{\vec{\mu}_i - \vec{\mu}_j}{\|\vec{\mu}_i - \vec{\mu}_j\|^2}$$

AKO $P(\omega_i) = P(\omega_j)$ ONDA hiperavnina prolazi kroz točku \vec{x}_0 , tj. prolazi srednjom vrijednosti od $\vec{\mu}_i$ i $\vec{\mu}_j$.

$$g_{ij}(\vec{x}) = 0 \Rightarrow \vec{w}^T (\vec{x} - \vec{x}_0) = (\vec{\mu}_i - \vec{\mu}_j)^T (\vec{x} - \vec{x}_0) = 0$$

ortogonalan na decizjsku hiperavninu

AKO $P(\omega_i) < P(\omega_j)$ ONDA je hiperavnina bliza $\vec{\mu}_i$.

AKO je σ^2 mala vrijednost u odnosu na $\|\vec{\mu}_i - \vec{\mu}_j\|$ položaj hiperavnine je neosjetljiv na vrijednosti $P(\omega_i)$, $P(\omega_j)$.

Kovarijacijska matrica nije dijagonalna.

$$\vec{x}_0 = \frac{1}{2} (\vec{\mu}_i + \vec{\mu}_j) - \ln \left(\frac{P(\omega_i)}{P(\omega_j)} \right) \frac{\vec{\mu}_i - \vec{\mu}_j}{\|\vec{\mu}_i - \vec{\mu}_j\|^2}$$

$$\frac{\|\vec{x}\|}{\Sigma^{-1}} = (\vec{x}^T \Sigma^{-1} \vec{x})^{1/2} \Sigma^{-1} \rightarrow \text{norma od } \vec{x}$$

Hiperavnina je ortogonalna na $\Sigma^{-1}(\vec{\mu}_i - \vec{\mu}_j)$

Klasifikator na temelju minimalne udaljenosti

Izmamo izraz

$$g_i(\vec{x}) = -\frac{1}{2} (\vec{x} - \vec{\mu}_i)^T \Sigma^{-1} (\vec{x} - \vec{\mu}_i) + \ln \pi_i(\vec{x}) + c_i \quad \xrightarrow{\text{zračno prostor je se}}$$

Predpostavka \rightarrow svi su razredi jednako vjerojatni i imaju istu kovarijantnu matricu

Sljедi:

$$g_i(\vec{x}) = -\frac{1}{2} (\vec{x} - \vec{\mu}_i)^T \Sigma^{-1} (\vec{x} - \vec{\mu}_i)$$

SLUČAJ $\Sigma = \sigma^2 I$

Maksimum $g_i(\vec{x})$ podrazumijeva MINIMUM od

$$d_i = \|\vec{x} - \vec{\mu}_i\|$$

\hookrightarrow euklidска udaljenost

- vektor značajki klasificira se u razred u skladu s minimalnom vrijednosti Euklidске udaljenosti

SLUČAJ Σ nije dijagonarna matica

Maksimum $g_i(\vec{x})$ postiže se kad je Σ^{-1} norma minimalna,

$$d_m = \left((\vec{x} - \vec{\mu}_i)^T \Sigma^{-1} (\vec{x} - \vec{\mu}_i) \right)^{\frac{1}{2}}$$

\hookrightarrow Mahalanobisova udaljenost

KARHUNEN-LOÈVA TRANSFORMACIJA (PCA)

I. PRISTUP

KL transformacija kao postupak minimizacije srednjih kvadratnih pogreški približnog zapisa uzorka

$\{\vec{e}_j\}$ → skup orthonormalnih vektora

Uzorak \vec{x} može se zapisati kao

$$\vec{x} = \sum_{j=1}^r c_j \vec{e}_j$$

c_j ; $j=1, 2, \dots, r$ → koeficijenti reda

Ako uzorak \vec{x} aproksimiramo pomoću n-članova reda dobivamo srednju kvadratnu pogrešku

$$\bar{\varepsilon}^2 = E \left\{ \left| \vec{x} - \sum_{j=1}^n c_j \vec{e}_j \right|^2 \right\}$$

E - operator matematičkog očekivanja

$$\begin{aligned} \bar{\varepsilon}^2 &= E \left\{ \left| \vec{x} - \sum_{j=1}^r c_j \vec{e}_j \right|^2 \right\} \\ &= E \left\{ \left| \sum_{j=1}^r c_j \vec{e}_j - \sum_{j=1}^r c_j \vec{e}_j \right|^2 \right\} \end{aligned}$$

-uzimamo u obzir orthonormalnost jedinjenih vektora

$$\vec{e}_j^\top \vec{e}_i = \begin{cases} 1, & \text{ako } j=i \\ 0, & \text{ako } j \neq i \end{cases} \quad *$$

Slijedi

$$\begin{aligned} \bar{\varepsilon}^2 &= E \left\{ \left| \sum_{j=n+1}^r c_j \vec{e}_j \right|^2 \right\} \\ &= E \left\{ \sum_{j=n+1}^r c_j^2 \right\} \Rightarrow \bar{\varepsilon}^2 = E \left\{ \sum_{j=n+1}^r c_j^2 \right\} \end{aligned}$$

$$\vec{x} - \sum_{j=1}^r c_j \vec{e}_j \perp \vec{e}_j$$

$$\vec{e}_j^\top \vec{x} = \vec{e}_j^\top \vec{e}_j \vec{e}_j^\top \vec{x} \rightarrow \text{uvrštavamo } *$$

$$\vec{e}_j^\top \vec{x} = 1 \cdot \vec{c}_j$$

$$\boxed{\vec{c}_j = \vec{e}_j^\top \vec{x}}$$

Izraz $\vec{c}_j = \vec{e}_j^T \vec{x} \rightarrow$ uvrstavamo u $\bar{\epsilon}^2$

$$\bar{\epsilon}^2 = E \left\{ \sum_{j=1}^r c_j^2 \right\}$$

$$= E \left\{ \sum_{j=1}^r \vec{e}_j^T \vec{x} \vec{e}_j \vec{x}^T \right\} \quad \begin{array}{l} \vec{e}_j \text{ je deterministički, pa možemo} \\ \text{zamjeniti redoslijed} \end{array}$$

$$= E \left\{ \sum_{j=1}^r \vec{e}_j^T \vec{x} \vec{x}^T \vec{e}_j \right\}$$

$$= \sum_{j=1}^r \vec{e}_j^T E \{ \vec{x} \vec{x}^T \} \vec{e}_j$$

$$R = E \{ \vec{x} \vec{x}^T \} \rightarrow \text{korelačka matrica uzorka}$$

$$\boxed{\bar{\epsilon}^2 = \sum_{j=1}^r \vec{e}_j^T R \vec{e}_j}$$

Tražimo da srednja kvadratna pogreška bude minimalna tj.
tražimo ortonormalne vektore \vec{e}_j (koordinatni sustav) koji
minimiziraju pogrešku

Lagrangeova funkcija:

$$\mathcal{L}(\vec{e}_j) = \sum_{j=1}^r \vec{e}_j^T R \vec{e}_j - \sum_{j=1}^r \lambda_j (\vec{e}_j^T \vec{e}_j - 1)$$

$$\frac{\partial \mathcal{L}}{\partial \vec{e}_j} = \sum_{j=1}^r 2 \vec{e}_j^T R - \sum_{j=1}^r \lambda_j \cdot 2 \vec{e}_j$$

$$= \sum_{j=1}^r 2 \vec{e}_j^T (R - \lambda_j I) = 0 \quad | : 2$$

$$\Rightarrow (R - \lambda_j I) \vec{e}_j = 0$$

$$R \vec{e}_j = \lambda_j I \vec{e}_j$$

$$\boxed{R \vec{e}_j = \lambda_j \vec{e}_j}$$

KL koordinatne osi: \rightarrow svigstveni vektor korelačke matrice $R = E \{ \vec{x} \vec{x}^T \}$

\rightarrow ortonormirani su \rightarrow koeficijenti VL reda su
međusobno nekorelirani

$R = E \{ \vec{z} \vec{z}^\top \}$ - dijagonalna matrica
 - elementi rednici: svojstvenim vrijednostima
 korelacijske matrice $R = E \{ \vec{z} \vec{z}^\top \}$

$$\begin{aligned}\vec{\epsilon}^2 &= \sum_{j=n+1}^r \vec{e}_j^\top R \vec{e}_j \\ &= \{ R \vec{e}_j = \lambda_j \vec{e}_j \} \quad \vec{e}_j^\top \vec{e}_j = 1 \\ &= \sum_{j=n+1}^r \vec{e}_j^\top \lambda_j \vec{e}_j = \sum_{j=n+1}^r \lambda_j\end{aligned}$$

$\bar{\epsilon}^2 = \sum_{j=n+1}^r \lambda_j$

$$A = \begin{bmatrix} \vec{e}_1^\top \\ \vec{e}_2^\top \\ \vdots \\ \vec{e}_n^\top \end{bmatrix} \rightarrow \text{transformacijska matrica}$$

- sastoji se od prvih n vektora koordinatnih osi \vec{e}_j uređenih po padajućem redoslijedu svojstvenih vrijednosti matrice

$\vec{y} = A \cdot \vec{x}$

\rightarrow Vektor uzoraka

Raspoznavanje uzoraka - umjesto korelacijske matrice R koristi se kovarijanska matrica K

$$K \vec{e}_j = \lambda_j \vec{e}_j$$

$$K = E \{ (\vec{x} - \vec{m})(\vec{x} - \vec{m})^\top \}$$

$\vec{\epsilon}^2 = \sum_{j=n+1}^r E \{ c_j \} \vec{e}_j$

II. PRISTUP

KL transformacija kada se maksimizira varijanca

- aproksimacija vektora \vec{x} gradi se iz ncr komponenti koje imaju najveću varijancu
- srednja kvadratna pogreška između \vec{x} , aproksimiranog \vec{x} jednaka je sumi varijanci komponenti koje su eliminirane iz \vec{x}

PREPOSTAVKA - slučajni vektor \vec{x} ima srednju vrijednost ϕ :

$$E\{\vec{x}\} = \vec{0}$$

operator matematičkog očekivanja

- \vec{x} nema srednju vrijednost $\vec{0}$? \rightarrow srednju vrijednost oduzimamo od \vec{x} prije daljnog postupka

\vec{x} - vektor značajki dimenzije r

\vec{e} - jedinični vektor dimenzije r

- Projiciramo \vec{x} na \vec{e}

$$A = \vec{x}^T \vec{e} = \vec{e}^T \vec{x}$$

ograničenje:

$$\|\vec{e}\| = (\vec{e}^T \vec{e})^{1/2} = 1$$

$$E[A] = E[\vec{e}^T \vec{x}] = \vec{e}^T E[\vec{x}] = 0$$

A \rightarrow projekcija - slučajna varijabla sa srednjom vrijednosti i varijancom u kojima se izostavlja statistika slučajnog vektora \vec{x}

Varijanca od A:

$$\begin{aligned}
 \sigma^2 &= E[A^2] = E[\vec{e}^T \vec{x} \cdot \vec{e} \vec{x}^T] \\
 &= E[(\vec{e}^T \vec{x})(\vec{x}^T \vec{e})] \\
 &= \vec{e}^T E[\vec{x} \vec{x}^T] \vec{e} \\
 &= \vec{e}^T R \vec{e}
 \end{aligned}$$

$R^T = R \Rightarrow$ simetrična je

$$\sigma^2 = \vec{e}^T R \vec{e}$$

$$R = E[\vec{x} \vec{x}^T]$$

→ korelacionska matrica slučajnog vektora \vec{x}

$$\boxed{\Psi(\vec{e}) = \sigma^2 = \vec{e}^T R \vec{e}}$$

CV - pronaći jedinične vektore \vec{e} uzduž kojih $\Psi(\vec{e})$ ima lokalne minimume ili maksimume (ekstreme)

OPTIMIZACIJA - Tražimo max vrijednost už. ograničenje euklidske norme vektora

$$\boxed{\vec{e}^T \cdot \vec{e} = 1}$$

$$L(\vec{e}) = \vec{e}^T R \vec{e} - \lambda (\vec{e}^T \vec{e} - 1)$$

$$\frac{\partial L}{\partial \vec{e}} = 2R\vec{e} - \lambda \cdot 2\vec{e} = 2R\vec{e} - 2\lambda\vec{e} = 0 \quad | : 2$$

$$R\vec{e} - \lambda\vec{e} = 0$$

$$(R - \lambda I)\vec{e} = 0$$

$$\boxed{\stackrel{\downarrow}{R\vec{e} = \lambda\vec{e}}}$$

KLASIFIKACIJA UZORAKA POMOĆU FUNKCIIA UDALJENOSTI

- Djelotvorna metoda kada razredi pokazuju srodstvo GRUPIRANJA

Klasifikacija pomoću najmanje udaljenosti.

MJERA UDALJENOSTI - Funkcija koja zadovoljava uvjete:

$$1) D(\vec{x}_k, \vec{x}_e) = 0 \quad \text{ako } \vec{x}_k = \vec{x}_e$$

$$\begin{aligned} D(\vec{x}_k, \vec{x}_e) &= \phi \\ D(\vec{x}_k, \vec{x}_e) &> 0 \end{aligned} \quad \left. \begin{array}{l} \text{ako } \vec{x}_k = \vec{x}_e \\ \text{ako } \vec{x}_k \neq \vec{x}_e \end{array} \right\}$$

$$2) D(\vec{x}_k, \vec{x}_e) = D(\vec{x}_e, \vec{x}_k)$$

$$3) D(\vec{x}_k, \vec{x}_e) \leq D(\vec{x}_k, \vec{x}_j) + D(\vec{x}_j, \vec{x}_e)$$

Euklidска udaljenost

$$D = \|\vec{x}_k - \vec{x}_e\| = \sqrt{\sum_{i=1}^n (x_{ki} - x_{ei})^2}$$

- invarijantna na translaciju i rotaciju


Minkovski udaljenost

$$D(\vec{x}_k, \vec{x}_e) = \left(\sum_{j=1}^n |x_{kj} - x_{ej}|^s \right)^{\frac{1}{s}}$$

$$\underline{s=1} \quad D(\vec{x}_k, \vec{x}_e) = \sum_{j=1}^n |x_{kj} - x_{ej}| \rightarrow \text{Manhattan ili city-block udaljenost}$$

$$\underline{s=2} \quad D(\vec{x}_k, \vec{x}_e) = \left(\sum_{j=1}^n |x_{kj} - x_{ej}|^2 \right)^{\frac{1}{2}} \rightarrow \text{Euklidска udaljenost}$$

$$\underline{s=\infty} \quad D(\vec{x}_k, \vec{x}_e) = \max \{ |x_{kj} - x_{ej}| \} \rightarrow \text{Čebiševjeva udaljenost}$$



Težinska udaljenost Minovskoj

$$D(\vec{x}_k, \vec{x}_e) = \left(\sum_{j=1}^n w_j |x_{kj} - x_{ej}|^s \right)^{\frac{1}{s}}$$

$w_j \rightarrow$ težina pojedine značajke

$$w_j \geq 1$$

Mahalanobisova udaljenost

$$D(\vec{x}_k, \vec{x}_e) = (\vec{x}_k - \vec{x}_e)^T C^{-1} (\vec{x}_k - \vec{x}_e)$$

$C \rightarrow$ kovarijacijska matrica dobivena iz skupa za učenje