

Strojno učenje – domaća zadaća 2

UNIZG FER, ak. god. 2016./2017.

Zadano: 17. 10. 2016. Rok: 21. 10. 2016.

Napomena: Zadatke možete rješavati samostalno ili u grupi. Ako zadatke rješavate u grupi, pobrinite se da svi članovi grupe pridonose rješenju i da ga naposlijetu svi razumiju. Po potrebi konzultirajte sve dostupne izvore informacija. Rješenja zadataka ponesite na iduće auditorne vježbe. Zabilježite sve nejasnoće i nedoumice, kako bismo ih prodiskutirali.

1. [Svrha: Razumjeti matrično rješenje za neregulariziranu i regulariziranu regresiju i izvježbati potrebnu matematiku. Razumjeti kako loša kondicija matrice utječe na stabilnost rješenja i kaok regularizacija to popravlja.]

- (a) Izvedite u matričnom obliku rješenje za vektor \mathbf{w} za neregularizirani linearни model regresije uz kvadratnu funkciju gubitka.
- (b) Izvedite to rješenje za L2-regularizirani model.
- (c) Raspolažemo sljedećim skupom primjera za učenje:

$$\mathcal{D} = \{(x^{(i)}, y^{(i)})\}_{i=1}^4 = \{(0, 4), (1, 1), (2, 2), (4, 5)\}.$$

Podatke želimo modelirati polinomijalnom regresijskom funkcijom $h(x) = w_0 + w_1 x + w_2 x^2$, uz regularizacijski faktor $\lambda = 10$. Napišite kako bi u ovome konkretnom slučaju izgleda jednadžba iz zadatka (b) (Ne morate ju izračunavati, samo ju napišite.)

- (d) Jednadžba iz zadatka (b) daje rješenje u zatvorenoj formi, međutim njezin izračun ponekad može biti računalno zahtjevan. Što konkretno predstavlja problem? Je li problem izražen kada imamo mnogo primjera za učenje ili kada imamo mnogo značajki? Obrazložite odgovor.
- (e) Rješenje jednadžbe iz zadatka (a) može biti numerički nestabilno. Što to znači i kada će to biti slučaj? Postoji li takav problem u slučaju formulacije problema iz zadatka (b)? Obrazložite.

2. [Svrha: Shvatiti kako se nelinarna funkcija u ulaznom prostoru funkcija preslikava u linearnu funkciju odnosno (hiper)ravninu u prostoru značajki.]

- (a) Regresijom želimo aproksimirati funkciju jedne varijable $y = 3 \cdot (x - 2)^2 + 1$. Skicirajte tu funkciju u ulaznomet prostoru. Definirajte linearan model $h(x)$ uz funkciju preslikavanja $\phi(x) = (1, x, x^2)$. Odredite vektor težina $\mathbf{w} = (w_0, w_1, w_2)$ tog modela.
- (b) Skicirajte u prostoru (x_1, x_2) (dakle u prostoru značajki, pri čemu zanemarite težinu w_0) izokonture funkcije y . Naznačite u tom prostoru točke u koje se preslikavaju primjeri $x^{(1)} = 1$, $x^{(2)} = 2$ i $x^{(3)} = 3$. Koja je vrijednost od $h(x)$ za navedene primjere?

3. [Svrha: Isprobati izračun regresijskog modela s različitim funkcijama preslikavanja i razviti intuiciju kako o tome kako funkcija preslikavanja određuje složenost hipoteze u ulaznome prostoru.] Linearnim modelom univarijatne regresije želimo aproksimirati jednu periodu funkcije $f(x) = \sin(\pi x)$. Raspolažemo skupom primjera za učenje

$$\mathcal{D} = \{(0.25, 0.707), (0.5, 1), (1, 0), (1.5, -1), (2, 0)\}.$$

- (a) Izračunajte parametre linearog modela regresije u izvornom prostoru primjera, tj. s funkcijom preslikavanja definiranom kao $\phi(x) = (1, x)$. Skicirajte dobivenu regresijsku funkciju.
- (b) Izračunajte parametre modela jednostrukе polinomijalne regresije drugog stupnja, tj. modela koji koristi funkciju preslikavanja $\phi(x) = (1, x, x^2)$. Skicirajte dobivenu regresijsku funkciju.
- (c) Izračunajte parametre modela višestruke polinomijalne regresije četvrtog stupnja, tj. modela koji koristi funkciju preslikavanja $\phi(x) = (1, x, x^2, x^3, x^4)$, uz L2-regularizaciju ($\lambda = 1$). Skicirajte dobivenu regresijsku funkciju.
- (d) Koji je model u ovom slučaju najprikladniji? Zašto?

Napomena: Izračun možete načiniti u nekom alatu koji podržava izračun matričnih operacija. Skicu također možete načiniti u nekom alatu, ili je možete napraviti ručno, izračunom vrijednosti regresijske funkcije u nekoliko odabranih točaka.

4. [Svrha: Uvjeriti se da, uz određene pretpostavke, kvadratna pogreška ima probabilističko tumačenje i opravdanje.] Kod postupka najmanjih kvadrata empirijska je pogreška definirana kao:

$$E(\mathbf{w}|\mathcal{D}) = \frac{1}{2} \sum_{i=1}^N (\mathbf{w}^T \phi(\mathbf{x}^{(i)}) - y^{(i)})^2.$$

Pokažite da je minimizacija gornjeg izraza istovjetna maksimizaciji log-izglednosti $\ln P(\mathcal{D}|\mathbf{w})$ (odnosno minimizaciji negativne log-izglednosti) uz pretpostavku normalno distribuiranog šuma $\mathcal{N}(h(\mathbf{x}|\mathbf{w}), \sigma^2)$.

5. [Svrha: Razumjeti vezu između faktora regularizacije i složenosti modela.] Neka $\mathcal{H}_{d,\lambda}$ označava model polinomijalne regresije stupnja d s L2-regularizacijskim faktorom λ . Razmatramo četiri modela: $\mathcal{H}_{2,0}$, $\mathcal{H}_{5,0}$, $\mathcal{H}_{5,100}$, $\mathcal{H}_{5,1000}$ u ulaznom prostoru $\mathcal{X} = \mathbb{R}$. Prepostavimo da su podaci u stvarnosti generirani funkcijom koja je polinom trećeg stupnja ($d = 3$). Prepostavite da imamo razmjerno malo podataka i da je šum u podatcima razmjerno velik. Na dva odvojena crteža skicirajte

- (a) regresijsku funkciju $h(x)$ za svih pet modela te
- (b) pogrešku učenja i ispitnu pogrešku za svih pet modela.

6. [Svrha: Shvatiti kako regularizacija utječe na optimizaciju. Shvatiti geometrijski argument zašto L1-regularizacija rezultira rijetkim modelima.]

- (a) Objasnite koja je svrha regularizacije i na kojoj se pretpostavci temelji.
- (b) Koja je prednost regulariziranog modela u odnosu na neregularizirani? Dolazi li ta prednost više do izražaja u slučajevima kada imamo puno primjera za učenje ili kada ih imamo malo?

- (c) Razmatramo jednostruku višestruku regresiju, $h(x) = w_0 + w_1x_1 + w_2x_2$. Skicirajte izokonture neregularizirane funkcije pogreške u ravnini \mathbb{R}^2 koju definiraju parametri w_1w_0 i w_2w_1 (napomena: funkcija pogreške je konveksna). Zatim skicirajte izokonture regularizacijskog izraza definiranog L2-normom vektora težina (i ova je funkcija konveksna). Pomoću ove skice objasnite na koji način regularizacija utječe na izbor optimalnih parametara $(w_1^*, w_2^*)(w_0^*, w_1^*)$. Skicirajte krivulju mogućih rješenja za $\lambda \in [0, \infty)$.
- (d) Ponovite prethodnu skicu, ali ovog puta sa L1-regularizacijom. Na temelju ove skice pokušajte odgovoriti na pitanje zašto L1-regularizacija daje rjeđe modele od L2-regularizacije.
7. [Svrha: Shvatiti vezu između težine značajki, važnosti značajki i složenosti modela.]
- (a) Treniramo model regresije uz nelinearnu funkciju preslikavanja $\phi : \mathbb{R}^n \rightarrow \mathbb{R}^m$, gdje $m > n$, uz L2-regularizaciju. Optimalan regularizacijski faktor λ odredili smo unakrsnom provjerom. Kako, nakon treniranja modela, možemo provjeriti (1) koje su značajke nebitne i (2) je li izvorni model presložen?
- (b) Kako bi se u ovom slučaju ponašao L1-regularizirani model?
- (c) Prepostavite da u skupu postoji skup multikolinearnih značajki koje su, osim što su redundantne, također i irrelevantne, odnosno zavisna varijabla u stvarnosti uopće ne ovisi o tim varijablama. Ako model nije regulariziran, koje su očekivane težine tih značajki?

(2) DOMACA ZADACA

21.10.2016

- 1) a) IZVOD U MATECIJNOM OBliku RJ. ZA VETOR \vec{w} ZA NEREGULARIZIRANI LINEARNI MODEL REGRESIJE UZ KUADRATNU FUNKCIJU GUBITKA.

$$h(\vec{x}|w) = \vec{w}^\top \vec{x}$$

$$E(h|D) = \frac{1}{2} \sum (h^{(i)}(x) - y^{(i)})^2 = \frac{1}{2} \sum (\vec{w}^\top \vec{x}^{(i)} - y^{(i)})^2 =$$

$$E(w|D) = \frac{1}{2} (\vec{w}^\top \vec{x}^{(i)} - y^{(i)})^\top (\vec{w}^\top \vec{x}^{(i)} - y^{(i)}) = \frac{1}{2} (\vec{x} w - y)^\top (\vec{x} w - y)$$

\Rightarrow MINIMIZACIJA POGRESKE $\nabla_w E(w|D) = \emptyset$ $\nabla_w \rightarrow$ parc. deriv. po w

$$\begin{aligned} E(w|D) &= \frac{1}{2} ((\vec{x} w)^\top \vec{x} w - (\vec{x} w)^\top y - y^\top \vec{x} w + y^\top y) = \\ &= \frac{1}{2} ((\vec{x} w)^\top \vec{x} w - y^\top (\vec{x} w) - y^\top \vec{x} w + y^\top y) = \\ &= \frac{1}{2} ((\vec{x} w)^\top \vec{x} w - 2y^\top (\vec{x} w) + y^\top y) = \frac{1}{2} (w^\top \vec{x}^\top \vec{x} w) - 2y^\top \vec{x} w + y^\top y \end{aligned}$$

$$\nabla_x^\top A x = x^\top (A + A^\top)$$

$$\nabla A x = A$$

$$\begin{aligned} \nabla_w E(w|D) &= \frac{1}{2} (w^\top (A + A^\top) - 2y^\top x + \emptyset) = \\ &= \frac{1}{2} (w^\top (x^\top x + x^\top x) - 2y^\top x) = w^\top x^\top x - y^\top x = \emptyset \end{aligned}$$

$$w^\top x^\top x = y^\top x \rightarrow x^\top x w = x^\top y \rightarrow w = (x^\top x)^{-1} x^\top y$$

$$\Rightarrow w = X^+ y \quad = (X^\top X)^{-1} X^\top y \quad \text{PSEUDOVERSA OD } X \rightarrow \underline{\underline{X^\top}}$$

- b) IZVEDI \vec{w} ZA L2-REGULARIZIRANI MODEL

$$\begin{aligned} E(w|D) &= \frac{1}{2} (\Phi w - y)^\top (\Phi w - y) + \frac{\lambda}{2} w^\top w = \\ &= \frac{1}{2} (\Phi w)^\top \Phi w - (\Phi w)^\top y - y^\top \Phi w + y^\top y + \lambda w^\top w \end{aligned}$$

$$\begin{aligned} \nabla_w E(w|D) &= \frac{1}{2} (w^\top (\Phi^\top \Phi + \Phi^\top \Phi) - 2y^\top \Phi + \emptyset + \lambda (w^\top \mathbb{I} + \mathbb{I}^\top w)) \\ &= \frac{1}{2} (2w^\top \Phi^\top \Phi - 2y^\top \Phi + 2\lambda w^\top \mathbb{I}) = w^\top \Phi^\top \Phi - y^\top \Phi + \lambda w^\top = \emptyset \end{aligned}$$

$$\Rightarrow \Phi^\top \Phi w - \Phi^\top y + \lambda w = \emptyset \quad (\Phi^\top \Phi + \lambda \mathbb{I}) w = \Phi^\top y$$

$$w = (\Phi^\top \Phi + \lambda \mathbb{I})^{-1} \Phi^\top y$$

- c) $D = \{(x^{(i)}, y^{(i)})\}_{i=1}^4 = \{(0, 4), (1, 1), (2, 2), (4, 5)\} \quad y \cdot \lambda = 10$, $\lambda = 10$, $h(x) = w_0 + w_1 x + w_2 x^2$. KAKO BI U OVOM SLUCAJU PREDSTAVLJALA JEDNADEBA PZ b)?



$$\Phi = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 1 \\ 1 & 2 & 4 \\ 1 & 4 & 16 \end{bmatrix} \quad \lambda \mathbb{I} = \begin{bmatrix} 10 & 0 & 0 \\ 0 & 10 & 0 \\ 0 & 0 & 10 \end{bmatrix} \quad y = \begin{bmatrix} 4 \\ 1 \\ 2 \\ 5 \end{bmatrix}$$

$$w = (\Phi^\top \Phi + \lambda \mathbb{I})^{-1} \Phi^\top y \quad (\text{MATLAB})$$

$$w_0 = 2.2945$$

$$w_1 = -0.1306$$

$$w_2 = 0.1779$$

d) IZRAČUN JEDN. 12 b) ZNA BIT RACUNALNO ZAHTEVAN.
 ŠTO KONKRETNO PREDSTAVLJA PROBLEM? JE LI PROBLEM
 IZRAŽEN KAD IMAMO PUNO PR. ZA UČENJE ILI KADA
 IMAMO MNOŠTO ZNACAJKI? OBRAZLOZI

- Racunanje inverza matrice veličine dimenzija racunski je izrazito zahtevna.

- Problem je izražen kada imamo mnošto znacajki u pogledu

$$\Phi = \text{dim. } N \times (m+1), \quad \Phi^T \Phi = [(m+1) \times N] [N \times (m+1)] = (m+1) \times (m+1)$$


A kako od tog faktora ($m+1$) dobijmo inverz, racunska je složenost tada veća što imamo veći broj znacajki.

e) RJ. JEDN. 12 a) MOŽE BIT NUMERIČKI NESTABILNO.
 ŠTO TO ZNAČI I KADA ĆE TO BITI SLUČAJ? POSTOJI LI TAKAV PROBLEM U SLUČAJU FORMULACIJE PROBLEMA IT ZADATKA b)?

Rj. može biti nestabilno kada postoji singularitet.
 To će biti slučaj kada je matrica $\Phi^T \Phi$ posebno kondicionirana,
 tj. kada dva stupca iste rešenice te matrice jake koreliraju.


U slučaju formulacije problema it b) to neće biti problem jer matrica $\Phi^T \Phi$ koja može biti prekondicionirana, dodatno faktor λ^2 (dijagonalna matrica) što rješava problem. Na taj način smanjujući korelaciju između stupaca (redakta), odnosno smanjujući kondicijski broj.

② a) $y = 3(x-2)^2 + 1$. SKICIRAJ OM FUNKCIJU U ULAZNOM PROSTORU
 DEF. LIN. MOD. $h(x)$ UT FUNKCIJU PRESLIKAVANJA $\Phi(x) = (1, x, x^2)$
 ODREDI VEKTOR TEŽINA $w = (w_0, w_1, w_2)$ TOG MODELA



b) SKICIRAJ U PROSTORU (x_1, x_2) IZOKONTURNE FUNKCIJE. NAJAVAĆI U TOM PROSTORU TOČKE U KOJIM SE PRESLIKAVAJU PR. $x^{(1)}=1$, $x^{(2)}=2$; $x^{(3)}=3$. Kojim je vr. od $h(x)$ za navedenе pr.?

$$\Phi = (1, x, x^2); \quad \Phi_1 = x; \quad \Phi_2 = x^2$$



$$h(x) = w_0 + w_1 x + w_2 x^2 \\ = 13 - 12x + 3x^2$$

$$h(x^1) = 13 - 12 + 3 = 4$$

$$h(x^2) = 13 - 24 + 12 = 1$$

$$h(x^3) = 13 - 36 + 27 = 4$$

③ a) LINEARNIM MOD. UNIVAR. REGR. ŽELIMO APPROX. JEDNU PERIODU FUNKCIJE $f(x) = \sin(\pi x)$. RASPOLAŽEMO SKUPOM PR. ZA UCENJE

$$D = \{(0.25, 0.707), (0.5, 1), (1, 0), (1.5, -1), (2, 0)\}$$

IZR. PARAM. LIN. MOD. REGRESIJE U RAVNOM PROSTORU PR., S FORM. PRESLIKAVANJA $\Phi(x) = (1, x)$. SKICEJ DODIJELJENU REGR.

$$\Phi = \begin{bmatrix} 1 & 0.25 \\ 1 & 0.5 \\ 1 & 1 \\ 1 & 1.5 \\ 1 & 2 \end{bmatrix}$$

$$y = \begin{bmatrix} 0.707 \\ 1 \\ 0 \\ -1 \\ 0 \end{bmatrix}$$

$$\vec{w} = (\Phi^T \Phi)^{-1} \Phi^T y = \begin{bmatrix} 0.9433 \\ -0.7637 \end{bmatrix}$$

$$h(x) = w_0 + w_1 x = 0.9433 - 0.7637x$$




b) IZR. PARAM. MODELA JEDNOSTRUKE POLINOMIJALNE REGR. II STUPNJA λ . MODELA KOG KORISTI $\Phi(x) = (1, x, x^2)$. SKICEJ

$$\Phi = \begin{bmatrix} 1 & 0.25 & 0.0625 \\ 1 & 0.5 & 0.25 \\ 1 & 1 & 1 \\ 1 & 1.5 & 2.25 \\ 1 & 2 & 4 \end{bmatrix}$$

$$y = \begin{bmatrix} 0.707 \\ 1 \\ 0 \\ -1 \\ 0 \end{bmatrix}$$

$$\vec{w} = (\Phi^T \Phi)^{-1} \Phi^T y = \begin{bmatrix} 1.7538 \\ -2.9408 \\ 0.9755 \end{bmatrix}$$

$$h(x) = 1.7538 - 2.9408x + 0.9755x^2$$



c) -UT $\Phi(x) = (1, x, x^2, x^3, x^4)$ MUZ L2-reg. ($\lambda=1$) + SKICA

$$\Phi = 5 \times 5 = \Phi^T$$

$$\Phi^T \Phi = 5 \times 5$$

$$\lambda I = 5 \times 5$$

$$\Phi = \begin{bmatrix} 1 & 0.25 & 0.0625 & 0.0156 & 3.906 \times 10^{-5} \\ 1 & 0.5 & 0.25 & 0.125 & 0.0625 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1.5 & 2.25 & 3.375 & 5.0625 \\ 1 & 2 & 4 & 8 & 16 \end{bmatrix}$$


$$y = \begin{bmatrix} 0.707 \\ 1 \\ 0 \\ -1 \\ 0 \end{bmatrix}$$

$$\vec{w} = (\Phi^T \Phi + \lambda I)^{-1} \Phi^T y$$

$$\Rightarrow \vec{w} = [0.8330 \quad -0.2818 \quad -0.4155 \quad -0.3461 \quad 0.2479]^T$$

$$\begin{bmatrix} 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix}$$

$$h(x) = 0.8330 - 0.2818x - 0.4155x^2 - 0.3461x^3 + 0.2479x^4$$



d) Koji je model u obliku slijedećeg najprikladnijeg i zašto?

Najprikladniji model je onaj pod c) s obzirom da imamo napušteni kvadratni pogrešku i oblikom najbolje prati fiju $f(x) = \sin(\pi x)$.

(4)

KOD POSTUPKA NAJMANJIH KUADRATNIH EMPIRIJSKIH POGREŠAK DEFINIRANA JE KAO

$$E(\vec{w}|D) = \frac{1}{2} \sum_{i=1}^N (\vec{w}^\top \phi(x^{(i)}) - y^{(i)})^2$$

POKAŽEĆE DA JE MINIMIZACIJA GORNJEG IZRAZA ISTOJETINA MAKSIMIZACIJI LOG IZGLEDNOSTI $\ln P(D|\vec{w})$ (ODNOŠNO MINIMIZACIJI NEGATIVNE LOG IZGLEDNOSTI) UZ PRETPOSTAVKU NORMALNO DISTRIBUIRANOG SUMA $\text{CN}(h(x^{(i)}|\vec{w}), \sigma^2)$

$$\Rightarrow E(\vec{w}|D) = \frac{1}{2} \sum_{i=1}^N (\vec{w}^\top \phi(x^{(i)}) - y^{(i)})^2$$

$$\rightarrow P(D|\vec{w}) = \prod_{i=1}^N p(x^{(i)}, y^{(i)}) = \prod_{i=1}^N p(y^{(i)}|x^{(i)}) p(x^{(i)})$$

$$\rightarrow \ln \mathcal{L}(\vec{w}|D) = \ln p(D|\vec{w}) = \ln \prod_{i=1}^N p(y^{(i)}|x^{(i)}) p(x^{(i)}) = \\ = \ln \prod_{i=1}^N p(y^{(i)}|x^{(i)}) + \ln \prod_{i=1}^N p(x^{(i)}) \quad \text{ne ovisi o } \vec{w} \Rightarrow \text{konst.}$$

$$\rightarrow \ln \prod_{i=1}^N p(y^{(i)}|x^{(i)}) = \ln \prod_{i=1}^N \text{CN}(h(x^{(i)}|\vec{w}), \sigma^2) = \\ = \ln \prod_{i=1}^N \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(y^{(i)} - h(x^{(i)}|\vec{w}))^2}{2\sigma^2}} = \ln \prod_{i=1}^N \frac{1}{\sqrt{2\pi}\sigma} \cdot e^{-\frac{(y^{(i)} - h(x^{(i)}|\vec{w}))^2}{2\sigma^2}}$$

$$(ln(x+x+\dots)) = \\ (lnx+lnx+\dots) = \\ = N \ln x$$

$$= -N \ln \sqrt{2\pi}\sigma + \ln \prod_{i=1}^N e^{-\frac{(y^{(i)} - h(x^{(i)}|\vec{w}))^2}{2\sigma^2}} = \\ = -N \ln \sqrt{2\pi}\sigma - \sum_{i=1}^N \frac{(y^{(i)} - h(x^{(i)}|\vec{w}))^2}{2\sigma^2}$$

$$\text{UZ PRETPOSTAVJENU} \\ \text{NORMALNU DISTRIB. GODJE} \\ \text{JE GAJSOV SUM} \\ \text{DN}(0, \sigma^2) \\ \therefore = -\frac{1}{2\sigma^2} \sum_{i=1}^N (y^{(i)} - h(x^{(i)}|\vec{w}))^2 = -\frac{1}{2} \sum_{i=1}^N (y^{(i)} - h(x^{(i)}|\vec{w}))^2$$


→ **MAKSIMIZACIJA LOG-IZGLEDNOSTI ODGOVARA MINIMIZACIJI FJE POGREŠAK DEFINIRANE KAO ZBROJ KUADRATNIH ODSITUJANJA (ako je pretpostavljeno da su Gaussiani)**
 $y^{(i)} = h(x^{(i)}) + \text{CN}(0, \sigma^2)$

5

$H_{d,\lambda}$ = MODEL POLINOM. REGR. STUPNJA d S L2 - REGULARIZACIJE
FAKTOROM λ

RAZMATRAMO 4 MODELA: $H_{2,0}$, $H_{5,0}$, $H_{5,100}$, $H_{5,1000}$ U UL. PROSTORU
 $X = \mathbb{R}$. PREPOSTAVLJAMO DA SU PODACI U SVAKOSTI GENERIRANI
FUNKCIJE $d=3$. PREPOSTAVLJAMO DA IMAMO RAZMJERNO MALO PODATAKA
I DA JE ŠUM U PODACIMA RAZMJERNO VEĆI. NA DVA CRTEZA SKICIRAJTE:


a) REGRESIJSKE FUNKCIJE $f_i(x)$ ZA SVIH PET MODELA



$$\begin{aligned} H_{2,0} &\rightarrow d=2, \lambda=0 \\ H_{5,0} &\rightarrow d=5, \lambda=0 \\ H_{5,100} &\rightarrow d=5, \lambda=100 \\ H_{5,1000} &\rightarrow d=5, \lambda=1000 \end{aligned}$$

$\lambda \uparrow$ fa postavak glatka
(\leftarrow složenost modela \downarrow)
smanjuje nečinjenost

b) POGREŠKA UČENJA I ISPIRNA POGREŠKA



- $H_{2,0}$ će sigurno imati najveću pogrešku, stupajući da je prevelik + nema regularizacije
- $H_{5,0}$ će imati najmanju pogrešku učenja (model sas obično iznenadili na primjerima) ali će imati najveću pogrešku generalizacije (jer nemamo učenju reguliranje i model se ptilazuje šumu)
- $H_{5,100}$ ima veću pogrešku generalizacije od $H_{5,1000}$ zbog manjeg λ , ali manju od $H_{5,0}$ jer ima veći λ . Pogr. učenja od $H_{5,100}$ je manja od $H_{5,0}$ ali veća od $H_{5,1000}$ jer se učenje ptilazava na šum (zbog reguliranje (od $H_{5,0}$))

6) a) SVRHA REGULARIZACIJE? NA KOJU SE PRETPOSTAVLJA TEMELJ?

SVRHA regularizacije je SPRIJEČAVANJE PRENAUČENOSTI MODELA ogranicavajući rastu vrijednosti parametara.


TEMELJ se na pretpostavci da što je LINEARNI MODEL složeniji, to ima veće vrijednosti parametra. Iz tog razloga kažnjavamo hipoteze s visokim vrijednostima parametara! (u tu pogresku ugradujemo uver dozvoljiv model).

b) PREDNOST REGULARIZIRANOG MODELA U ODNOŠU NA NEREGUL.,? DOLAZI LI TA PREDNOST DO PEREJAVA U SUCAJEVILA KADA IMAMO PUNO ILI MALO PR. ZA UCENJE?

Prednost REGULARIZIRANOG modela u odnosu na neregularizirani je da je REG. MODEL TEŽE PRENAUČENI!! To dolazi do perejava kad imamo MALO PR. ZA UCENJE!!


Druga prednost je poboljšanje numeričke stabilitetu.

c) RAZMOTRIMO JEON. REGRESIJU $h(x) = w_0 + w_1 x$, SICURAJ IZOKONTURE NEREG. REG. POGR. U RAUNINI R^2 KOD DEF. PARAM. w_0 I w_1 , ZATIM SK. IZOKONT. REGULARIZ. IZAKA DA DEF. S L2-normu VECORA TEŽINA. POMOĆU OVE SKICE OBJASNI NA KOG NACIN REGULARIZACIJA UTEŽE NA PEBOR OPTIMALNIH PARAM. (w_0^*, w_1^*) . SICURAJE KRIVU MOGUĆIH RJ. ZA $\lambda \in [0, \infty)$



- OPTIMALNI PARAM. UVIJEK SE NALAZE NA SPOJNICI IZOKONTURA
- OPT. PARAM. SU MANJI OD PARAM. KOJI MINIMIZIRAJU FG POGRESKE (KAO NEREG. REGR.).
- L2 - REG. NE MOže REZULTIRATI RIJETKIM MODEUIMA, ZA TO BI SE OPT. PARAM. MORALI NALAZITI NA W1 OSI. PLUS, L2 KAŽNJAVA TEŽINE PROPORTIONALNO MULTIM. IZGOBLJUJU.
- L2 DAJE RJ. U ZATVORENOJ FORMI

d) Ponovi c) s L1 - reg. na temelju ove sluge potvrdite
odg na pitanje: ZASTO L1 REG. DAJE PREDICE MODELE U L2



IZOKONTURE REGULARIZACIJSKOG
IZRAZA KOD L1-REG. IMAJU
KVADRATNI OBLIK TE JE
VEROVATNOST DA ĆE SE S
IZOKONTUROM NEREG. TE POGRE.
SJEĆI BUZU (LUNU) OPI
KVADRATNOG SUSTAVA (w_0, w)
PUNO VECÀ NEGO KOD)

→ w_0
IZOKONTURE L2 REG.
IZRAZA, REZULTIRAJU
TIME RJEDIM MODELOM.

4 a)

TRENIRALO MODEL REGRESIJE UZ NEUN. IZU PRESLIKAVANJA
 $\phi: \mathbb{R}^n \rightarrow \mathbb{R}^m$, gdje je $m > n$, uz L2 REG. OPT. REG. FAKTOR
 λ ODREDILO SHO UNAKRSNOM PROJEROM. KAKO, NAKON
TRENIRANJA MODELA, MOŽEMO PROJERITI:

1) KOJE SU ZNAČAJKE NEBITNE

One značajke cije su ujedno svi u modelu
modela regresije uz L2 reg. JAKO PRIGUŠENE (odnosno
param. w_j uz te značajke su ≈ 0) su NEBITNE!
Osim toga moguće su bitne od značajki koje nisu jasno
pričuvane. (zato sto L2 teže kažnjava značajke
većeg imosa) ($w_j \gg 0$)

2) JE LI IZVORNI MODEL PRESLOŽEN

Izvorni je model PRESLOŽEN ali su parametri
 w_j uz "najslabije" značajke (najveće potencije
kod polinoma) blizu 0 ! → To znači da je L2
kaznio, odnosno pričuvao, te značajke.

b) KAKO BI SE U ODM SUSTAVU PONAŠAO L1-REG. MODEL?

L1 - regularizacijski model bi vjerovatno te značajke u
potpunosti pritegnuo na 0 , rezultirajući nijednom modelom.
Ali bi ih u najmanju ruku još više pričuvao.

c) →