

# Strojno učenje – domaća zadaća 3

UNIZG FER, ak. god. 2016./2017.

Zadano: 24. 10. 2016. Rok: 28. 10. 2016.

*Napomena:* Zadatke možete rješavati samostalno ili u grupi. Ako zadatke rješavate u grupi, pobrinite se da svi članovi grupe pridonose rješenju i da ga naposlijetu svi razumiju. Po potrebi konzultirajte sve dostupne izvore informacija. Rješenja zadataka ponesite na iduće auditorne vježbe. Zabilježite sve nejasnoće i nedoumice, kako bismo ih prodiskutirali.

1. [Svrha: *Znati definirati poopćeni linearan model i razumjeti dvije vrste nelinearnosti koje se kod njega javljaju. Razumjeti geometriju linearog modela.*]
  - (a) Definirajte poopćeni linearan model i navedite varijante modela koje su (i) nelinearne u parametrima i (ii) nelinearne u granici između klasa.
  - (b) Dokažite da je  $\mathbf{w}$  normala (hiper)ravnine.
  - (c) Izvedite izraz za predznačenu udaljenost primjera  $\mathbf{x}$  od hiperravnine.
2. [Svrha: *Isprobati na konkretnom kako se regresija može upotrijebiti za klasifikaciju. Razumjeti kako ostvariti višeklasnu klasifikaciju pomoću više binarnih modela. Razumjeti zašto je korištenje linearne regresije za klasifikaciju loša ideja.*] Na predavanjima smo pokazali kako se linearan model regresije može koristiti za klasifikaciju. Pokažite to na sljedećim primjerima iz triju ( $K = 3$ ) klasa:

$$\begin{aligned}\mathcal{D} &= \{(\mathbf{x}^{(i)}, y^{(i)})\}_{i=1}^6 \\ &= \{((-3, 1), 0), ((-3, 3), 0), ((1, 2), 1), ((2, 1), 1), ((1, -2), 2), ((2, -3), 2)\}.\end{aligned}$$

- (a) U gornjem primjeru za oznake klasa koristili smo cijele brojeve, no u praksi kod linearnih modela to ne radimo tako. Kako to radimo u praksi i zašto ne koristimo cijele brojeve kao oznake klasa?
- (b) Primijenite pristup *jedan-naspram-ostali* (OVR), definirajte dizajn-matricu i vektor oznaka  $\mathbf{y}$  za svaki od triju modela, te izračunajte hipoteze  $h_j(\mathbf{x})$  za svaku od triju klasa. Izračun možete napraviti ručno ili u nekom alatu.
- (c) Izračunajte diskriminacijske funkcije  $h_{12}(\mathbf{x})$ ,  $h_{23}(\mathbf{x})$  i  $h_{13}(\mathbf{x})$  između svih parova hipoteza. Skicirajte primjere i dobivene granice u prostoru  $\mathbb{R}^2$ .
- (d) U koju bi klasu bio klasificiran primjer  $\mathbf{x} = (-1, 3)$ ? Obrazložite odgovor.
- (e) Objasnite koja je prednost pristupa OVR nad pristupom *jedan-naspram-jedan* (OVO), a što je nedostatak.
- (f) Možete li reći koja je vjerojatnost da primjer pripada toj klasi? Obrazložite odgovor.
- (g) U praksi linearu regresiju ne bismo željeli koristiti za klasifikaciju. Zašto? Pokažite na gornjem primjeru u čemu je problem (možete modificirati primjer).

3. [Svrha: Razumjeti kriterij perceptronra i ograničenja koja proizlaze iz toga što ta funkcija nije derivabilna.]

Algoritam perceptronra minimizira pogrešku  $E_p(\mathbf{w}|\mathcal{D})$  koju nazivamo *kriterij perceptronra*. Ta je funkcija aproksimacija udjela pogrešnih klasifikacija (engl. *misclassification ratio*), odnosno očekivanja gubitka 0-1,  $E_m(\mathbf{w}|\mathcal{D})$ , koju bismo idealno htjeli minimizirati, ali to ne možemo. Pogledajte (u slajdovima) kako izgleda pogreška perceptronra u prostoru parametara.

- (a) Objasnite zašto ne možemo izravno minimizirati  $E_m(\mathbf{w}|\mathcal{D})$ .
- (b) Je li pogreška perceptronra  $E_p(\mathbf{w}|\mathcal{D})$  gornja ograda za empirijsku pogrešku  $E(\mathbf{w}|\mathcal{D})$ ? Objasnite.
- (c) Jedan nedostatak perceptronra jest da rješenje  $\mathbf{w}^*$  (a time i položaj granice) ovisi o početnim težinama i redoslijedu predočavanja primjera. Pozivajući se na sliku površine pogreške u prostoru parametara, objasnite zbog čega je to tako.
- (d) Drugi nedostatak perceptronra jest da postupak ne konvergira ako primjeri nisu linearno odvojivi. Pozivajući se opet na sliku površine pogreške u prostoru parametara, objasnite zašto je to tako.

4. [Svrha: Razumjeti odnose između funkcija gubitaka različitih modela. Razumjeti kako funkcija gubitka određuje dobra i loša svojstva modela.]

- (a) Skicirajte na jednome grafikonu sljedeće tri funkcije gubitka: (1) kvadratni gubitak regresije, (2) gubitak perceptronra i (3) gubitak 0-1.
- (b) Odgovorite čemu odgovara desna strana grafikona ( $x$ -os veća od nule), a čemu lijeva ( $x$ -os manja od nule).
- (c) Pozivajući se na skicu, odgovorite zašto kvadratni gubitak nije prikladan gubitak u slučajevima kada želimo minimizirati broj pogrešnih klasifikacija.
- (d) Pozivajući se na skicu, odgovorite za koje će modele očekivanje gubitka (empirijska pogreška) biti veće od broja pogrešnih klasifikacija.

### ③ DOMAĆA ZADACA

① a) DEF. POPOĆENI UN MODEL + NAVEDI VAR. MODELA KOJE SU:  
 i) NEUN. U PARAM. ii) NEUN U GRANICA IZMEDU KLASA

$\Rightarrow$  LINEARAN MODEL (Granica je linearna, hiperplanska)  $h(x) = \vec{w}^T \vec{x}$

$\Rightarrow$  POPOĆENI LINEARNI MODEL  $\Rightarrow h(x) = f(\vec{w}^T \vec{x})$  granica u ul.  
prostor je linearno  
preslikan k funkciji

gdje je  $f$  aktivacijska funkcija koja spisuje linearu funkciju na intervalu  $[0, 1]$  ili na intervalu  $[-1, 1]$ .

(u) u parametri modela, dali je  $\vec{x}$  vektor začajki.

i) Model je NELINEARAN U PARAM. Kada je  $f$  NELINEARNA funkcija

ii) Mod. je NEUN. U GRANICAMA IZMEDU KLASA kada je ulazni prostor  $X$  preslikan u prostor začajki  $\Phi(X)$  NELINEARnim PRESLUČAVANJEM  $\Phi: \mathbb{R}^n \rightarrow \mathbb{R}^m \Rightarrow h(x) = f(\vec{w}^T \Phi(x))$

b) DOKAŽI DA JE  $\vec{w}$  NORMALA (HIPER)RAVNINI:

$\rightarrow$  Razmatramo sledeći model  $h(\vec{x}; \vec{w}) = w_0 + w_1 x_1 + w_2 x_2$

$\rightarrow$  Granica izmedu klasa je  $w_0 + w_1 x_1 + w_2 x_2 = 0$

Primer  $\vec{x}$  klasificiran u  $C_1$  ako je  $h(x) \geq 0$ , inace u  $C_2$ .

$\Rightarrow$  Granica izmedu klasa je  $(n-1)$  dimenzionska hiperplanska definirana jednadžbom  $h(x) = 0$ . Za dve točke  $x_1$  i  $x_2$  koje leže na hiperplanini vrijedi:

$$\begin{aligned} h(x_1) &= h(x_2) \\ \vec{w}^T \vec{x}_1 + w_0 &= \vec{w}^T \vec{x}_2 + w_0 \\ \vec{w}^T (\vec{x}_1 - \vec{x}_2) &= 0 \rightarrow \vec{w} \text{ JE NORMALA HIPERPLANI.} \end{aligned}$$

c) IZVEDI IZRAZ ZA PREDSTAVLJANJE UDALJENOSTI PR.  $\vec{x}$  OD HIPERR.

d - PREDSTAVLJANA UDALJENOST TOČKE  $\vec{x}$  OD HIPERPLANE

$X$  - probijanje odabranog točka  $x_L$  - ortog. projekcija na hiperplanu


Vrijedi:  $\vec{x} = \vec{x}_L + d \frac{\vec{w}}{\|\vec{w}\|}$   $l \cdot \vec{w}^T / + w_0 \quad \|\vec{w}\|^2$

$$\vec{w}^T \vec{x} + w_0 = \vec{w}^T \vec{x}_L + w_0 + d \frac{\vec{w}^T \vec{w}}{\|\vec{w}\|^2}$$

$$h(x) = h(x_L) + d \frac{\vec{w}^T \vec{w}}{\|\vec{w}\|^2}$$

$d \frac{\vec{w}^T \vec{w}}{\|\vec{w}\|^2} = 0$  pr. leži na hiperplanini

$$d = \frac{h(x)}{\|\vec{w}\|}$$



$$2) K \in \mathbb{Z}; D = \{(x^{(i)}, y^{(i)})\}_{i=1}^6 = \{((-3, 1), 0), ((-3, 3), 0), ((1, 2), 1), ((2, 1), 1), ((1, -2), 1), ((2, -3), 1)\}$$


a) KAKVE OZNAKE ZA KLASU SE KORISTE U PRAKSI? ZASTO NE KORISTIMO CIJELUE BROJOVE?

U praksi, umjesto viseljedne klasifikacije s cijelim brojevima radimo više binarnih klasifikacija. 3 su pristupa:

① OVR (one-vs-rest)

$\Rightarrow (K-1)$  binarnih klasifikatora, svaki bin.klas.  $\hat{h}_j$  odgovara pr. klasi  $C_j$  od pr. svih ostalih klasa. Pr. klas. u  $C_j$  daje  $\hat{h}_j(x) \geq 0$

$\Rightarrow$  PROBLEM: Kad više bin.klas. pr. klasificira pozitivno




② OVO (one-vs-one)

$\Rightarrow (K \choose 2)$  bin.klasif., po jedan za svaki par klasa.


Klasif.  $\hat{h}_{ij}$  odgovara pr. kl.  $C_i$  od pr. klase  $C_j$ . U slučaju više klasa svaki pr. klasif. pozitivno određuje  $x$ :

$$\hat{h}(x) = \operatorname{argmax}_{C_i} \sum_{C_j} \hat{h}_{ij}(x)$$



③ OVR\* - K bin.klasif. OVR i zatim klasifikacija u klasa s navedenim površinama

$$h(x) = \operatorname{argmax}_{C_j} (\hat{h}_j(x))$$



U praksi se cijeli brojevi ne koriste jer prilikom regresije za doći do problem jednom pravcem ne mogu se odvojiti tri klase.

Pr. Imamo  $x \in R^3$ , koji je najprije blizu  $R_1$ , zatim do  $R_2$ . Prilikom regresije  $x$  može biti blizu  $R_1$ , što nije točno.

b) PRIMJENI OVR, DEF. DIZAJN MATEMATIČKI  $\Phi$  I VEKTOR OZNAKA  $\vec{y}$  ZA SVAKU OD 3 KLASA TE IZR. HIPOTEZU  $\hat{h}_j(x)$  ZA SVAKU OD 3 KLASU.  $\rightarrow K=3 \rightarrow (K-1)=2$  binarne klasif.  $\rightarrow h_1, h_2$

$$\Phi(x) = \begin{bmatrix} 1 & -3 & 1 \\ 1 & -3 & 3 \\ 1 & 1 & 2 \\ 1 & 2 & 1 \\ 1 & 1 & -2 \\ 1 & 2 & -3 \end{bmatrix}, \quad \vec{y}_1 = \begin{bmatrix} 1 \\ 1 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}, \quad \vec{y}_2 = \begin{bmatrix} 0 \\ 1 \\ 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}, \quad \vec{y}_3 = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 1 \\ 1 \\ 1 \end{bmatrix}$$

$$h_1 = 0.3351 - 0.2173 x_1 - 0.0052 x_2$$

$$h_2 = 0.2592 + 0.2343 x_1 + 0.1225 x_2$$

$$h_3 = 0.14058 - 0.017 x_1 + 0.2173 x_2$$

$$\vec{w}_j = (\Phi^\top \Phi)^{-1} \Phi^\top \vec{y}_j = \Phi^{-1} \vec{y}_j$$

$$\hat{h}_j(x) = \vec{w}_j^\top \tilde{x} = \vec{w}_j^\top \Phi(x)$$

$$\vec{w} = \underbrace{\begin{bmatrix} 3 \times 6 & 6 \times 3 \end{bmatrix}}_{3 \times 6} \underbrace{\begin{bmatrix} 6 \times 1 & 6 \times 1 \end{bmatrix}}_{6 \times 1} = 3 \times 1 = \begin{bmatrix} w_0 \\ w_1 \\ w_2 \end{bmatrix}$$

$$\hat{h}_j(x) = w_0 j + w_{1j} x_1 + w_{2j} x_2$$

c) IZR. DISKR. FJE  $\hat{h}_{12}(x)$ ,  $\hat{h}_{23}(x)$  i  $\hat{h}_{13}(x)$  između svih parova hipoteza. SKICIRAJ PR. I DOBIVENE GRANICE U PROSTORU  $R^2$ .

$$\hat{h}_{12}(x) = w_{0,12} + w_{1,12} x_1 + w_{2,12} x_2 \quad ; \quad \vec{w}_{12} = \vec{w}_1 - \vec{w}_2$$

spojna mreža  
pri i en  
pri i en

analogni za  $\hat{h}_{23}$  ( $\hat{h}_{13}$ )

$$\vec{w}_{23} = \vec{w}_2 - \vec{w}_3$$

$$\vec{w}_{13} = \vec{w}_1 - \vec{w}_3$$

$$\Rightarrow h_2 = 0.0759 - 0.4516x_1 - 0.2277x_2 = \emptyset$$

$$h_{23} = -0.1466 + 0.2513x_1 + 0.4398x_2 = \emptyset$$

$$h_{13} = -0.0707 - 0.2003x_1 + 0.212x_2 = \emptyset$$

$$x_2 = -1.9833x_1 + \frac{1}{3}$$

$$x_2 = -0.571x_1 + \frac{1}{3}$$

$$x_2 = 0.945x_1 + \frac{1}{3}$$

$$X = \begin{bmatrix} -3 & 1 \\ -3 & 3 \\ 1 & 2 \\ 2 & -1 \\ 1 & -2 \\ 2 & -3 \end{bmatrix} \quad Y = \begin{bmatrix} 0 \\ 0 \\ 1 \\ 1 \\ 2 \\ 2 \end{bmatrix}$$

KLASA ①  
KLASA ②  
KLASA ③

$$(1,1) h_1 = 0.9217 \quad h_2 = 0.2311 \quad h_{23} = 0.2395 \Rightarrow \text{KLASA } ①$$

$$(1,3) h_1 = 0.9217 \quad h_2 = 0.2238 \quad h_{23} = -0.1955 \Rightarrow \text{KLASA } ①$$

$$(1,2) h_1 = 0.1023 \quad h_2 = 0.9395 \quad h_{23} = -0.0488 \Rightarrow \text{KLASA } ②$$

$$(2,1) h_1 = -0.1047 \quad h_2 = 0.9503 \quad h_{23} = 0.1545 \Rightarrow \text{KLASA } ②$$

$$(1,-2) h_1 = -0.1283 \quad h_2 = 0.0184 \quad h_{23} = 0.8233 \Rightarrow \text{KLASA } ③$$

$$(2,-3) h_1 = -0.0839 \quad h_2 = 0.2602 \quad h_{23} = 0.0232 \Rightarrow \text{KLASA } ③$$

d) U koju bi klasu bio klasificiran PR.  $x = (-1, 3)$ ? OBRAZLOZI

Primer bi bio klasificiran u klazu 2 jer je i vidljivo da plice iz prethodnog podzadatka. Primer se nalazi između hiperpravaca  $h_{12}$  i  $h_{23}$ , dokle klasa 1 je  $h_{12} = 0.9215$

e) KAJA JE PREDNOST PRISTUPA OVR NAD OVO? STO JE NEODSTANAT?

PREDNOST: - Kod OVR pristupa NEMA PREDVJEDANOSTI! jedan primer pripada samo jednoj klasi!  
- OVR ima manje modela od OVO! OVR -  $\frac{k}{2}$

MANA: OVR daje rezultata neumotičenim brojem primjera kroz klase!

f) KOJA JE VJEROJATNOST DA PR. PRIPADA TJOJ KLASI? OBRAZLOZI

Ne možemo da se slijedi da primer pripada određenoj klasi s obzirom da klasifikacija linearizacijom NIJE PREDIKTIVNI POSTUPAK.

Izaz modela NEMA VJEROJATNOSNI INTERPRETACIJU! (VJEROJATNOST HIPOTEZE Nisu ograničene na int. {0,1})

g) U PRAKCI UN-REG. NE KORISTIMO ZA KLASIFIKACIJU. ZASTO? POKAZINA GORNJEM PR. U ČETVRI JE PROBLAM

Lin. Reg. se ne koristi za klasifikaciju jer, u to što izlazi nemaju vjerojatnosnu interpretaciju, model je jasno NEROBUSAN NA VRJEDNOSTI koje odstaku! Međutim to nije to što funkcija gubitka L kaže i dobro klasificirajuće primjere. Što su ti primjeri, valio na dobro snane granice, dalje od granice, oni tim jasno upućuju na njen njezin položaj, te samim time i na klasifikaciju primjera!!

Ako np. u prethodnom primeru zamjenimo  $((2, -3), 2)$  sa  $((2, -1), 2)$ :

$$h_1 = 0.3245 - 0.2243x_1 - 0.0088x_2$$

$$h_2 = 0.4198 + 0.2060x_1 + 0.0862x_2$$

$$h_{23} = 0.2556 + 0.0183x_1 - 0.0777x_2$$

$$\text{KLFN. } h = [1 \ 1 \ 2 \ 2 \ 2 \ 3]$$

!!! VJEZNO KLASIFI!

$$h_{12} = -0.0953 - 0.4304x_1 - 0.0953x_2 = \emptyset$$



$$h_{13} = 0.0689 - 0.2427x_1 + 0.0689x_2 = \emptyset$$

$$h_{23} = 0.1642 + 0.1877x_1 + 0.1642x_2 = \emptyset$$

$$x_{2,12} = -4.52x_1 - 1$$

$$x_{2,13} = 3.5225x_1 - 1$$

$$x_{2,23} = -2.72x_1 - 1$$



3) ALG. PERCEPTRONA MINIMIZIRA  $E_{\text{emp}}(\vec{w})$ .  $E_{\text{emp}}(\vec{w})$  KJU NARAVNO KRIITERIJ PERCEPTRONA. TA JE FIC APPROX. UDJELOVAC POGR. KLASIF.  $\rightarrow$  OČEK. GUB. 0-1,  $E_m$ .

a) ZAŠTO NE MOŽEMO IZRAVNO MINIMIZIRATI  $E_m(\vec{w})$ ?

$$E_m = E_m(\vec{w}) = \frac{1}{N} \sum \mathbb{1} \{ f(\vec{w}^T \phi(x_i)) \neq y_i \}$$

OČEKIVANJE GUBITKA 0-1  
KJU BISMO IDEALNO HTELI  
MINIMIZIRATI

$(E_m \uparrow)$




NITE DERIVABILNA

Ova funkcija je PO DIJELOVIMA konstantna te stoga ne postoji mogućost konstrukcije GRADIJENTNOG SPUSTA! (Da taj alg. možemo biti u stanju izv. derivaciju pogreške)

b) DA LI JE  $E_p(\vec{w})$  GORNJA OKRADA ZA  $E_{\text{emp}}(\vec{w})$ ? OBJASNJI  $L(h(x,y))$

Ne nje, kao što je vidljivo i sa slike.  
0-1 loss funkcija gubitka konstantnog je iznosa (1) za pogresno klasificiranje primjere, dok funkcija gubitka perceptrona linearno raste od 0, stoga postoji dio na kojem je  $E_p < E_{0-1}$ , samim time  $E_p$  nije gornja okrada za  $E$ .



c) JEDAN  $\oplus$  PERC. JEST DA RJ.  $\vec{w}^*$  (ASAMEN TIME I POLOZAJ GRANICE) OVISI O POČ. TEŽINAMA I REDOSLEDU PREDODAVALJUĆA PR. POZVANI CI SE NA SLEDEĆE POGREŠKE U PROSTORU PARAM., OBJASNJI ZBOG ČEGA JE TO TAKO.

Perceptron će na temelju početnih težina i redoslijeda predodavanja primjera odabrat samo jednu hipotezu od njih dva. Zašto? Zato što će algoritam perceptrona zaustaviti čim ispravno klasificira primjere za učenje, odnosno u končnom broju koraka za lin. odabivne primjere. Ali končnici, nešto neće biti u hipotezi koja najbolje klasificira ( $h_2$ ), već bilo koja moguće učenje!


Ne možemo koja  $\left\{ \begin{array}{l} h_1 \text{ bolja hipoteza jer se nalazi približno} \\ \text{neg. p.}, \text{dok je } h_2 \text{ bolja jer ima} \\ \text{bolje svojstva generalizacije.} \end{array} \right\}$   $\left| \begin{array}{c} ++ \\ ++ \\ - - \end{array} \right| \quad h_1$   
či hipoteza biti itabrana kod perceptrona

d) DRUGI NEODUSTANAK JE DA DA PRESUPAK NE KONVERGIJA AKO PR. NIŠU LINEARNO ODVOJIVI! OBJASNJI ZAŠTO.

Algoritam perceptrona funkcioniра tako da se postupali ponavlja dokle god svi primjeri nisu ispravno klasificirani, odnosno dok algoritam ne konvergira. Ukoliko primjeri NIŠU LIN. ODVOJIVI, ne postoji ispravna klasifikacija svih primjera stoga algoritam perceptrona NE KONVERGIJA.

$\hookrightarrow$  (rez. neće biti hipoteza h s najmanjom mogućom pogreškom)

- 4) a) Skicaj na jednom grafu svedeće 3 tipa gubitaka:
- KUADRATNI GUBITAK REGRESIJE
  - GUBITAK PERCEPTRONA,
  - GUBITAK  $0-1$



- c) Zašto kuadratni gubitak nije prikladan gubitak u slučaju kada želimo minimizirati broj pogrešnih klasifikacija?

Kuadratni gubitak nije prikladan za min. broj pogr. klasif. zato što je to samo KAJNAVA SWIJE TOČKO KLASIFIKIRANE PRIMJERE, stoga će primjere broj kao nekajne klasifikirane primjere.

- d) Za koje će modelne očekivanje gubitka biti veće od broja pogr. klasif.?

Za klasifikaciju REGRESIJOM (kuadratni gubitak)