

Strojno učenje – domaća zadaća 9

UNIZG FER, ak. god. 2016./2017.

Zadano: 19. 12. 2016. Rok: 4. 1. 2017.

Napomena: Zadatke možete rješavati samostalno ili u grupi. Ako zadatke rješavate u grupi, pobrinite se da svi članovi grupe pridonose rješenju i da ga naposlijetu svi razumiju. Po potrebi konzultirajte sve dostupne izvore informacija. Rješenja zadataka ponesite na iduće auditorne vježbe. Zabilježite sve nejasnoće i nedoumice, kako bismo ih prodiskutirali.

1. [Svrha: Razumjeti model Bayesovog klasifikatora i njegove komponente. Razumjeti što su to generativni modeli, kako se razlikuju od diskriminativnih te koje su njihove prednosti i njihovi nedostatci.]
 - (a) Definirajte model Bayesovog klasifikatora i navedite sve veličine koje se pojavljaju u definiciji modela. Objasnite zašto faktoriziramo brojnik. Objasnite ulogu nazivnika i objasnite kada ga možemo zanemariti.
 - (b) Je li taj model parametarski ili neparametarski? Obrazložite odgovor.
 - (c) Objasnite zašto Bayesov model nazivamo generativnim i opišite generativnu priču Bayesovog klasifikatora.
 - (d) Objasnite razliku između generativnih i diskriminativnih modela te navedite prednosti jednih i drugih.
2. [Svrha: Isprobati izračun maksimalne aposteriorne vjerojatnosti i najvjerojatnije hipoteze uz minimizaciju rizika.] Razmotrimo problem klasifikacije neželjene el. pošte u klase *spam* ($y = 1$), *important* ($y = 2$) i *normal* ($y = 3$). Neka su apriorne vjerojatnosti tih klasa $P(y = 1) = 0.2$, $P(y = 2) = 0.05$ i $P(y = 3) = 0.75$. Za neku poruku el. pošte \mathbf{x} izglednosti iznose $p(\mathbf{x}|y = 1) = 0.8$ i $p(\mathbf{x}|y = 2) = p(\mathbf{x}|y = 3) = 0.5$. Izračunajte aposteriorne vjerojatnosti za svaku od klasa te maksimalnu aposteriornu hipotezu za primjer \mathbf{x} .
3. [Svrha: Razumjeti faktorizaciju zajedničke vjerojatnosti uz pretpostavku uvjetne nezavisnosti te povezanost toga s induktivnom pristranošću i, posljedično, brojem značajki modela.]
 - (a) Definirajte naivan Bayesov klasifikator i pretpostavku na kojoj se temelji.
 - (b) Zašto nam treba pretpostavka o uvjetnoj nezavisnosti značajki te kojoj vrsti induktivne pristranoštci ona odgovara?
 - (c) Naivan Bayesov klasifikator koristimo za klasifikaciju rukom pisanih znamenki u jednu od deset klasa. Znamenke su prikazane kao vektor binarnih značajki (crno/bijeli slikovni elementi) u matrici s razlučivošću 32×32 . Odredite ukupan broj parametara naivnog Bayesovog klasifikatora.

4. [Svrha: Isprobati na konkretnom primjeru izračun parametara naivnog Bayesovog klasifikatora.] Naivan Bayesov model želimo upotrijebiti za binarnu klasifikaciju “Skupo ljetovanje na Jadranu”. Skup primjera za učenje je sljedeći:

i	Mjesto	Otok	Smještaj	Prijevoz	$y^{(i)}$
1	Istra	da	privatni	auto	da
2	Kvarner	ne	kamp	bus	ne
3	Dalmacija	da	hotel	avion	da
4	Dalmacija	ne	privatni	avion	ne
5	Istra	ne	privatni	auto	da
6	Kvarner	ne	kamp	bus	ne
7	Dalmacija	da	hotel	auto	da

- (a) Izračunajte MLE procjene svih parametara modela te klasificirajte primjere (Istra, ne, kamp, bus) i (Dalmacija, da, hotel, bus).
- (b) Izračunajte Laplaceove (zaglađene) procjene za sve parametre modela te klasificajte nanovo iste primjere.
5. [Svrha: Razumjeti definiciju uzajamne informacije i način njezina izračuna.]
- (a) Krenuvši od definicija za entropiju i relativnu entropiju, izvedite mjeru uzajamne informacije $I(X, Y)$ kao Kullback-Leiblerovu divergenciju između zajedničke razdiobe, $P(X, Y)$, i zajedničke razdiobe uz pretpostavku nezavisnosti, $P(X)P(Y)$.
- (b) Izračunajte mjeru uzajamne informacije $I(X, Y)$ za varijable X i Y s razdiobom definiranom u zadatku (1) u zadaći 8. Biste li, temeljem vrijednosti uzajamne informacije, rekli da su varijable X i Y nezavisne?
- (c) Uzajamna informacija nije odozgo ograničena, ali je ograničena odozdo. Primjenom Jensenove nejednakosti, dokažite da vrijedi $I(X, Y) \geq 0$.

6. [Svrha: Razviti intuiciju za model kontinuiranog Bayesovog klasifikatora.]

Izrađujemo Bayesov model za klasifikaciju primjera iz $\mathcal{X} = \mathbb{R}$ u tri klase. Učenjem na skupu primjera dobili smo sljedeće parametre modela: $P(y=1) = 0.3$, $P(y=2) = 0.2$, $\mu_1 = -5$, $\mu_2 = 0$, $\mu_3 = 5$, $\sigma_1^2 = 5$, $\sigma_2^2 = 1$, $\sigma_3^2 = 10$. Skicirajte funkcije gustoće vjerojatnosti $p(x|y)$, $p(x,y)$, $p(x)$ i $p(y|x)$.

7. [Svrha: Razumjeti izvod modela kontinuiranog Bayesovog klasifikatora i osvježiti potrebno znanje matematike.]
- (a) Krenuvši od izraza (4.29) iz skripte, izvedite model višedimenzijskog Bayesovog klasifikatora s kontinuiranim ulazima s dijeljenom i dijagonalnom kovarijacijskom matricom.
- (b) Napišite broj parametara ovog modela.
- (c) Objasnite zašto je izglednost faktorizirana u produkt univarijatnih razdioba, što odgovara pretpostavci o uvjetnoj nezavisnosti, premda značajke mogu biti nelinearno uvjetno zavisne.

8. [Svrha: Razviti intuiciju za složenost modela kontinuiranog Bayesovog klasifikatora i shvatiti kako se problem u konačnici svodi na odabir optimalnog modela.] Želimo izgraditi klasifikator za klasifikaciju brukoša u jednu od dvije klase: $y = 1 \Rightarrow$ "Završava FER u roku" i $y = 2 \Rightarrow$ "Produljuje studij". Svaki je primjer opisan sa šest ulaznih varijabli: prosjek ocjena 1.–4. razreda (četiri varijable), bodovi državne mature iz matematike te bodovi državne mature iz fizike. Raspolažemo trima modelima: modelom \mathcal{H}_1 s dijeljenom kovarijacijskom matricom, modelom \mathcal{H}_2 s dijagonalnom (i dijeljenom) kovarijacijskom matricom i modelom \mathcal{H}_3 s izotropnom kovarijacijskom matricom.
- (a) Koliko svaki od ova tri modela ima parametara?
 - (b) Za koji od ova tri modela očekujete da će najbolje generalizirati u ovom konkretnom slučaju (uzmite u obzir prirodu problema i očekivane odnose između značajki)? Zašto?
 - (c) Nacrtajte skicu funkcije empirijske pogreške i pogreške generalizacije i naznačite na njoj točke koje označavaju navedenim trima modelima.
 - (d) Kako biste u praksi odredili koji će model upotrijebiti?
9. [Svrha: Razumjeti vezu između Bayesovog klasifikatora i logističke regresije, odnosno probabilističku interpretaciju logističke regresije. Razumjeti razliku u broju parametara između diskriminativnog i generativnog modela te utjecaj broja klasa i broja primjera na taj odnos.]
- (a) Izvedite model logističke regresije krenuvši od generativne definicije za $P(y = 1|\mathbf{x})$. Izvod napravite korak po korak te se uvjerite da možete obrazložiti svaki korak u izvodu. Napišite sve pretpostavke koje ste ugradili u izvod.
 - (b) Model logističke regresije koristimo za binarnu klasifikaciju primjera s $n = 100$ značajki. Odredite broj parametara modela logističke regresije te njemu odgovarajućeg generativnog modela.
 - (c) Izračunajte broj parametara za isti slučaj, ali sa $K = 5$ klasa.
 - (d) Prepostavite da klasificiramo u $K = 10$ klasa. Izračunajte koliko velika mora biti dimenzija prostora značajki n , a da bi se logistička regresija isplatila jer ima manje parametara od odgovarajućega generativnog modela.

9. DOMAĆA ZADAĆA

a)

$$p(y|x) = \frac{p(x|y)p(y)}{\sum_{y'} p(x|y')p(y')}$$

$p(y|x)$ - APOSTERIORNA VJEROJATNOST; VJEROJATNOST
DA PRIMJER x Pripada klasi y

$p(x|y)$ - PREGLEDNOST KLASE; VJEROJATNOST PRIMJERA
U KLASI

$p(y)$ - APRIORNA VJEROJATNOST KLASE

FAKTOORIZACIJA $p(x,y)$ NA $p(x|y)p(y)$ OMOGUĆUJE
MODELIRANJE SLOŽENIH DISTRIBUCIJA; $p(x|y)$ I $p(y)$
MODELIRAMO ZASEBNO.

VLOGA NAZIVNIKA JE NORMALIZIRATI VRJEDNOST NA
JEDNICH INTERVALIMA ĆIME DOBIVAMO VJEROJATNOSNU
INTERPRETACIJU. MOŽEMO GA ODBACITI PRI PRORAČUNU MAP
HIPOTEZE JER JE ON ISTI ZA SVE KLASE PA JE
MAKSIMIZACIJA BROJnika EKVIVALENTNA MAKSIMIZACIJI
CJELOBIRAZA.

b) PARAMETARSKI JER NE OVISE O BROJU PRIMJERA N
ALI OVISE O BROJU ZNAČAJAKI m (SVAKU ZNAČAJAKU
MODELIRAMO NEKOM VJEROJATNOSNOM DISTRIBUCIJOM ĆILI PARAMETR
NE OVISE O BROJU PRIMJERA).

c) NAZIVAMO GA GENERATIVnim ZATO ŠTO MODELIRA
ZAJEDNIČKU DISTRIBUCIJU $p(x,y)$, A NA TEMELJU NJE

RAZUNAMO $p(y|x)$ I LI NEKU DUGU DISTRIBUCIJU
INTERESA. EFektivno modeliramo nastajanje podataka
 $\{(x^{(i)}, y^{(i)})\}_{i=1}^n$, što se naziva GENERATIVNA PRIČA.

GENERATIVNA PRIČA BAYESOVOG KLASIFIKATORA

$p(x,y) = p(x|y)p(y)$ UKAZUJE DA PRVO ODABIREMO ZNANJE
PREMA $p(y)$, A POTOM ODABIREMO PRIMJER PREMA $p(x|y)$.

d) GENERATIVNI MODELI VJEROJATNOST $p(y|x)$ MODELIRAJU
POSREDNO PREKO ZAJEDNIČKE DISTRIBUCIJE $p(x,y)$, DOK
DISKREMINATIVNI MODELI VJEROJATNOST $p(y|x)$ MODELIRAJU
IZRAVNO. PREDNOSTI GENERATIVNIH SU LAKA UGRADNJA
STRUČNOG ZNANJA, INTERPRETABILNOST REZULTATA, POUZDANOST
KLASIFIKACIJE TE NAUČENJE STRSEČIH VRJEDNOSTI, A
MANE SU VELIK BROJ POTREBNIH PRIMJERA ZA UČENJE TE
NEPOTREBNA SLOŽENOST MODELIRANJA.

2)

$$p(y=1) = 0.2$$

$$p(y=2) = 0.05$$

$$\underline{p(y=3) = 0.75}$$

$$p(x|y=1) = 0.8$$

$$p(x|y=2) = 0.5$$

$$\underline{p(x|y=3) = 0.5}$$

$$h_1(x) = p(x|y=1)p(y=1) = 0.8 \cdot 0.2 = 0.16 //$$

$$h_2(x) = 0.05 \cdot 0.5 = 0.025 //$$

$$h_3(x) = 0.75 \cdot 0.5 = 0.375 //$$

$$P(x) = \sum_y p(x|y)p(y) = 0.16 + 0.025 + 0.375 = 0.56 //$$

MAP HIPOTEZA:

$$h(x) = \arg \max_y p(x|y)p(y) = \begin{cases} 1 & (\text{KLASA "NORMAL"}) \\ 0 & \end{cases}$$

$$P(y=1 | x) = \frac{p_{y|x}(x)}{P(x)} = \frac{0.16}{0.56} = 0.2857 //$$

$$P(y=2 | x) = \frac{0.025}{0.56} = 0.04464 //$$

$$P(y=3 | x) = \frac{0.375}{0.56} = 0.6696 //$$

3. a) NAIVAN BAYESOV KLASIFIKATOR:

$$h(x_1, \dots, x_m | y) = \operatorname{argmax}_j P(y) \cdot \prod_{i=1}^m P(x_i | y)$$

TEMELJI SE NA PREPOSTAVCI DA SU SVE ZNAČAJKE MEĐUSOBNO UVJETNO NEZAVISNE T.J. DA VRJEDI $P(x_i | x_j, y) = P(x_i | y)$

b) TREBA NAM ZATO ŠTO AKO MODELIRAMO $p(x | y)$ KAO KATEGORIČKU RAZDLOBU OD X IMAMO PREVIŠE PARAMETARA, A TIME I PRESLOŽEN MODEL ODNOŠNO NEMA GENERALIZACIJE. TO JE PRISTRANOST JEZIKA, OGRANIČAVAMO MODEL.

$$c) K=10, m=32 \cdot 32 = 1024, k_k=2, k=1 \dots N$$

$$\text{BROJ PARAMETARA} = \underbrace{K-1}_{\substack{\text{MODELIRANJE} \\ p(y) \text{ SVAKE} \\ \text{KLASE}}} + \underbrace{\sum_{k=1}^m (k_k-1)K}_{\substack{\text{MODELIRANJE} \\ p(x_i | y) \text{ ZA} \\ \text{SVAKU ZNAČAJKU}}} = 9 + 1024 \cdot 10 = 10249$$

4. a) $P(X_1 = \text{ISTRA}, y=\text{DA}) = 1/2, P(X_1 = \text{ISTRA}, y=\text{NE}) = 0$
 $P(X_1 = \text{KVARNER}, y=\text{DA}) = 0, P(X_1 = \text{KVARNER}, y=\text{NE}) = 2/3$
 $P(X_1 = \text{DALMACIJA}, y=\text{DA}) = 1/2, P(X_1 = \text{DALMACIJA}, y=\text{NE}) = 1/3$

→

$$\begin{array}{ll}
 P(X_2 = DA, Y = DA) = 3/4, & P(X_2 = DA, Y = NE) = 0 \\
 P(X_2 = NE, Y = DA) = 1/4, & P(X_2 = NE, Y = NE) = 1 \\
 \\
 P(X_3 = PRIVATN, Y = DA) = 1/2, & P(X_3 = PRIVATN, Y = NE) = 1/3 \\
 P(X_3 = KAMP, Y = DA) = 0, & P(X_3 = KAMP, Y = NE) = 2/3 \\
 P(X_3 = HOTEL, Y = DA) = 1/2, & P(X_3 = HOTEL, Y = NE) = 0 \\
 \\
 P(X_4 = AUTO, Y = DA) = 3/4, & P(X_4 = AUTO, Y = NE) = 0 \\
 P(X_4 = BUS, Y = DA) = 0, & P(X_4 = BUS, Y = NE) = 2/3 \\
 P(X_4 = AVION, Y = DA) = 1/4, & P(X_4 = AVION, Y = DA) = 1/3
 \end{array}$$

$$h(ISTRA, NE, KAMP, BUS) = \arg\max_y P(y) \prod_{k=1}^m P(X_k | y)$$

$$y = DA: P(y) \prod_{k=1}^m P(X_k | y) = \frac{4}{7} \cdot \left(\frac{1}{2} \cdot \frac{1}{4} \cdot 0 \cdot 0\right) = 0$$

$$y = NE: P(y) \prod_{k=1}^m P(X_k | y) = \frac{3}{7} \cdot \left(0 \cdot 1 \cdot \frac{2}{3} \cdot \frac{2}{3}\right) = 0$$

NE MOŽEMO DONIJETI ODLUKU!

$$\begin{array}{ll}
 h(DALMACIJA, DA, HOTEL, BUS) = \arg\max_y P(y) \prod_{k=1}^m P(X_k | y) \\
 \\
 y = DA: P(y = DA) \prod_{k=1}^m P(X_k | y = DA) = \frac{4}{7} \cdot \left(\frac{1}{2} \cdot \frac{3}{4} \cdot \frac{1}{2} \cdot 0\right) = 0 \\
 y = NE: P(y = NE) \prod_{k=1}^m P(X_k | y = NE) = \frac{3}{7} \cdot \left(\frac{1}{3} \cdot 0 \cdot 0 \cdot \frac{2}{3}\right) = 0
 \end{array}$$

NE MOŽEMO DONIJETI ODLUKU!

$$\begin{array}{ll}
 b) P(ISTRA | DA) = 3/7, & P(ISTRA | NE) = 1/6 \\
 P(KVARNER | DA) = 1/7, & P(KVARNER | NE) = 1/2 \\
 P(DALMACIJA | DA) = 3/7, & P(DALMACIJA | NE) = 1/3 \\
 \\
 P(DA | DA) = 2/3, & P(DA | NE) = 1/5 \\
 P(NE | DA) = 1/3, & P(NE | NE) = 4/5
 \end{array}$$

$$P(\text{PRIVATN} | \text{DA}) = 3/7, \quad P(\text{PRIVATN} | \text{NE}) = 1/3$$

$$P(\text{KAMP} | \text{DA}) = 1/7, \quad P(\text{KAMP} | \text{NE}) = 1/2$$

$$P(\text{HOTEL} | \text{DA}) = 3/7, \quad P(\text{HOTEL} | \text{NE}) = 1/6$$

$$P(\text{AUTO} | \text{DA}) = 4/7, \quad P(\text{AUTO} | \text{NE}) = 1/6$$

$$P(\text{BUS} | \text{DA}) = 1/7, \quad P(\text{BUS} | \text{NE}) = 1/2$$

$$P(\text{AVION} | \text{DA}) = 2/7, \quad P(\text{AVION} | \text{NE}) = 1/3$$

$$h(\text{DA} | \text{ISTRA, NE, KAMP, BUS}) = \frac{4}{7} \left(\frac{3}{7} \cdot \frac{1}{3} \cdot \frac{1}{7} \cdot \frac{1}{7} \right) = 0.001666$$

$$h(\text{NE} | \text{ISTRA, NE, KAMP, BUS}) = \frac{3}{7} \left(\frac{1}{6} \cdot \frac{4}{5} \cdot \frac{1}{2} \cdot \frac{1}{2} \right) = 0.0143$$

$$\boxed{h(x) = \text{NE}}$$

$$h(\text{DA} | \text{DALMACIJA, DA, HOTEL, BUS}) = \frac{4}{7} \left(\frac{3}{7} \cdot \frac{2}{3} \cdot \frac{3}{7} \cdot \frac{1}{7} \right) = 0.01$$

$$h(\text{NE} | \text{DALMACIJA, DA, HOTEL, BUS}) = \frac{3}{7} \left(\frac{1}{3} \cdot \frac{1}{5} \cdot \frac{1}{6} \cdot \frac{1}{2} \right) = 0.00238$$

$$\boxed{h(x) = \text{DA}}$$

5) a) ENTROPIJA:

$$H(P) = - \sum_x p(x) \ln p(x)$$

RELATIVNA ENTROPIJA:

$$H(P, Q) - H(P) = - \sum_x p(x) \ln Q(x) + \sum_x p(x) \ln p(x) =$$

$$= - \sum_x p(x) \ln \frac{p(x)}{Q(x)} = D_{KL}(P||Q) \rightarrow \text{KULLBACK-LEIBLEROVA DIVERGENCIJA}$$

$$D_{KL}(P(x,y) || P(x)P(y)) = - \sum_{x,y} p(x,y) \cdot \ln \frac{p(x,y)}{p(x)p(y)} = I(X,Y)$$

VEĆAJAMNA
INFORMACIJA

b) Iz dž 8:

$$P(1,1) = 0.2$$

$$P(1,2) = 0.05$$

$$\underline{P(1,3) = 0.3}$$

$$P(2,1) = 0.05$$

$$P(2,2) = 0.3$$

$$P(2,3) = 0.1$$

$$P(X=1) = 0.55, \quad P(X=2) = 0.45$$

$$P(Y=1) = 0.25, \quad P(Y=2) = 0.35 \quad P(Y=3) = 0.4$$

$$I(X,Y) = P(1,1) \ln \frac{P(1,1)}{P(X=1)P(Y=1)} + P(1,2) \ln \frac{P(1,2)}{P(X=1)P(Y=2)} + \dots$$

$$I(X,Y) = \{ \text{MATLAB} \} = 0.1946 \rightarrow I(X,Y) > 0 \rightarrow NISU \text{ NEZAVISNE}$$

c) JENSENOVA NEJEDNAKOST:

ZA KONVEKSNU FUNKCIJU $f(x)$ VRJEDI:

$$f(E[X]) \leq E[f(x)]$$

$$I(X,Y) = \sum_{X,Y} P(X,Y) \ln \frac{P(X,Y)}{P(X)P(Y)} \geq 0$$

NEKA $f = \ln$, PO JENSENU ODMA VRJEDI:

$$\ln E\left[\frac{P(X,Y)}{P(X)P(Y)}\right] \leq E\left[\ln \frac{P(X,Y)}{P(X)P(Y)}\right] =$$

$$E\left[\ln \frac{P(X,Y)}{P(X)P(Y)}\right] = \sum_{X,Y} P(X,Y) \ln \frac{P(X,Y)}{P(X)P(Y)} = - \sum_{X,Y} P(X,Y) \ln \frac{P(X)P(Y)}{P(X,Y)}$$

$$\leq \ln \sum_{X,Y} P(X,Y) \cdot \frac{P(X)P(Y)}{P(X,Y)} = \ln \sum_{X,Y} P(X)P(Y) = \ln(1) = 0,$$

$$- \sum_{X,Y} P(X,Y) \ln \frac{P(X)P(Y)}{P(X,Y)} \leq 0$$

$$\boxed{I(X,Y) \geq 0}$$

NE ULAZI
U ISPIT!

6. $x \in \mathbb{R}$

$$P(y=1) = 0.3 \quad P(y=2) = 0.2 \quad \Rightarrow \quad P(y=3) = 0.5$$

$$\mu_1 = -5, \quad \mu_2 = 0, \quad \mu_3 = 5, \quad \sigma_1^2 = 5, \quad \sigma_2^2 = 1, \quad \sigma_3^2 = 10$$

MATLAB:


$$P(x|y)$$

0.4

$$N(0, 1)$$


$$N(-5, 5)$$

$$N(5, 10)$$




$$P(x,y)$$

0.08



$$P(x)$$

0.12



$P(y|x) \rightarrow \text{MATLAB}$

$$a) h_j(x) = x^T \Sigma^{-1} \mu_j - \frac{1}{2} \mu_j^T \Sigma^{-1} \mu_j + \ln P(c_j) \quad (4.29)$$

VE PREPOSTAVKU DA VARIJABLE NISU KORELIRANE
KORISTIMO DIJAGONALNU KOVARIJACIJSKU MATRICU,
 $\Sigma = \text{diag}(\sigma_i^2)$. ONDA JE $\Sigma^{-1} = \text{diag}(1/\sigma_i^2)$, A
 $|\Sigma| = \prod_i \sigma_i^2$. MULTIVARIJATNA GAUSSOVA GUSTOĆA DEGENERIRAJE
U PRODUKT UNIVARIJANTNIH GAUSSOVIH RAZDJOBLJA:

$$p(x|c_j) = \frac{1}{(2\pi)^{m/2} \prod_{i=1}^m \sigma_i} \exp \left\{ -\frac{1}{2} \sum_{i=1}^m \frac{(x_i - \mu_{ji})^2}{\sigma_i^2} \right\}$$

$$= \prod_{i=1}^m \frac{1}{\sqrt{2\pi} \sigma_i} \exp \left\{ -\frac{1}{2} \frac{(x_i - \mu_{ji})^2}{\sigma_i^2} \right\}$$

$$\underline{h_j(x) = -\frac{1}{2} \sum_{i=1}^m \frac{(x_i - \mu_{ji})^2}{\sigma_i^2} + \ln P(c_j)}$$

b) BROJ PARAMETARA: $m + \underbrace{m \cdot k}_{\text{VARIJANCE}} + \underbrace{k-1}_{P(c_j)}$
 \downarrow \downarrow
 CENTROIDI

c) ZATO DA MODEL BUDE JEDNOSTAVNIJI, A TIME I
 MANJE SUKON PRENAUČENOSTI. UMJESTO $O(m^2)$ OVISNOSTI
 BROJA PARAMETARA O BROJU ENAČAJAKI DOBIVAMO $O(m)$
 OVISNOST TE JE BROJ PARAMETARA MODELA OČITO
 ZNATNO SJAVJEN.

8) a) H_1 - DIELJENA KOVARIJACIJSKA MATRICA

BRD) PARAMETARA: $\frac{m}{2}(m+1) + mk + k - 1$

$$= 34 \quad \boxed{\begin{array}{l} k=2 \\ m=6 \end{array}}$$

H_2 - DIJAGONALNA KOVARIJACIJSKA MATRICA

BRD) PARAMETARA: $m + mk + k - 1$

$$= 19 \quad \boxed{11}$$

H_3 - ROTRODNA KOVARIJACIJSKA MATRICA

BRD) PARAMETARA: $Rm + k$


$$= 13 \quad \boxed{11}$$

b) OČEKUJEM DA JE MODEL S DIJAGONALNOM KOVARIJACIJSKOM MATRICOM DATI NAJBOLJE REZULTATE.

H_1 MODELIRA MEĐUKORELIRANOST, A BUDUĆI DA SU ZNACAJKE MEĐUSOBNO KORELIRANE (NETKO TKO JE MAO DOBRE OCJENE VJEROJATNO ĆE IMATI I PUNO BODOVA NA NATURI) MOŽE DOĆI DO LOŠE KONPACIONIRANOSTI MATRICE Σ^{-1} . TAKOĐERIMA I NAJVİŞE PARAMETARA I SKLON JE PRENAUČENOSTI.

H_3 SVE VARIJANCE MODELIRA JEDNAKIMA ŠTO ĆE LAKO DOVESTI PO POPNAUČENOSTI; VELIKA JE RAZLIKA U SKALAMA ZA OCJENE (1-5) I BROJ BODOVA NA NATURI (0-100).

H_2 NE MODELIRA MEĐUKORELIRANOST ZBOG ČEGA GA JE TEŽE PRENAUČITI, NEGO H_1 , A KORISTI NORMALIZIRANE EUKLIDSKE UDALJENOSTI ZBOG ČEGA JE NEOSJETLJIV NA RAZLIKE U VARIJANCI I MEDU POJEDINIM DIMENZIJAMA, ZA RAZLIKU OD H_3 .



d) UNAKRSNOM PROVJEROM.

2)

a) APOSTERIORNA VJEROJATNOST ZA

KONTINUIRANI BAYESOV KLASIFIKATOR:

$$P(y=1|x) = \frac{p(x|y=1) P(y=1)}{p(x|y=1) P(y=1) + p(x|y=2) P(y=2)} =$$

$$= \frac{1}{1 + \frac{p(x|y=2) P(y=2)}{p(x|y=1) P(y=1)}} = \frac{1}{1 + \exp\left(\ln\left(\frac{p(x|y=2) P(y=2)}{p(x|y=1) P(y=1)}\right)\right)}$$

$$= \frac{1}{1 + \exp(-\lambda)} = \sigma(\lambda),$$

GDJĘ:

$$\lambda = \ln \frac{p(x|y=1) P(y=1)}{p(x|y=2) P(y=2)} = \underbrace{\ln(p(x|y=1) P(y=1))}_{\ln_1(x)} - \underbrace{\ln(p(x|y=2) P(y=2))}_{\ln_2(x)}$$

AKO PRETPOSTAVIMO DIJELJENU KOVARIJACIJSKU MATRICU:

$$\lambda = h_1(x) - h_2(x)$$

$$\lambda = \underbrace{x^T \Sigma^{-1} (\mu_1 - \mu_2)}_w - \frac{1}{2} \mu_1^T \Sigma^{-1} \mu_1 + \frac{1}{2} \mu_2^T \Sigma^{-1} \mu_2 + \ln \frac{P(y=1)}{P(y=2)}$$

↳ SVE ŠTO JE UZ x^T SMO OZNĀILI (SUPSTITUIRALI)
KAO VEKTOR w , A SVE SLOBODNE ČLANOVE KAO w_0
DAKLE MOŽE SE ZAPISATI:

$$\boxed{\lambda = w^T x + w_0}$$

UZ PRETPOSTAVKU DIJELJENE KOVARIJACIJSKE MATRICE
 Σ POKAZANO JE DA JE BAYESOV KLASIFIKATOR
JEDNAK LOGISTIČKOJ REGRESIJI.

b) $n = 100$

LOGISTIČKA REGRESIJA: BROJ PARAMETARA = $m+1 = 101$,

BAYESOV KLASIFIKATOR UZ DIJELJENU KOV. MAT. Σ :

$$\text{BROJ PARAMETARA} = \frac{m}{2}(m+1) + 2m + 1 = 5251 //$$

c) $n = 100, k = 5$

LOGISTIČKA REGRESIJA UZ OVU SHEMU VIŠEKLASNE KLASIFIKACIJE: BROJ PARAMETARA = $k(m+1) = 505$,

BAYESOV KLASIFIKATOR UZ DIJELJENU Σ

$$\text{BROJ PARAMETARA} = \frac{m}{2}(m+1) + mK + K - 1 = 5554 //$$

$$d) \quad k=10$$

LOGREG UZ OVO SHEMU | BAYES

$$\binom{k}{2}(m+1) = \frac{m^2}{2} + \frac{m}{2} + 10m + 9$$

$$\frac{10!}{2!8!} (m+1) = \frac{m^2}{2} + \frac{m}{2} + 10m + 9$$

$$45m + 45 = \frac{m^2}{2} + 10.5m + 9$$

$$\frac{m^2}{2} + 34.5m - 36 = 0$$

$$m_1 = -1, \quad m_2 = 79$$

↳ TEK ZA TO ZNACAJKI JE VISE ISPLATI
LOGISTICKA REGRESIJA (UZ OVO SHEMU VIŠEKLASNE
KLASIFIKACIJE).