

1) Raspoznavanje temeljeno na primjerima

Osnovna zamisao: na temelju (nekoliko) primjera (ili možda u kombinaciji s nekoliko kontraprimjera) uzborka koji pripadaju nekom razredu W_i sustav je u stanju odrediti da li novi (nepoznati) uzbork pripada tom razredu W_i .

Proces raspoznavanja može se podijeliti u dvije faze:

I. faza učenja

(tutorial stage, Learning stage)

II. faza odlučivanja

(decision stage, decision stage)

UČENJE S UČITELJEM

(Supervised Learning)



FAZ
A
Z
A
U
C
E
N
J
A

U postupku učenja s učiteljem imamo skup uzoraka za vježbanje ili učenje. Učitelj označuje pripadnost uzorka razredu (ili pridružuje cijenu koštanja svakom uzorku) i traži način redukcije ukupne cijene koštanja za sve te uzorke, odnosno traži oblik decizijske funkcije koja će uz najmanju pogrešku (ili bez pogreške) klasificirati uzorke iz skupa za učenje.



Pitanja:

- 1) Kako možemo biti sigurni da je određeni algoritam dovoljno djelotvoran i da može "naučiti" rješenje za zadani problem?
- 2) Koliko je stabilan na promjene parametara?
- 3) Da li konvergira u konačnom vremenu?



Nakon što je sustav naučio
decišijsku funkciju on se
primjenjuje na stvarnim
(neoznačenim, nepoznatim)

ODLUČIVANJA

uzorcima te se
verificiraju rezultati
raspoznavanja

2) Raspoznavanje temeljeno na strukturi (složenih) uзорaka

- uзорак opisan primitivima (terminalima) i odnosom između tih primitiva primitivi, producijska pravila,

$\begin{array}{c} / \quad \backslash \\ \text{terminali} \quad \text{neterminali} \end{array}$

gramatika, jezik

$G = (V_n, V_T, P, S)$ podloga su za jezični (sintaksni) pristup raspoznavanju

- Svakom razredu uзорaka pripadajući jezik, odnosno stroj koji raspoznavaju pojedinu gramatiku

3) Grupiranje (engl. Clustering)

- učenje bez učitelja

(engl. Unsupervised Learning)

U sustavu nema učitelja, barata se s neoznačenim uzorcima (ne zna se njihova pripadnost niti broj razreda) .

Sustav oblikuje grupe ili "prirodno grupira" ulazne uzorke. Korisnik obično eksperimentira s različitim postupcima grupiranja (svaki od njih daje drugacije "prirodne" grupe). Na temelju generiranih grupa korisnik potvrđuje ili odbacuje hipoteze.

Još jedan postupak učenja

Učenje s kritikom (engl.

Reinforcement learning, Learning with a critic)

Tipični postupci učenja klasifikatora su takvi da im se na ulazu postavi uzorak, zatim sustav određuje (tentativni) razred.

On se uspoređuje s znatom stvarnom pripadnosti razreda i to se koristi da bi se poboljšao klasifikator (npr. ako je pogrešna klasifikacija korigira se decizijska funkcija proporcionalno "veličini" greške)

Učenje s kritikom ne dobiva signal o tačnoj kategoriji, odnosno razredu, umjesto toga povratna korektivna veta nudi informaciju da li je nešto točno ili netočno.


NE SPECIFICIRA SE ZAŠTO, ODNOŠNO
KAKO JE TO POGREŠNO!

U RU obično se upotrebljava binarno učenje s kritikom

APSTRAKTNI PRIKAZ RASPOZNAVANJA UZORAKA

Raspoznavanje uzorka -

redukcija informacije, preslikavanje informacije i postupak označavanja informacije




$$f_e : F \rightarrow P$$

$$c : P \rightarrow R^1$$

(C)

Uhr : stožac raspoznavanja


smjer redukcije informacije



Primjer (R.O.Duda et al.):

Potpustavimo da tvornica ribljih konzervi želi automatizirati proces razvrstavanja riba koje stižu na pokretnoj vrpci

Pilot-projekt : razdvajanje lososa i brancina uporabom kamere.



Instaliramo kameru, uzmemo nekoliko slika uzoraka (lososa i brancina) i za početak primjetimo neke fizičke razlike između tih dviju vrsta riba :


- veličina (dužina);
 - svjetlina (ton);
 - broj i oblik ljuški,
 - položaj ustiju;
 - it.d.
- } značajke

Sve te značajke nude se u izvedbi klasifikatora.

Uočavamo i utjecaj šuma i varijacije u uzetim slikama -

- svjetlosti, položaja i orijentacije ribe na pokretnoj vrpcu...

Prototip sustava:



- Kamerom se snima riba (ili ribe) na vrpcu
- slika se preprocesira (uklanja šuma, poboljšanje kontrasta, segmentacija, lokalizacija)
- informacija koja se odnosi samo na jednu ribu ţalje se pod sustavu za izlučivanje značajki (engl. feature extractor).

U podstavu za izlučivanje značajki reducira se količina informacije tako da se "mjere" određene značajke ili svojstva.

Vrijednost tih značajki se presljeđuje klasifikatoru koji donosi konačnu odluku o pripadnosti uzorka razredu $w_1 = \text{"Losos"}$ ili $w_2 = \text{"brancin"}$

Pretpostavimo da nam je poznavao riba (zaposlen u tvornici) rekao da je brancin općenito dulji od lososa.

Ta informacija će nam poslužiti za izgradnju modela ribe:

m1: Brancin ima tipično veću duljinu od lososa.


- Označimo duljinu s l i pretpostavimo da na temelju duljine ribe možemo obaviti klasifikaciju.
- Klasifikacijsko (jednostavno) pravilo: "Ako duljina ribe prelazi duljinu l^* onda je riba brancin."

ℓ^* - kritična duljina.

Kako odrediti ℓ^* ?

ℓ^* cemo odrediti na temelju uzoraka iz skupa za učenje (engl. training samples): uzet cemo veći broj slika riba, izmjeriti duljinu i provjeriti (uz pomoć znalca) rezultat.

Pretpostavimo da smo dobili histograme:




- duljina kao jedini kriterij nije dovoljna
- pogreška (vidi osjenčana područja!)

Pokušajmo sa značajkom:
prosječna svjetlina ribe

(paži: moramo eliminirati varijacije
osvjetljenja scene!)

m2: Losos je prosječno sujetlijiji
u odnosu na brancin

Histogrami svjetline



Histogram svjetline nas je ohrebrio
- x^* - optimalna (kritična) vrijednost
praga daje manju pogrešku

Upotrijebit ćemo obje značajke:


- duljinu ℓ (x_2 - značajka)
- prosječnu sujetlinu (x_1 - značajka)


Oblikovali smo vektor značajki:

$$\vec{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

- dvodimenzionalni prostor značajki (duljina, sujetlina)

duljina






ω_1 = "losos" (\times)

ω_2 = "brancin" (\circ)

- generalizacija


osnovna namjena dizajna sustava
je uspješna klasifikacija
uzoraka (engl. novel patterns)
koje sustav nije "vidio".



Tako složena granica (koja savršeno dobro klasificira uzorke iz skupa za učenje) neće doprinositi generalizaciji


- u stvarnosti možemo se zadovoljiti s nešto skromnijom performansom sustava za uzorke iz skupa za učenje - a to može značiti da će sustav imati bolju performansu za nove uzorke.

kako sustav automatski određuje decizijsku funkciju u n-dim. prostoru znacijski?



- generalizacija

osnovna namjena dizajna sustava
je uspješna klasifikacija
uzoraka (engl. novel patterns)
koje sustav nije "vidio".



ω_1 = "losos" (x)



ω_2 = "brancin" (o)

- generalizacija

osnovna namjena dizajna sustava
je uspješna klasifikacija
uzoraka (engl. novel patterns)
koje sustav nije "vidio".


2. MODEL SUSTAVA ZA RASPOZNAVANJE UŽORAKA

2.1 FORMALNI MODEL



2.2. ZNAČAJKE, VEKTOR ZNAČAJKI I KLASIFIKATOR

osnovne faze/stupeň kvi u postupku oblikovanju sustava RU



značajke - promatramo ih kao slučajne varijable : x_i

vektor značajki - slučajni vektori \vec{x}

$$\vec{x} = [x_1, x_2, \dots, x_n]^T$$

- značajke koje predstavljaju razlike između ratreda ustanaka nazivaju se INTERSET značajke

INTRASET značajke su zajedničke svim ratredima it PUI (područja uporabe) i ne nose discriminacijsku informaciju - tave značajke mogu se zanemariti

Izbor značajki - izlučiti i izabrati INTERSET značajke

- U većini slučajeva određivanje potpunog skupa diskriminacijskih znacajki je iznimno teško ili čak nemoguće;
- Nekе diskriminacijske znacajke mogu se naći na temelju raspoloživih rezultata mjerenja (senzoriranja);
- Redukcija dimenzionalnosti vektora znacajki uporabom transformacija sa minimalnim gubitkom informacija;
- Vektor znacajki predstavljen kao točka u n-dimenzionalnom prostoru znacajki;
- Obično definiramo i neku vrstu metrike u takvom prostoru znacajki;
- Klasifikacija (razvrstavanje) uzorka temelji se na decisijskim funkcijama; PROBLEM: određivanje optimalne decisijske procedure;


- Problem klasifikacije može se promatrati kao razvrstavanje nepoznatog uzorka u potprostor prostora značajki na temelju decizijskih granica, koje definiraju te potprostore!

- Decizijske granice određene su decizijskim funkcijama:
 $d_1(\vec{x}), d_2(\vec{x}), \dots, d_M(\vec{x})$

1. d_i je funkcija koja ima za argument VETOR a vraća
SKALAR / **VAŽNO!**

- Pravilo razvrstavanja:
Ako $d_i(\vec{x}) > d_j(\vec{x})$ za
 $i, j = 1, 2, \dots, M$ te $j \neq i$
tada nepoznati uzorak \vec{x}
pripada razredu W_i .

Model sustava za raspoznavanje



- Vanjski, fizički svijet sadrži praktički
 - oo mnogo značajki
 - "analogni" svijet
 - senzor ili pretvarač pretvara analogni svijet u zapis koji sadrži r (brojčanih) vrijednosti
- Preprocesiranje : izlučivanje sume, poboljšanje mjerne podatka
- Prostor značajki : $n \ll r$
 $\vec{X} = (x_1, x_2, x_3, \dots, x_n)^T$
- Prostor odlučivanja - jednodim. prostor R^1

LINEARNE FUNKCIJE

ODLUCIVANJA

(engl. Linear discriminant functions)


\vec{X} - vektor značajki

$$\vec{X} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

$$o \in \omega_1$$

$$x \in \omega_2$$

$$M=2$$



Funkcija odlučivanja kao linearna kombinacija komponenti vektora \vec{X} :

$$d(\vec{X}) = w_1 x_1 + w_2 x_2 + \dots + w_n x_n + w_{n+1}$$

za

$n=2$ funkcija odlučivanja \rightarrow jednadžba pravca

$n=3$

jednadžba ravnine

$n > 3$

hiperravnina

w_i - težinski koeficijenti; $i=1, 2, \dots, n$

w_{n+1} - pomaknuće, užežnosni prag

(engl. bias, threshold weight)

SLUČAJ: DVA RAZREDA (ω_1 i ω_2)

$$M=2$$

$$d(\vec{x}) = w_1 x_1 + w_2 x_2 + \dots + w_n x_n + w_{n+1} = 0$$

$$M=2; \quad \omega_1 < \omega_2$$

Decizijsko pravilo:

isko pravilo: ako $d(\hat{x}) > 0$ onda $\hat{x} \in \omega_1$

$$d(\tilde{x}) < 0 \text{ and } \tilde{x} \in \omega_2$$


ako je $d(x) = 0$


ne definirano

$d(x)$ zapisimo u vektorskem obliku:

$$d(\vec{x}) = \vec{W}_0^T \vec{x} + W_{n+1} = 0$$

Geometrijska interpretacija funkcije odlučivanja:





Jednadžba hiperravnine:

$$\vec{u}^T (\vec{x} - \vec{p}) = 0$$

$$\vec{W}_0^T \vec{x} + w_{n+1} = 0 \quad / \|\vec{W}_0\|$$

$$\frac{\vec{W}_0^T \vec{x}}{\|\vec{W}_0\|} = -\frac{w_{n+1}}{\|\vec{W}_0\|}$$

$$\vec{u}^T \vec{x} = \vec{u}^T \vec{p}$$

$$\|\vec{W}_0\| = \sqrt{w_1^2 + w_2^2 + \dots + w_n^2}$$

usporedimo!

$$\vec{u} = \frac{\vec{W}_0}{\|\vec{W}_0\|} \quad ; \quad \vec{u}^T \vec{p} = -\frac{w_{n+1}}{\|\vec{W}_0\|}$$

$$\vec{u} = \frac{\vec{w}_0}{\|\vec{w}_0\|}$$

→ pokazuje orientaciju
hiperravnine;
ako je neka komponenta od \vec{u}
jednaka 0 onda je
hiperravnina paralelna s
odgovarajućom koordinatnom
osi

Apsolutna vrijednost $\vec{u}^T \vec{p}$:

$|\vec{u}^T \vec{p}|$ predstavlja udaljenost
hiperravnine od ishodišta.

$$D_u = \frac{|W_{n+1}|}{\|\vec{w}_0\|}$$

Posljedice:

- Budući da je $\vec{u} = \frac{\vec{w}_0}{\|\vec{w}_0\|}$ ispitivanjem vektora težinskih koeficijenata \vec{w}_0 može se utvrditi da li je hiperravnina paralelna s bilo kojom koordinatnom osi.
- Ako je $W_{n+1} = 0$ onda hiperravnina prolazi kroz ishodište koordinatnog sustava
- Udaljenost točke \vec{x} od hiperravnine je $D_x = |\vec{u}^T \vec{p} - \vec{u}^T \vec{x}|$
 $= \left| \frac{\vec{w}_0^T \cdot \vec{p}}{\|\vec{w}_0\|} - \frac{W_{n+1} \vec{x}}{\|\vec{w}_0\|} \right|$


rf 5

SLUČAJ: VIŠE RAZREDA $M > 2$

- više pristupa rješavanju problema linearnog klasifikatora za $M > 2$

$$M = C \quad C > 2$$

Primjer: problem se može reducirati na C problema klasifikacije u dva razreda u kojem se i -ti problem rješava linearnom funkcijom odlučivanja koja odvaja uzorke razreda ω_i od svih ostalih koji ne pripadaju razredu ω_i .



slika za 1. slučaj

1. Slučaj: Granica između $\omega_i ; i=1, 2, \dots, C$
i preostalih razreda

$$d_i(\vec{x}) = w_{i,1}x_1 + w_{i,2}x_2 + \dots + w_{i,n}x_n + w_{i,n+1} = 0$$

$$d_i(\vec{x}) = \vec{w}_i^T \vec{x} + w_{i,n+1}$$

2. slučaj :

Upotrijebi $\frac{c(c-1)}{2}$ linearnih funkcija
odlucivanja tako da sa svakom funkcijom
odvoji se par razreda
 $\frac{n}{2}$

Granica između ω_i i ω_j je zadana s :

$$d_{ij}(\vec{x}) = W_{ij1}x_1 + W_{ij2}x_2 + \dots + W_{ijn}x_n + W_{ijn+1} = 0$$

3. slučaj :

$$\begin{aligned} d_{ij}(\vec{x}) &= d_i(\vec{x}) - d_j(\vec{x}) = \\ &= (W_{i1} - W_{j1})x_1 + (W_{i2} - W_{j2})x_2 + \dots + \\ &\quad (W_{in} - W_{jn}) \cdot x_n + (W_{in+1} - W_{jn+1}) = 0 \end{aligned}$$

$$d_i(\vec{x}) = \vec{W}_i^T \vec{x} + W_{in+1}$$

ako je $d_i(\vec{x}) > d_j(\vec{x}) ; j=1, 2, \dots; j \neq i$

onda $\vec{x} \in \omega_i$

klasifikator \rightarrow Linearni stroj (engl. linear machine)

$$(\vec{W}_i - \vec{W}_j)^T \vec{x} + (W_{in+1} - W_{jn+1}) = 0$$

ODREĐIVANJE FUNKCIJE ODLUCIVANJA → UČENJE ILI VJEŽBANJE

Problem oblikovanja linearne klasifikatora:
odrediti koeficijente linearne funkcije odlučivanja:

$$\vec{W} = \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_n \end{bmatrix} \quad i \quad w_{n+1}$$
$$d(\vec{x}) = \vec{W}^T \vec{x} + w_{n+1}$$

"Automatizirati" postupak određivanja koeficijenata linearne funkcije odlučivanja:
iterativni postupak **učenja** koeficijenata linearne funkcije odlučivanja uporabom uzoraka iz skupa za učenje (engl. training set).

N uzoraka: $\vec{x}_1, \vec{x}_2, \dots, \vec{x}_N$
razvrstani u dva razreda w_1 i w_2
Vektori uzoraka $\vec{x}_i \quad i=1, 2, \dots, N$
su "oznaceni" vektori tj. oni sa poznatom pripadnosti razredu
(w_1 ili w_2). **UPOTRIJEBIT**
ĆEMO IH ZA UČENJE $d(\vec{x})$!

Povećat cemo dimenzionalnost vektora \vec{x} za jedan

$$\vec{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \\ 1 \end{bmatrix}$$

radi elegantnijeg zapisa:

$$d(\vec{x}) = \vec{w}^T \vec{x}$$

Uspijemo li odrediti takav vektor težinskih koeficijenata \vec{w} tako da pomoći funkcije $d(\vec{x})$ pravilno razvrstamo sve uzorke (iz skupa za učenje), kažemo da su ω_1 i ω_2 LINEARNO RAZDVOJIVI.

$$M=2$$

Uzorak \vec{x} je pravilno razvrstan ako za sve \vec{x} iz ω_1

vrijedi $\vec{w}^T \vec{x} > 0$ i ako

za sve \vec{x} iz ω_2

vrijedi $\vec{w}^T \vec{x} < 0$

Jedinstven uvjet: $\vec{w}^T \vec{x} > 0$

ako uzorke iz ω_2 pomnožimo

s -1 !

Redefiniran problem:

ef 9.

Tražimo vektor koeficijenata \vec{w} linearne funkcije odlučivanja tako da vrijedi

$\vec{w}^T \vec{x} > 0$ za sve uzorke

\vec{x} iz skupa uzoraka za učenje.

/PAZI: uzorci $\vec{x} \in \omega_2$ su pomnoženi s -1 /

odnosno

$[x] \vec{w} > 0$ za sve uzorke \vec{x}

$$[x] = \begin{bmatrix} \vec{x}_1^T \\ \vec{x}_2^T \\ \vdots \\ \vec{x}_N^T \end{bmatrix}$$

$[x]$ je matriča svih uzoraka iz skupa za učenje, s tim da su uzorci iz ω_2 pomnoženi s -1.

$$\vec{w} = (w_1, w_2, \dots, w_n, w_{n+1})^T$$

$\vec{0}$ - multi vektor

PRIMJER 1:

$$\vec{x}_1 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}; \quad \vec{x}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

$$\vec{x}_1 \in \omega_1 \\ \vec{x}_2 \in \omega_1$$

$$\vec{x}_3 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}; \quad \vec{x}_4 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

$$\vec{x}_3 \in \omega_2 \\ \vec{x}_4 \in \omega_2$$

- POVEĆAJMO DIMENZIONALNOST VETORA:

$$\vec{x}_1 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}; \quad \vec{x}_2 = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix}; \quad \vec{x}_3 = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$$

$$\vec{x}_4 = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$$

- POMNOŽIMO SVE UZOREKE IZ RAZREDA ω_2 S -1

$$\vec{x}_3 = \begin{bmatrix} -1 \\ 0 \\ -1 \end{bmatrix}; \quad \vec{x}_4 = \begin{bmatrix} -1 \\ -1 \\ -1 \end{bmatrix}$$

- Oblikujmo matricu $[X]$

$$[X] = \begin{bmatrix} 0 & 0 & 1 \\ 0 & 1 & 1 \\ -1 & 0 & -1 \\ -1 & -1 & -1 \end{bmatrix}_{4 \times 3}$$

$[x] \vec{w} > \vec{0}$

$$\begin{bmatrix} 0 & 0 & 1 \\ 0 & 1 & 1 \\ -1 & 0 & -1 \\ -1 & -1 & -1 \end{bmatrix}_{4 \times 3} \cdot \begin{bmatrix} w_1 \\ w_2 \\ w_3 \end{bmatrix}_{3 \times 1} > \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}_{4 \times 1}$$

Vektor \vec{w} koji zadovoljava sustav linearnih nejednadržbi

$$[x] \cdot \vec{w} > 0$$

nazivamo razvojni vektor.

A) GRADIJENTNI POSTUPCI ODREĐIVANJA RAZVOJNOG VEKTORA

$d(\vec{x})$ - funkcija vektorskog argumenta
 \uparrow vektor!

Opcenito: $f(\vec{y})$

$$\vec{y} = (y_1, y_2, \dots, y_n)^T$$

Gradijent funkcije vektorskog argumenta:

$$\text{grad } f(\vec{y}) = \frac{df(\vec{y})}{d\vec{y}} = \begin{bmatrix} \frac{df}{dy_1} \\ \frac{df}{dy_2} \\ \vdots \\ \frac{df}{dy_n} \end{bmatrix}$$

- GRADIJENT SKALARNE FUNKCIJE VEKTORSKOG ARGUMENTA JE VEKTOR

- svaka komponenta gradijenta predstavlja veličinu promjene funkcije u smjeru komponente vektora

VRNEDJ:

- Povećanje argumenta u smjeru pozitivnog gradijenta funkcije f dovodi nas do maksimuma funkcije f
- povećanje argumenta u smjeru negativnog gradijenta dovodi nas do minimuma funkcije f

PRIMJER 2:

$$\text{Funkcija } J(w, 1) = (|w| - w)$$


$$\frac{\partial J(w, 1)}{\partial w} = \operatorname{sgn}(w) - 1$$

$$\operatorname{sgn}(x) = \begin{cases} 1 & \text{za } x > 0 \\ -1 & \text{za } x \leq 0 \end{cases}$$

$$\frac{\partial J}{\partial w} = -2 \quad \text{ako je } w \leq 0$$

$$= 0 \quad \text{ako je } w > 0$$

$$w(k+1) > w(k)$$



↑ povećaje
 argumenta u smjeru
 negativne vrijednosti komp.
 gradijenta \Rightarrow prema min.

ef14

$$\vec{w}^T \vec{x}_i > 0 \quad \text{za } i=1,2,\dots,N$$

$$\begin{matrix} \vec{w}^T \\ [1 \times 3] \end{matrix} \cdot \begin{matrix} \vec{x}_i \\ [3 \times 1] \end{matrix} > 0 \quad [1 \times 1]$$

gdje je \vec{x}_i - i-ti (transponirani) redak matrice $[X]$ dimenzija $N \times (n+1)$

OSNOVNA ZAMISAO:

IZABRATI NEKU FUNKCIJU KOJA ĆE DOSTIĆI MINIMUM KAD JE ISPUNJEN UVJET:

$$\vec{w}^T \vec{x}_i > 0 \quad \text{za sve } i=1,2,\dots,N$$

- zahtijevamo da izabrana funkcija ima samo jedan minimum (i naravno, funkcija je funkcija vektorskog argumenta (\vec{w})).

UŽMIMO FUNKCIJU: \rightarrow apsolutna vrijednost!

$$J(\vec{w}, \vec{x}) = \underbrace{(|\vec{w}^T \vec{x}|)} - \vec{w}^T \vec{x}$$

- minimum funkcije $J(\vec{w}, \vec{x}) = 0$
- trivijalan slučaj $\vec{w} = \vec{0}$

- Netrivijalan slučaj:

67/5

MINIMUM (KRITERIJSKE) FUNKCIJE
 $J(\vec{w}, \vec{x})$ POSTIŽE SE
PRI ISPUNJENJU UVJETA
 $\vec{w}^T \vec{x} > 0$

GRADIJENTNI POSTUPAK:
KORAK PO KORAK POVEĆAVAMO
ARGUMENT \vec{w} U SMJERU
NEGATIVNOG GRADIJENTA
FUNKCIJE $J(\vec{w}, \vec{x})$ SVE DOK
NE POSTIGNEMO MINIMUM
(KRITERIJSKE) FUNKCIJE
 $J(\vec{w}, \vec{x})$.

$\vec{w}(k)$ - vrijednost \vec{w} u k-tom koraku

$$\vec{w}(k+1) = \vec{w}(k) - c \left\{ \frac{\partial J(\vec{w}, \vec{x})}{\partial \vec{w}} \right\}$$

$\vec{w} = \vec{w}(k)$

$\vec{w}(k+1)$ - vrijednost "novog" vektora \vec{w} (u $k+1$ koraku)

c - pozitivna konstanta, različita od 0, koja određuje veličinu korekcije

/ korekcija se više ne izvodi kada je

$\frac{\partial J(\vec{w}, \vec{x})}{\partial \vec{w}} = \hat{0}$; što je uvjet za minimum /

PRIMJER 3:

Funkcija :	Derivacije	Funkcija	Derivacija
C (konst.)	0	e^x	e^x
x^n	$n x^{n-1}$	a^x	$a^x (\ln a)$
$\frac{1}{x}$	$-\frac{1}{x^2}$	$\ln x$	$\frac{1}{x}$
$\frac{1}{x^n}$	$-\frac{n}{x^{n+1}}$		
\sqrt{x}	$\frac{1}{2\sqrt{x}}$		
$\sqrt[n]{x}$	$\frac{1}{n\sqrt[n]{x^{n-1}}}$		

Derivacija funkcije s konst. faktorom

$$(cu)' = c \cdot u'$$

Derivacija produkta dviju ili nekoliko funkcija

$$(uv)' = uv' + u'v$$

$$(uvw) = uvw' + uv'w + u'vw$$

Derivacija razlomaka

$$\left(\frac{u}{v}\right)' = \frac{v \cdot u' - u \cdot v'}{v^2}$$

Derivacija funkcije od funkcija (složene funkcije)

$y = f(u)$ i $u = \varphi(x)$ tada

$$\frac{dy}{dx} = f'(u) \cdot \varphi'(x)$$

Derivacija složene funkcije od nekoliko

variabli: $u = f(x, y, \dots, t)$

gdje je $x = \varphi(\xi)$ $y = \psi(\xi), \dots, t = \chi(\xi)$

$$\frac{du}{d\xi} = \frac{\partial u}{\partial x} \frac{dx}{d\xi} + \frac{\partial u}{\partial y} \frac{dy}{d\xi} + \dots + \frac{\partial u}{\partial t} \frac{dt}{d\xi}$$

Derivirajuće linearne funkcije:

$$\frac{d}{d\vec{x}} (\vec{x}^T A) = A$$

$$\frac{d}{d\vec{x}} (\vec{x}^T) = I$$

$$\frac{d}{d\vec{x}} (\vec{x}^T \vec{a}) = \frac{d}{d\vec{x}} (\vec{a}^T \vec{x}) = \vec{a}$$

$$\frac{d}{d\vec{x}} (\vec{a}^T \vec{x} \vec{b}) = \vec{a} \vec{b}^T$$

$$\frac{d}{d\vec{x}} (\vec{a}^T \vec{x} \vec{a}) = \frac{d}{d\vec{x}} (\vec{a}^T \vec{x}^T \vec{a}) = \vec{a} \vec{a}^T$$

$$\frac{d}{d\vec{x}} (\vec{x}^T C \vec{x}) = (C + C^T) \vec{x}$$

ako je $C = C^T$ onda

$$\frac{d}{d\vec{x}} (\vec{x}^T C \vec{x}) = 2C \vec{x}$$

$$\frac{d}{d\vec{x}} (\vec{x}^T \vec{x}) = 2\vec{x}$$


$$\frac{d}{d\vec{x}} (A\vec{x} + \vec{b})^T (D\vec{x} + \vec{e}) = A^T (D\vec{x} + \vec{e}) + D^T (A\vec{x} + \vec{b})$$

PERCEPTRON (Rosenblatt, 1957)

P1

- bionika (biologija - elektronika): grana znanosti koja trazi polazne točke za rješenje tehničkih problema u uzorima što ih čovjeku pruža sama priroda
- : primjena bioloških koncepta za izgradnju električnih naprava

Perceptron - klasificira uzorce u jedan od dva razreda



pz

Jedinica u polju A generira izlaz realicit od 0 ako je dovoljan broj senzorskih jedinica priključenih na A jedinici pobuden (aktiviran).

x_i - odgovor i -te asocijativne jedinice

w_i - težinska vrijednost

Odgovor R proporcionalan je sumi odgovora A jedinica; odgovori su pomnoženi težinskim knjednostima w_i :

$$R = \sum_{i=1}^{n+1} w_i x_i = \vec{w}^T \vec{x}$$

Pravilo klasifikacije:

- ako je $R > 0$ nepoenati se uzorak razvrstava u ω_1

- ako je $R < 0$ nepoenati se uzorak razvrstava u ω_2

Perceptron - klasifikator uzoraka
u dva razreda - ako
su razredi linearno
separabilni

- modifikacija perceptrona za
klasifikaciju uzoraka u $M > 2$
razreda:

M - jedinica R

R_1, R_2, \dots, R_M

Pravilo:

Uzorak se razvrstava u razred
 w_i ažda $R_i > R_j$ za sve $i \neq j$.

Osnovni model perceptrona može se
raširiti na nelinearne decizijske
funkcije umetanjem nelinearnog
pretprocesora između A i R poja

- Višeslojni perceptron MLP

ALGORITAM PERCEPTRONA

(Reward - Punishment Concept)

Algoritam učenja perceptrona:

- zadana su dva skupa uzoraka za učenje koji pripadaju razredu w_1 i w_2

- $\vec{w}(1)$ početna vrijednost vektora težinskih koeficijenata - proizvoljno izabran.

- k-ti korak učenja :

- Ako $\vec{x}(k) \in w_1$ i

$\vec{w}^T(k) \vec{x}(k) \leq 0$ zamijeni $\vec{w}(k)$ sa

$$\vec{w}(k+1) = \vec{w}(k) + c \vec{x}(k),$$

gdje je c korekcijski faktor

- Ako $\vec{x}(k) \in w_2$ i


$\vec{w}^T(k) \vec{x}(k) \geq 0$ zamijeni

$$\vec{w}(k+1) = \vec{w}(k) - c \vec{x}(k)$$

- u drugim slučajevima ostavi $\vec{w}(k) \Rightarrow \vec{w}(k+1) = \vec{w}(k)$

- c mora biti pozitivan (: konstanta).

PRIMJER



$$\omega_1 : \{(0,0,1)', (0,1,1)'\}$$

$$\omega_2 : \{(1,0,1)', (1,1,1)'\}$$

$$c=1 \quad i \quad \vec{w}(1)=\vec{0}$$

1.k.

$$\vec{w}^T(1) \cdot \vec{x}(1) = (0,0,0) \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} = 0$$

$$\vec{w}(2) = \vec{w}(1) + \vec{x}(1) = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}$$

2.k.

$$\vec{w}^T(2) \cdot \vec{x}(2) = (0,0,1) \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix} = 1$$

$$\vec{w}(3) = \vec{w}(2) = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}$$

3.k.

$$\vec{w}^T(3) \cdot \vec{x}(3) = (0,0,1) \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} = 1$$

$$\vec{w}(4) = \vec{w}(3) - \vec{x}(3) = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} - \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} = \begin{pmatrix} -1 \\ 0 \\ 0 \end{pmatrix}$$

4.k.

$$\vec{w}^T(4) \vec{x}(4) = (-1, 0, 0) \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = -1$$

$$\vec{w}(5) = \vec{w}(4) = \begin{pmatrix} -1 \\ 0 \\ 0 \end{pmatrix}$$

zbog korekcija u 1. i 3. koraku postupak
se ponavlja!

[RJEŠENJE SE DOBIVA SAMO KAD ALGORITAM
DAJE POTPUNO ERROR - FREE ITERACIJU
ZA SVE UZORKE U SKUPU ZA UČENJE]

$$\vec{x}(5) = \vec{x}(1)$$

$$\vec{x}(6) = \vec{x}(2)$$

$$\vec{x}(7) = \vec{x}(3)$$

$$\vec{x}(8) = \vec{x}(4)$$

DRUGA ITERACIJA DAJE:

$$\vec{w}^T(5) \cdot \vec{x}(5) = (-1, 0, 0) \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} = 0$$

$$\vec{w}(6) = \vec{w}(5) + \vec{x}(5) = \begin{pmatrix} -1 \\ 0 \\ 0 \end{pmatrix} + \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} = \begin{pmatrix} -1 \\ 0 \\ 1 \end{pmatrix}$$

$$\vec{w}^T(6) \cdot \vec{x}(6) = (-1, 0, 1) \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix} = 1$$

$$\vec{w}(7) = \vec{w}(6) = \begin{pmatrix} -1 \\ 0 \\ 1 \end{pmatrix}$$

$$\vec{w}^T(7) \cdot \vec{x}(7) = (-1, 0, 1) \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} = 0$$

$$\vec{w}(8) = \vec{w}(7) - \vec{x}(7) = (-1, 0, 1)^T - \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} = \begin{pmatrix} -2 \\ 0 \\ 0 \end{pmatrix}$$

$$\vec{w}^T(8) \cdot \vec{x}(8) = (-2, 0, 0) \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = -2$$

$$\vec{w}(9) = \vec{w}(8)$$

Dogodile su se drijje pogreške!

Nova iteracija

$$\vec{x}(9) = \vec{x}(1)$$

$$\vec{x}(10) = \vec{x}(2)$$

$$\vec{x}(11) = \vec{x}(3)$$

$$\vec{x}(12) = \vec{x}(4)$$

$$\vec{w}^T(9) \cdot \vec{x}(9) = 0 \quad \vec{w}(10) = \vec{w}(9) + \vec{x}(9) = \begin{pmatrix} -2 \\ 0 \\ 1 \end{pmatrix}$$

$$\vec{w}^T(10) \cdot \vec{x}(10) = 1 \quad \vec{w}(11) = \vec{w}(10) = \begin{pmatrix} -2 \\ 0 \\ 1 \end{pmatrix}$$

$$\vec{w}^T(11) \cdot \vec{x}(11) = -1 \quad \vec{w}(12) = \vec{w}(11) = \begin{pmatrix} -2 \\ 0 \\ 1 \end{pmatrix}$$

$$\vec{w}^T(12) \cdot \vec{x}(12) = -1 \quad \vec{w}(13) = \vec{w}(12) = \begin{pmatrix} -2 \\ 0 \\ 1 \end{pmatrix}$$

Dogodila se pogreška! Nova iteracija:

$$\vec{x}(14) = \vec{x}(1) = (0, 0, 1)^T$$

$$\vec{x}(15) = \vec{x}(2) = (0, 1, 1)^T$$

$$\vec{x}(16) = \vec{x}(3) = (1, 0, 1)^T$$

$$\vec{x}(17) = \vec{x}(4) = (1, 1, 1)^T$$

$$\vec{w}^T(14) \cdot \vec{x}(14) = (-2, 0, 1) \cdot \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} = 1 \quad \vec{w}(15) = \vec{w}(14) = \begin{pmatrix} -2 \\ 0 \\ 1 \end{pmatrix}$$

$$\vec{w}^T(15) \cdot \vec{x}(15) = (-2, 0, 1) \cdot \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix} = 1 \quad \vec{w}(16) = \vec{w}(15)$$

$$\vec{w}^T(16) \cdot \vec{x}(16) = (-2, 0, 1) \cdot \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} = -1 \quad \vec{w}(17) = \vec{w}(16)$$

$$\vec{w}^T(17) \cdot \vec{x}(17) = (-2, 0, 1) \cdot \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = -1 \quad \vec{w}(18) = \vec{w}(17)$$

$$d(\vec{x}) = -2x_1 + 1$$

$$\boxed{\vec{w} = \begin{pmatrix} -2 \\ 0 \\ 1 \end{pmatrix}}$$

PRIMJER 4:

$$\omega_1 = \{(0,0)^T, (0,1)^T\};$$

$$\omega_2 = \{(1,0)^T, (1,1)^T\}$$

- povećajmo dimenzionalnost prostora znacajki na dimenziju $n+1$.

$$\{(0,0,1)^T, (0,1,1)^T\}$$

$$\{(1,0,1)^T, (1,1,1)^T\}$$

- pomnožimo sve uzorke iz razreda ω_2 sa -1

$$\{(-1,0,-1)^T, (-1,-1,-1)^T\}$$

- pretpostavimo da su skupovi uzoraka za učenje razdvojivi linearnom funkcijom odlučivajuća

$$d(\vec{x}) = w_1 x_1 + w_2 x_2 + w_3 \\ = \vec{w}^T \vec{x}$$

- postupak perceptron-a sa stalnim priрастom

Neka je $C=1$ i neka je početni vektor koeficijenata $\vec{w}(1)$ proizvoljni, npr. $\vec{w}(1) = (-1, 0, 0)^T$.

- u prvom koraku učenja uzimamo uzorak $\vec{x}(1) = (0, 0, 1)^T$

Računamo:

$$\vec{w}^T(1) \cdot \vec{x}(1) = (-1, 0, 0) \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} = 0,$$

zbog toga

$$\vec{w}(2) = \vec{w}(1) + \vec{x}(1) = \begin{pmatrix} -1 \\ 0 \\ 1 \end{pmatrix}.$$

U drugom koraku učenja uzimamo uzorak $\vec{x}(2) = (0, 1, 1)^T$

Racunamo:

$$\vec{w}^T(2) \cdot \vec{x}(2) = (-1, 0, 1) \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix} = 1$$

Zato sto je $\vec{w}^T(2) \cdot \vec{x}(2) > 0$, u skladu s postupkom učenja $\vec{w}(3) = \vec{w}(2)$

U trećem koraku upotrebjavamo uzorak $\vec{x}(3) = (-1, 0, -1)^T$

Racunamo:

$$\vec{w}^T(3) \cdot \vec{x}(3) = (-1, 0, 1) \begin{pmatrix} -1 \\ 0 \\ -1 \end{pmatrix} = 0$$

$$\vec{w}(4) = \vec{w}(3) + \vec{x}(3)$$

$$\vec{w}(4) = \begin{pmatrix} -2 \\ 0 \\ 0 \end{pmatrix}$$

U četvrtom koraku učenja uzimamo uzorak $\vec{x}(4) = (-1, -1, -1)^T$

Racunamo:

$$\vec{w}^T(4) \vec{x}(4) = (-2, 0, 0) \begin{pmatrix} -1 \\ -1 \\ -1 \end{pmatrix} = 2$$

Buduci da je $\vec{w}^T(4) \vec{x}(4) > 0$ vrijedi $\vec{w}(5) = \vec{w}(4)$

**RJEŠENJE ĆEMO DOBITI KADA NA TEHEĆU IZRAČUNATOG
 \vec{w} PRAVILNO RAZVRSTAVAMO SVE UZORKE**

- u ovom primjeru došlo je do pogrešnog razvrstavanja dva uzorka - posljedica \rightarrow popravljajuće vektora koef. funkcije odlučivanja \vec{w} .

Postupak učenja nastavljamo tako da pretpostavimo $\vec{x}(5) = \vec{x}(1)$, $\vec{x}(6) = \vec{x}(2)$, $\vec{x}(7) = \vec{x}(3)$ i $\vec{x}(8) = \vec{x}(4)$

Dobivamo:

$$\vec{w}^T(5) \vec{x}(5) = 0 \quad \text{dijedi} \quad \vec{w}(6) = \vec{w}(5) + \vec{x}(5)$$

$$\vec{w}(6) = \begin{pmatrix} -2 \\ 0 \\ 1 \end{pmatrix}$$

$$\vec{w}^T(6) \vec{x}(6) = 1 \quad \text{dijedi} \quad \vec{w}(7) = \vec{w}(6)$$

$$\vec{w}^T(7) \vec{x}(7) = 1 \quad \text{dijedi} \quad \vec{w}(8) = \vec{w}(7) = \begin{pmatrix} -2 \\ 0 \\ 1 \end{pmatrix}$$

$$\vec{w}^T(8) \vec{x}(8) = 1 \quad \text{dijedi} \quad \vec{w}(9) = \vec{w}(8) = \begin{pmatrix} -2 \\ 0 \\ 1 \end{pmatrix}$$

I u drugom ponavljanju nisu bili razvrtiani svi uzorci pravilno. Treća iteracija:

$$\vec{x}(9) = \vec{x}(1) \quad \vec{x}(10) = \vec{x}(2) \quad \vec{x}(11) = \vec{x}(3)$$

$$\vec{x}(12) = \vec{x}(4)$$

$$\vec{w}^T(9) \vec{x}(9) = (-2, 0, 1) \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} = 1 \quad ; \rightarrow \vec{w}^T(10) = \vec{w}^T(9)$$

$$\vec{w}^T(10) \vec{x}(10) = (-2, 0, 1) \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix} = 1 \quad \rightarrow \vec{w}^T(11) = \vec{w}^T(10)$$


$$\vec{w}^T(11) \vec{x}(11) = (-2, 0, 1) \begin{pmatrix} -1 \\ 0 \\ -1 \end{pmatrix} = 3 \quad \vec{w}^T(12) = \vec{w}^T(11)$$

$$\vec{w}^T(12) \vec{x}(12) = (-2, 0, 1) \begin{pmatrix} -1 \\ -1 \\ -1 \end{pmatrix} = 1 \quad \vec{w}^T(13) = \vec{w}^T(12)$$

$$\vec{w} = (-2, 0, 1)^T$$


$$\text{Decizija funkacija } d(\vec{x}) = \underline{\vec{w}^T \vec{x}} = \underline{-2x_1 + 1}$$

Uzorci za rješavanje:



Naučena funkcija odlučivanja:

$$d(\vec{x}) = -2x_1 + 1 = 0$$



$$\bullet \in \omega_1$$

$$\circ \in \omega_2$$