

VIS III. CIKLUS

UZORAK

Uzorak je X slučajna varijable s raspodjelom F . Za slučajne varijable X_1, \dots, X_n kažemo da su nezavisne kopije slučajne varijable X , ako one imaju svojstva:

1. međusobno su nezavisne
 2. imaju raspodjelu identične raspodjeli slučajne varijable X .
- Tako dobivena n -torke slučajnih varijabli (X_1, \dots, X_n) nazivamo uzork. Ako je x_1 realizacija varijable X_1 , x_2 realizacija X_2 itd., tada će (x_1, \dots, x_n) nazivati vrijednost ili realizacija uzorka (X_1, \dots, X_n) . Broj n označava veličinu (dimenziju ili volumen) uzorka.

STATISTIKA, PROCJENITELJ I PROCJENA

Slučajna varijable $\theta := g(X_1, \dots, X_n)$ nazivamo se statistika. Statističkom nazivom označavamo funkciju koja ovisi o uzorku X_1, \dots, X_n , a ne ovisi (eksplicitno) o nepoznatim parametrima. Uzorak je ν nepoznati parametri u populaciji X . Za statistiku kažemo da je procjenitelj parametra ν . Vrijednost te statistike $\hat{\theta} := g(x_1, \dots, x_n)$ nazivamo procjenom parametra ν .

PROCJENA: OČEKIVANJE I SVR

Nepresto očekivanje a populacije X procjenjujemo pomoću sredine uzorka:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Za slučajnu varijablu vrijedi $E(\bar{X}) = \mu$; $D(\bar{X}) = \frac{\sigma^2}{n}$
gdje je σ^2 varijanca (disperzija) populacije.

NEPRISTRANI PROCJENITELJI

Za statistiku θ kažemo da je nepristrani procjenitelj ili nepristrana statistika parametra v , ukoliko vrijedi

$$E(\theta) = v$$

USPOREDBA STATISTIKA

Ukao je (X_1, \dots, X_n) uzorak, i neponeti parametar te $\theta_1(X_1, \dots, X_n), \theta_2(X_1, \dots, X_n)$ dvije nepristrane statistike za v . Kažemo da je θ_1 bolja (efikasnija) od θ_2 ako je $D(\theta_1) < D(\theta_2)$.

VALJANE STATISTIKE - raste broj uzorka mora biti bolja aproksimacija.

Statistiku $\theta_m = \theta(X_1, X_2, \dots, X_m)$ nazivamo valjanim
procjenom parametra v ako za svaki $\varepsilon > 0$ slučajna varijabla
 θ_m konvergira prema v po vjerojatnosti:

$$\lim_{m \rightarrow \infty} P(|\theta_m - v| < \varepsilon) = 1$$

TEM. Da bi nepristrana statistika bila veljana, dovoljno je da joj dispersija teži u nulu (kad u teži u beskonačnost).

DOKAZ: slijedi iz Čibotićeve nejednakosti:

$$P(|\theta_m - \vartheta| < \varepsilon) \geq 1 - \frac{E[(\theta_m - \vartheta)^2]}{\varepsilon^2} = 1 - \frac{D(\theta_m)}{\varepsilon^2} \rightarrow 1$$

PROCJENE DISPERZIJE

Ako je očekivajte a populacije X poznato, nepristrana procjena nepoznate dispersije σ^2 računa se formулом

$$D^2 := \frac{1}{m} \sum_{i=1}^m (X_i - \bar{x})^2.$$

Ako su očekivajte a ; dispersija σ^2 populacije X nepoznati, onda se nepristrani procinitelji za dispersiju računaju formулом

$$S^2 := \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

KRITERIJ NAJVEĆE IZGLEDNOSTI

Neka je x_1, x_2, \dots, x_n realizacija varake populacije X , čija funkcija gustoće $f(\vartheta, x)$ ovisi o nepoznatom parametru ϑ . Funkcija izglednosti definira se kao umnošak

$$L(\vartheta, x_1, \dots, x_n) := f(\vartheta, x_1) f(\vartheta, x_2) \dots f(\vartheta, x_n).$$

Za procjenu parametra ϑ unimamo onu vrijednost $\hat{\vartheta}$ za koju funkcija izglednosti poprima globalni maksimum.

KVANTILI

Realan broj x_p za koji vrijedi $F(x_p) = p$ to jest

$$\int_{-\infty}^{x_p} f(t) dt = p \text{ naziva se kvantil reda } p.$$

INTERVAL POVJERENJA SVUĐAJNE VARIJABLE

Neka je $0 < p < 1$. Interval $[c_1, c_2]$ za koji vrijedi $P(c_1 < X < c_2) = p$ naziva se interval povjerenja reda p za občajnu varijablu X .

$$c_2 - c_1 \rightarrow \min$$

$$\int_{c_1}^{c_2} f(t) dt = p, \quad \text{f je samo jednu točku lokalnog maksimuma} \\ \Rightarrow \text{unimodalna funkcija gustote}$$

UVOD ZNAČAJNOSTI

za zadani broj p , $0 < p < 1$ koji određuje interval povjerenja, veličina $\lambda = 1 - p$ naziva se nivo značajnosti (signifikantnosti).

Pri tom za jednostrane kvantile vrijedi:

$$x_p = x_1 - \alpha \quad x_{1-p} = x_\alpha$$

, a za dvostrane:

$$x_{\frac{\alpha}{2}(1-p)} = x_{\frac{\alpha}{2}} \quad x_{\frac{1}{2}(1+\lambda)} = x_{1-\frac{\alpha}{2}}$$

INTERVAL POVJERENJA ZA NEPOZNATI PARAMETAR

Prestpostavimo da postoji funkcije $\Theta(x_1, \dots, x_n)$, $\bar{\Theta}(x_1, \dots, x_n)$ tako da za sve neodržavajuće x_1, \dots, x_n uzorka vrijedi:

$$P \left\{ \Theta(x_1, \dots, x_n) < \theta < \bar{\Theta}(x_1, \dots, x_n) \right\} = p$$

Interval $(\Theta, \bar{\Theta})$ će zovu interval povjerenja za θ reda p .

UZ POZNATU DISPERZIJU σ^2

RAZDIOBA SREDINE UZORKA

TRM. Ako populacija X -ima ima normalnu $N(\mu, \sigma^2)$, onda je sredina uzorka vrijedna:

$$\bar{X} = \frac{X_1 + \dots + X_n}{n} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

INTERVALI POUJEREVJA ZA OČEKIVANJE NORMALNE RAZDIOBE, UZ POZNATI σ^2

1. Izabire se nivo pouzdanosti p i odredi $\alpha = 1 - p$.
2. Iz tablice kvantila normalne raspodjelje, odredi se kvantil $u_{1-\frac{\alpha}{2}}$.
3. Izračuna se sredina \bar{X} uzorka X_1, \dots, X_n .
4. Izračuna se $u_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}$.

$$\text{Interval poujerenja je: } P\left(\bar{X} - u_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + u_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}\right) = p$$

UZ POZNATO OČEKIVANJE

JEDNOSTRANI INTERVAL POUJEREVJA ZA DISPERZIJU

1. Izabire se nivo pouzdanosti.
2. Iz tablice kvantila hi kvadrat vrijednosti s $n-1$ stupnjeva slobode, odredi se odgovarajući kvantil χ_{n-1-p}^2 .
3. Izračuna se poujena disperzija s^2 iz uzorka x_1, \dots, x_n .
4. Izračuna se $\frac{(n-1)s^2}{\chi_{n-1-p}^2}$.

$$\text{Jednostani interval poujerenja je: } P\left(0 \leq \sigma^2 \leq \frac{(n-1)s^2}{\chi_{n-1-p}^2}\right) = p$$

DVOSTRANI INTERVAL POVJERENJA ZA DISPERZIJU

1. Izdaje se nivo pouzdanosti $p = 1 - \alpha$
2. Iz tablice kvantila: u m kvadrat varijable s m stupnjeva slobode, određe se kvantili $c_1 = \chi^2_{m, \frac{\alpha}{2}} : c_2 = \chi^2_{m, 1-\frac{\alpha}{2}}$.
3. Izračunaju se dispersija \hat{d}^2 uzorka x_1, \dots, x_m .
4. Izračunaju se $\gamma_1 = \frac{m \hat{d}^2}{c_2}, \gamma_2 = \frac{m \hat{d}^2}{c_1}$.

Dvostani interval povjerenja je $P(\gamma_1 \leq \tau^2 \leq \gamma_2) = p$.

TEH. Neka su X_1, \dots, X_m nezavisne $\sim N(\mu, \sigma^2)$ varijabla.

Tada su \bar{X}, S^2 nezavisne duće varijable! Pri tom $(m-1) S^2 / \sigma^2$ ima χ^2_{m-1} varidobu.

STUDENTOVA RAZDIOBA

X, X_1, \dots, X_m nezavisne jedinice normalne varijable. Tada duće varijable:

$$t := \frac{X}{\sqrt{(x_1^2 + \dots + x_m^2)/m}} = \frac{X}{\sqrt{X_m/m}} \text{ ima Studentovu varidobu (t-varijablu)}$$

$$\text{Izgleda } t_m : f(x) = C_m \left(1 + \frac{x^2}{m}\right)^{-\frac{m+1}{2}}$$

Interval $(0, \delta)$ je ovaj interval povjerenja za red.

INTERVALI POUJERENJA ZA ~~DISPERSIJU~~ OČEKIVANJE NORMALNE RAZDIODE, UZ NEPOZNATI σ^2

1. Izrađuje se nivo pouzdanosti $p = 1 - \alpha$.
2. Iz tablica kvantila Studentove razdiobe s $m-1$ stupnjeva slobode, odredi se odgovarajući kvantil $t_{1-\frac{\alpha}{2}}$.
3. Izrađena se procjena sredine \bar{x} uorka.
4. Izrađena se procjena disperzije \hat{s}^2 uorka.
5. Izrađena se $\bar{x} \pm t_{1-\frac{\alpha}{2}} \frac{\hat{s}}{\sqrt{m}}$.

Interval poujerenja je:

$$P\left(\bar{x} - t_{1-\frac{\alpha}{2}} \frac{\hat{s}}{\sqrt{m}} \leq a \leq \bar{x} + t_{1-\frac{\alpha}{2}} \frac{\hat{s}}{\sqrt{m}}\right) = p.$$

INTERVALI POUJERENJA ZA DISPERZIJU NORMALNE RAZDIODE, UZ NEPOZNATO OČEKIVANJE a

1. Izrađuje se nivo pouzdanosti p i odredi $\alpha = 1 - p$.
- 2a. Za jednostrani interval, iz tablica kvantila li kvadrat razdiobe s $m-1$ stupnjeva slobode, odredi se odgovarajući kvantil $c = \chi^2_{m-1, \alpha}$.
- 2b. Za dvostrani interval, iz tablica kvantila li kvadrat razdiobe s $m-1$ stupnjeva slobode, odredi se kvantili $c_1 = \chi^2_{m-1, \frac{\alpha}{2}}, c_2 = \chi^2_{m-1, 1-\frac{\alpha}{2}}$.
3. Izrađena se nepristrana procjena disperzije \hat{s}^2 uorka.

4a. Izrađuna se: $\beta = \frac{(m-1)s^2}{c}$.

4b. Izračunaju se $\beta_1 = \frac{(m-1)s^2}{c_2}$, $\beta_2 = \frac{(m-1)s^2}{c_1}$.

Jednostrani interval poujerenja je $P(0 \leq T^2 \leq \beta) = p$.

Dvostrani interval poujerenja je $P(\beta_1 \leq T^2 \leq \beta_2) = p$

Centralni granični teorem

Neka je (X_m) miz identički distribuiranih nezavisnih slučajnih varijabli s očekivanjem a i disperzijom T^2 . Označimo $Z_m = X_1 + \dots + X_m$. Onda vrijedi

$$\frac{Z_m - ma}{\sqrt{T^2}} \xrightarrow{D} N(0, 1)$$

INTERVALNA PROCJEVA ZA VJEROJATNOST P DOGADAJA

Procjena vjerojatnosti p događaja A računa se pomoću relativne frekvencije pojavljivanja tog događaja: $\hat{p} = \frac{m}{n}$.

Interval poujerenja za vjerojatnost reda $1-\alpha$ jest

$$P(p_1 \leq p \leq p_2) = 1-\alpha$$

pri čemu se rubovi računaju formулом

$$p_{1,2} = \hat{p} \pm u_{1-\frac{\alpha}{2}} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

SNAGA TESTA

Snaga testa je funkcija $S: \Lambda \rightarrow [0, 1]$ definisana ovako:

$$S(\omega) = P\left(\{\text{prihvadaju je alternativa } H_1\}\right)$$

POGREŠKE PRVE I DRUGE VRSTE

Definirajmo $\alpha = \sup_{\omega \in H_0} S(\omega)$.

Ovaj broj označava maksimalnu vjerojatnost da je prihvadena alternativa H_1 , iako je istinita H_0 . Broj α mora se pogreška prve vrste.

Na isti način: $\beta = \sup_{\omega \in H_1} [1 - S(\omega)]$ definira pogrešku druge vrste.

Ova daje maksimalnu vjerojatnost da je prihvadena hipoteza H_0 , iako je istinita H_1 .

TEST

Izberite se kritična vrijednost x_α .

Ukoliko je realizacija statistike veća od x_α prihvada se hipotezu H_0 . (možda pogreška II. vrste)

Ukoliko je realizacija statistike manja od x_α odbacuje se hipotezu H_0 (možda pogreška I. vrste)

TESTIRANJE PARAMETARSKIM HIPOTEZA - JEDNOSTRANI TESTOVI

Zadaje se nivo značajnosti α . Na temelju pomoći razdiobe uz pretpostavljenu istinitost hipoteze H_0 određe se

1. kvantil $x_{1-\alpha}$ (za $\nu > \nu_0$) ili
2. kvantil x_α (za $\nu < \nu_0$).

Hipoteza H_0 se odbacuje ukoliko vrijednost \hat{x} varijable izracunate iz uzorka padne van intervala povjerenja reda $1-\alpha$: $\hat{x} > x_{1-\alpha}$ u prvom slučaju, odnosno $\hat{x} < x_\alpha$, u drugom slučaju. U protivnom se hipoteza ne može odbaciti.

TESTIRANJE PARAMETARSKIM HIPOTEZA - DVOSTRANI TEST

Zadaje se nivo značajnosti α . Na temelju pomoći razdiobe uz pretpostavljenu istinitost hipoteze H_0 određe se kvantili $x_{\frac{\alpha}{2}}$ i $x_{1-\frac{\alpha}{2}}$ za dvostrane alternativne $\nu \neq \nu_0$.

Hipoteza H_0 se odbacuje, ukoliko vrijednost \hat{x} varijable izracunate iz uzorka padne van intervala povjerenja reda $1-\alpha$: $\hat{x} > x_{1-\frac{\alpha}{2}}$ ili $\hat{x} < x_{\frac{\alpha}{2}}$. U protivnom se hipoteza prihvaca.

U-test - nepoznato očekivanje i poznata disperzija

Zadaje se nivo značajnosti α . Na temelju njega odredi se kvantil

1. $u_{\nu-\alpha}$, u slučaju jednostvarnih alternativa, te
2. $u_{1-\frac{\alpha}{2}}$, u slučaju dvostavnih alternativa.

Izrađena je vrijednost u statistike dobivena iz uzorka. Test glasi:

1. Ako je $|u| > u_{1-\alpha}$ (za desnu alternativu) ili $|u| < u_{\nu-\alpha}$ (za lijevu) hipoteza H_0 se odbacuje.
2. Ako je $|u| > u_{1-\frac{\alpha}{2}}$ (za dvostavanu alternativu) hipoteza H_0 se odbacuje.

T-test - neporavno deluje i poravna disperzija

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}, \text{ Mo istinita onda je Studentova varijabla}$$

\Rightarrow test istinkas za normalnu varijablu

Hi kvarant test

1. Uzorak $\{x_1, x_2, \dots, x_n\}$ podjelimo u m varende. Neka je n_k broj realizacija u pojedinom varendenju, te p_k teorijetska vjerovatnost pojedinog varendenja. Minimalni volumen pojedinog varendenja treba biti 5, varende u koje je $n_j < 5$ spajaju se u jedan varjedim.

2. Statistika χ^2 -testa dana je s $\chi^2_2 = \sum_{j=1}^m \frac{(n_j - n_j p_j)^2}{n_j p_j}$.

Sluđljiva varijabla χ^2_2 ima približno χ^2 varijablu sa $f = m - r - 1$ stupnjeva slobode. Tu je r broj parametara varijabke izvijenih iz uzorka.

3. U tablicama pridano kvantil $\chi^2_{1-\alpha}$, za zadani nivo značajnosti α i broj stupnjeva slobode f .

4. Ako je $\chi^2_2 < \chi^2_{1-\alpha}$, prihvaci se hipoteza da se varijabla varijable X podvrgava datijenom zakonu. U protivnom se hipoteza odbacuje.

$$F_m(x) = \frac{\mu_m(x)}{m}$$

TEOREM. Statistika $F_m(x)$ je nepristrana i valjana procjena za vrijednost slučajne varijable $F(x)$.

DOKAZ:

Oznatmo za celi broj k iz skupa $\{1, \dots, m\}$:

$$p = P(X_k \leq x) = F(x)$$

$$1 - p = P(X_k \geq x) = 1 - F(x).$$

Tada slučajna varijable ima binomnu raspodjelu $B(m, p)$.

Stoga vrijedi $E(F_m(x)) = \frac{1}{m} E(\mu_m(x)) = \frac{1}{m} \cdot mp = p = F(x)$

Nadajte prema sljedećem redom veličini brojeva, vrijedi:

$$\left| \frac{B(m, p) - mp}{m} \right| \xrightarrow{P} \emptyset$$

$$\text{pa dobivamo } |F_m(x) - F(x)| \xrightarrow{P} \emptyset$$

Dakle $F_m(x)$ je valjana procjena za $F(x)$.

TEOREM GLIVENKO-CANTELLIJA

Neka su (X_m) nezavisne logije slučajne varijable X s raspodjelom F . tada vrijedi

$$\lim_{m \rightarrow \infty} P\left(\sup_x \left| \frac{\mu_m(x)}{m} - F(x) \right| = \emptyset \right) = 1$$

Dakle, $\frac{\mu_m(x)}{m}$ konvergira ka $F(x)$ skoro sigurno.